



天數智芯
Iluvatar CoreX

天數智芯

Megatron-DeepSpeed 框架功能说明

版本：V4.3.0-BI150 (x86)|V4.3.6-BI150 (ARM)

日期：2025.6.30

适用产品：天垓 150

声明

版权与保密声明

本文档（属未发表作品）版权归属于天数智芯全权所有，且本声明不构成对本文档已发表的承认。本文档所载全部信息均为天数智芯保密信息（包括但不限于天数智芯技术信息、经营信息、专属于接收方的未公开资料等）。未经天数智芯事先书面许可，严禁任何形式的使用、复制、传播、转录或翻译。

免责声明

天数智芯可以随时对本文档或本文档中描述的产品进行改进和/或更改。本文档包括与天数智芯产品有关的信息，作为说明典型应用的一种方式，因此，不一定提供足以进行生产设计的完整信息。对于本文档中内容的准确性或完整性，天数智芯不做任何陈述或保证。

联系方式

地址：上海闵行区陈行公路 2168 号 3 幢

电话：021-68886607

网址：www.iluvatar.com

目录

1	Megatron-DeepSpeed 框架功能说明	4
1.1	修订记录	4
1.2	Megatron-DeepSpeed 框架概览	4
1.3	支持的特性	4
1.4	支持的模型	5

1 Megatron-DeepSpeed 框架功能说明

1.1 修订记录

- CORE01-BI430-RF08-00: 2025/6/30
 - 更新天数智芯适配版 Megatron-DeepSpeed 的版本为 v2.6.0, 当前版本同步适配到天数智芯适配版 Megatron-LM v0.11.0
- CORE01-BI420-RF08-00: 2025/1/24
 - 更新天数智芯适配版 Megatron-DeepSpeed 的版本为 v2.5.0
 - 更新**支持的特性**, 提供当前版本 (v2.5.0) 的特性更新项
- COREX01-BI411-RF08-00: 2024/8/26
 - 更新**支持的模型**
 - 删除“运行训练演示脚本”
- COREX01-BI410-RF08-00: 2024/6/30
 - (V4.1.1-BI150 版本已删除相关小节) “运行训练演示脚本”中推荐用户使用 .whl 包安装天数智芯适配版的 Megatron-DeepSpeed
- COREX01-BI340-RF08-00: 2024/3/25

文档本次发布内容与 V3.3.0-BI150 文档相比 (COREX01-BI330-RF08-00), 有以下更新:

 - 更新天数智芯适配版 Megatron-DeepSpeed 的版本为 v2.4.1
 - 更新**支持的特性**, 提供当前版本 (v2.4.1) 的特性更新项

1.2 Megatron-DeepSpeed 框架概览

天数智算软件栈提供天数智芯适配版的 Megatron-DeepSpeed v2.6.0 深度学习编程框架。

Megatron-DeepSpeed 是一个基于 PyTorch 并面向大规模语言模型的分布式训练框架。Megatron-DeepSpeed 结合了 Megatron-LM 框架与 DeepSpeed 库两者的优势, 将张量并行、数据并行、管道并行与零冗余优化器等功能整合, 实现 3D 并行策略。这使得千亿级参数量以上的大规模语言模型 (如 BLOOM) 的分布式训练变得更加简单和高效。关于 Megatron-DeepSpeed 的详细信息, 请参考 [官方仓库](#)。

1.3 支持的特性

天数智芯适配版的 Megatron-DeepSpeed 深度学习编程框架功能有:

- 支持多种分布式并行策略, 您可以依据自身资源情况组合定制合适的并行策略, 最大化利用算力资源。

Megatron-DeepSpeed 支持的分布式并行策略有:

- 数据并行 (Data Parallelism): 相同的设置和模型被复制多份, 每次每份都被馈送不同的一份数据。处理是并行完成的, 不同份模型在每个训练步结束时同步。

- 张量并行 (Tensor Parallelism): 每个张量都被分成多个块, 因此张量的每个分块都位于其指定的加速卡上, 而不是让整个张量驻留在单张加速卡上。在处理过程中, 每个分块在不同的加速卡上分别并行处理, 结果在步骤结束时同步。
- 管道并行 (Pipe Parallelism): 模型在多个 GPU 上垂直 (即按层) 拆分, 因此只有一个或多个模型层放置在单张加速卡上。每张加速卡并行处理流水线的不同阶段, 并处理 Batch 的一部分数据。
- 零冗余优化器 (ZeRO, Zero Redundancy Optimizer): 执行与张量并行相类似的张量分块, 但整个张量会及时重建以进行前向或反向计算, 因此不需要修改模型。ZeRO 还支持各种卸载技术以补偿有限的 GPU 显存。

- 支持使用 FlashAttention。FlashAttention 的运行速度比 PyTorch 标准注意力快 2-4 倍, 所需内存减少 5-20 倍。

您可以通过启动参数 **--use-flash-attn** 开启 FlashAttention。

- 支持使用 FP16 与 BF16 自动混合精度训练。

您可以通过设置运行脚本对应参数来选择对应参数类型, 详细内容请参考 [官方脚本](#)。

- 相较于天数智芯适配版 Megatron-DeepSpeed v2.5.0, 当前版本有如下更新:

- 同步适配到天数智芯适配版 Megatron-LM v0.11.0
- 天数智芯适配版 Megatron-DeepSpeed 的安装依赖于天数智芯适配版 Megatron-LM

- 相较于天数智芯适配版 Megatron-DeepSpeed v2.4.1, v2.5.0 版本有如下更新:

- 适配 Megatron-LM v0.8.0 版本, 依赖于安装的 Megatron-LM
- DeepSpeed MoE 支持, 通过 **-ds-num-experts** 指定
- 多机 save/load checkpoint 支持
- 存在和 Megatron-LM 的重复特性, 以 Megatron-LM 属性指定, 如自定义重计算 PP Layer

1.4 支持的模型

天数智芯适配版的 Megatron-DeepSpeed 支持的模型如下所示:

- GPT-3 125M
- GPT-3 1.3B
- GPT-3 13B
- GPT-3 30B
- BERT 336M
- BERT 1.3B
- BERT 3.9B
- LLaMA 7B
- LLaMA 13B
- LLaMA2 7B
- LLaMA2 13B
- LLaMA2 70B
- Aquila 7B
- Aquila 34B

本次发布提供 LLaMA2-34B 大模型训练演示脚本, 请向您的应用工程师了解详情。

商标声明

- 天数智芯、天数智芯 logo、Iluvatar CoreX 等商标、标识、组合商标为上海天数智芯半导体有限公司之注册商标或商标，受法律保护。
- CentOS 标识为 Red Hat 公司的商标。
- Docker 为 Docker 公司在美国和其他国家的商标或注册商标。
- Linux 为 Linus Torvalds 在美国和其它国家的注册商标。
- NVIDIA、CUDA、GeForce 和 GeForce GTX 为 NVIDIA 公司在美国和/或其它国家的商标和/或注册商标。
- PyTorch 为 Facebook 公司的商标。
- TensorFlow 为 Google 公司的商标。
- Ubuntu 为 Canonical 公司的注册商标。

除上述明确列出的商标外，本内容中可能存在的任何其他未明示的产品名称、服务名称、企业名称、标识、口号、域名或其他商业标记 (无论是否标注 ™ 或 ® 符号)，均假定归属于其各自合法的商标权人所有。