



天数智芯
Iluvatar CoreX

天数智芯

Megatron-LM 框架功能说明

版本：V4.3.0-BI150 (x86)|V4.3.6-BI150 (ARM)

日期：2025.6.30

适用产品：天垓 150

声明

版权与保密声明

本文档（属未发表作品）版权归属于天数智芯全权所有，且本声明不构成对本文档已发表的承认。本文档所载全部信息均为天数智芯保密信息（包括但不限于天数智芯技术信息、经营信息、专属于接收方的未公开资料等）。未经天数智芯事先书面许可，严禁任何形式的使用、复制、传播、转录或翻译。

免责声明

天数智芯可以随时对本文档或本文档中描述的产品进行改进和/或更改。本文档包括与天数智芯产品有关的信息，作为说明典型应用的一种方式，因此，不一定提供足以进行生产设计的完整信息。对于本文档中内容的准确性或完整性，天数智芯不做任何陈述或保证。

联系方式

地址：上海闵行区陈行公路 2168 号 3 幢

电话：021-68886607

网址：www.iluvatar.com

目录

1 Megatron-LM 框架功能说明	4
1.1 修订记录	4
1.2 Megatron-LM 框架概览	5
1.3 支持的特性	6
1.3.1 Tensor Parallelism and Overlap	6
1.3.2 Pipeline Parallelism and Overlap	7
1.3.3 非均衡放置	8
1.3.4 Sequence Parallelism	8
1.3.5 Activation Checkpointing and Recomputation	9
1.3.6 FlashAttention	9
1.3.7 异构混合训练	9
1.3.8 Zero Bubble 流水线并行	9
1.3.9 MoE 模型支持	9
1.3.10 MTP 技术支持	10
1.3.11 Finetune 支持	10
1.3.12 其它优化技术	10
1.3.13 新增参数说明	10
1.4 支持的运行模式	13
1.4.1 Legacy+Local	13
1.4.2 Legacy+TE	13
1.4.3 MCore+Local	13
1.4.4 MCore+TE	13
1.5 支持的加速库	13
1.5.1 ix-TransformerEngine	13
1.5.1.1 版本更新	14
1.5.1.2 支持的 API	14
1.5.1.3 开启 Overlap 环境配置	16
1.5.1.4 设置优化参数方式	17
1.5.1.5 优化参数说明	17
1.6 支持的模型	20

1 Megatron-LM 框架功能说明

1.1 修订记录

- COREX01-BI430-RF09-00: 2025/6/30
 - 更新天数智芯适配版 Megatron-LM 的版本为 v0.11.0
 - 新增以下特性支持：
 - * MoE 模型支持
 - * MTP 技术支持
 - * Finetune 支持
 - 新增参数说明 表格新增：
 - * --lora-rank
 - * --lora-alpha
 - * --lora-dropout
 - * --lora-targets
 - 更新 ixTE 的版本为 v1.1.0, 更新以下内容：
 - * 更新支持的 API：
 - 更新 API 列表
 - transformer_engine.pytorch.moe.FusedMoEMLP API 新增 padded_input 参数
 - 删除 transformer_engine.pytorch.moe.CommonTokenDispatcher 和 transformer_engine.pytorch.moe.TPOverlapedTokenDispatcher API, Megatron-LM 已实现类似功能
 - * TP Overlap 优化参数：
 - 新增 tp_use_direct 参数
 - 更新 tp_prim_p2p_level 参数相关信息
 - * CP Overlap 优化参数：
 - 新增 cp_use_direct 参数
 - 更新 cp_prim_p2p_level 参数相关信息
 - * MoE 优化参数, 新增 moe_grouped_gemm_stream_num 参数
 - * 其它参数, 新增 attention_use_memory_efficient 和 enable_zero_bubble 参数
 - * 提供 IXCLL_USE_DIRECT 和 IXCLL_PRIM_P2P_LEVEL 环境变量说明
- COREX01-BI420-RF09-00: 2025/1/24
 - 更新天数智芯适配版 Megatron-LM 的版本为 v0.8.0
 - 新增 DP 维度上的混合训练
 - 新增Zero Bubble 流水线并行 特性
 - 新增参数说明 表格：
 - * 新增“优化技术”列
 - * 新增部分参数
 - 更新 ixTE 的版本为 v0.2.4, 更新以下内容：
 - * 更新支持的 API, 新增以下 API：
 - transformer_engine.pytorch.moe.FusedMoEMLP

- transformer_engine.pytorch.moe.CommonTokenDispatcher
- transformer_engine.pytorch.moe.TPOverlapedTokenDispatcher
- * 新增开启 Overlap 环境配置
- * 新增设置优化参数方式
- * 新增CP Overlap 优化参数, MoE 优化参数, 其它参数
- * 新增部分TP Overlap 和内存优化 参数
- COREX01-BI411-RF09-00: 2024/8/26
 - 新增异构混合训练
 - 新增参数说明 新增 --parallel-group-num 和 --parallel-group 参数
 - 更新支持的模型
 - 删除“运行训练演示脚本”
- COREX01-BI410-RF09-00: 2024/6/30

文档本次发布内容与 V3.4.0-BI150 文档相比 (COREX01-BI340-RF09-00), 有以下更新:

- 更新天数智芯适配版 Megatron-LM 的版本为 v0.6.0
- 更新以下内容:
 - * Tensor Parallelism and Overlap
 - * Pipeline Parallelism and Overlap
 - * Sequence Parallelism
- 新增以下内容:
 - * 非均衡放置
 - * 新增参数说明
 - * 支持的运行模式
 - * ix-TransformerEngine 加速库
- 更新支持的模型, 提供调优配置相关代码示例

1.2 Megatron-LM 框架概览

天数智算软件栈提供天数智芯适配版的 Megatron-LM v0.11.0 大语言模型训练框架。

Megatron-LM 框架是一款开源大语言模型 (LLM) 训练框架, 包含主框架 Megatron-LM 和 Megatron-Core。Megatron-Core 将 Megatron 中 LLM 训练中的 GPU 加速技术抽象为一个模块化的 API 库, 可以给开发者和研究院提供更多的灵活性, 可以更容易地加速大模型的训练过程。

Megatron 提出了一系列技术来优化 LLM 训练, 包括张量并行 (Tensor Parallelism)、流水线并行 (Pipeline Parallelism)、序列并行 (Sequence Parallelism)、激活值选择性保存和重计算 (Activation Checkpointing and Recomputation) 等, 详情请参考 [论文 1](#)、[论文 2](#) 和 [论文 3](#)。天数智芯也对这些技术进行了适配和优化, 以便用户进行大语言模型的训练。

更多功能介绍和技术细节, 请参考 [Megatron-LM 官方文档](#)。


本次发布适配的 Megatron-LM 版本是 Core v0.11.0, 包括 Megatron-LM 和 Megatron-Core。

1.3 支持的特性


天数智芯适配版 Megatron-LM 支持该框架的原生功能，并在天数智芯加速卡上对以下功能做了针对性的优化，使得 Megatron-LM 在天数智芯加速卡上达到最佳性能。

1.3.1 Tensor Parallelism and Overlap

天数智芯适配版 Megatron-LM 支持原生的张量并行模式，并针对 Tensor Parallelism (TP) Communication Overlap 做了适配硬件的优化。TP Overlap 相关的参数配置，请参考[TP Overlap](#) 优化参数说明。



(a) MLP



(b) Self-Attention

图 1: Megatron Tensor Parallelism 说明图 (来自 Megatron 论文)

1.3.2 Pipeline Parallelism and Overlap

天数智芯适配版 Megatron-LM 支持 Megatron 原生的流水线并行模式，支持开启 Virtual Pipeline 的 Interleaved 1F1B 模式。




Figure 4: Default and interleaved 1F1B pipeline schedules. The top figure shows the default non-interleaved 1F1B schedule. The bottom figure shows the interleaved 1F1B schedule, where each device is assigned multiple chunks (in this case, 2). Dark colors show the first chunk and light colors show the second chunk. The size of the pipeline bubble is smaller (the pipeline flush happens sooner in the interleaved timeline).

图 2: Megatron Interleaved 1F1B 说明图 (来自 Megatron 论文)

在 Interleaved 1F1B 模式下，支持 Pipeline Parallelism (PP) Overlap，默认开启。

1.3.3 非均衡放置

在默认的均衡放置模式下，由于 Recomputation 和 Embedding, Vocab Gemm 的存在，以及 Layer/PP 无法整除，会导致不同 Stage Memory 占用和算力占用不均衡，从而出现 Pipeline 的 Bubble。因此，针对这些场景，天数智芯提供了非均衡放置模式，通过[新增参数说明](#)，可以了解支持更精细的控制不同 Stage 的 Layer 数量。

1.3.4 Sequence Parallelism

天数智芯适配版 Megatron-LM 支持原生的 Sequence Parallelism (SP)，并对其做了优化。




图 3: Megatron Tensor Parallelism 和 Sequence Parallelism 并行说明图 (来自 Megatron 论文)

更详细的 SP ON 可选优化参数配置，请参考[优化参数说明](#)。

1.3.5 Activation Checkpointing and Recomputation

Megatron-LM 中的重计算策略可以减少内存的使用量，用计算换取内存，可以带来更多的调优空间。天数智算软件栈也针对这项技术进行了适配和优化。

首先，天数智芯适配版 Megatron-LM 支持原生的重计算技术，并做了更精细的参数控制，以单独设置每个 stage 的重计算策略。同时，天数智芯适配版 Megatron-LM 减少了部分场景的重计算，例如 Dropout=0 和 linear-bias=False 场景下，每个 stage 最后一个 MLP-Gemm2 和后面的 Tensor Parallelism 通信，在 Recomputation 时可以省略，天数智算软件栈删减了这部分计算和通信。

1.3.6 FlashAttention

天数智算软件栈实现了 FlashAttention 算法，并适配了 [FlashAttention 库](#)。天数智芯适配版 Megatron-LM 也对接了天数智芯适配版 FlashAttention 库来优化 Attention 模块的执行效率和内存占用，详情请参考《PyTorch 框架功能说明》中对 FlashAttention 的说明。

1.3.7 异构混合训练

天数智芯实现了与 NVIDIA 设备在 Megatron-LM 上进行异构混合训练的功能。

当前异构混合训练可以支持基于 Pipeline Parallelism (PP) 的混合，以及基于 Tensor Parallelism (TP) 的混合。PP 混合即异构的设备分别放置不同的 stage，TP 混合即异构设备上 stage 的 TP 可以不同。

PP 混合使用[非均衡放置](#)的方法来平衡天数智芯设备和 NVIDIA 设备在计算时间上的差距，TP 混合使用新增的参数(参考[新增参数说明](#))来控制天数智芯设备和 NVIDIA 设备使用不同的 TP 来平衡计算时间或者是显存使用的差距。您可以通过组合使用这两种混合方式来达到最佳的混合训练效率。

在天数智芯适配版 Megatron-LM v0.8.0 中，新增支持了 DP 维度上的混合训练。

1.3.8 Zero Bubble 流水线并行

天数智芯适配版 Megatron-LM v0.8.0 版本新增 [Zero Bubble Pipeline Parallelism](#) 调度方式，可以实现在部分模型中的性能提升。

Zero Bubble Pipeline Parallelism，即 Zero Bubble 流水线并行，通过分离反向计算中的 dx 和 dw，减少了流水线并行中的气泡，从而达到提升整体训练效率的目的，在 GBS 受限的部分场景，性能会有较大提升。

1.3.9 MoE 模型支持

开源版 Megatron-LM 在 v0.11 版本中支持了 DeepSeekV3 等 MoE 模型的训练，天数智芯也对此进行了适配和优化，主要包括支持：

- Aux-loss-free 负载均衡、Node-limited routing、MoE Parallel Folding 等新特性
- 专家并行的切分策略
- MoE Parallel Folding 支持 Dense Module 和 MoE Module 采用不同的并行策略

更新特性支持列表详情，请参考 [MoE 特性介绍官方文档](#)。

1.3.10 MTP 技术支持

开源版 Megatron-LM 在 v0.11 版本中支持了 DeepSeekV3 等模型的训练，天数智芯适配版 Megatron-LM 在当前版本中加入了 MTP (Multi-Token Prediction) 的支持。

1.3.11 Finetune 支持

天数智芯适配版 Megatron-LM 支持了 SFT 和 LoRA 类型的模型微调，请参考[新增参数说明](#)中 Finetune 和 LoRA 相关的参数说明使用。

1.3.12 其它优化技术

天数智芯适配版 Megatron-LM 的其它优化技术，如数据并行 (Data Parallelism) 和分布式优化器 (Distributed Optimizer)，也能很好地工作，详情请参考 [Megatron-LM 官方文档](#)。

1.3.13 新增参数说明

以下为天数智芯为了更好更方便地进行大模型训练而新增的参数，您可以按需设置。

表 1: 新增参数说明

参数名	类型	默认值	优化技术	说明
--position-embedding-type	str	learned-absolute	通用	新增 alibi 模式
--recompute-method-per-stage	nargs	None	通用	单独设置每个 stage 的重计算策略，覆盖 --recompute-method ；两两一组，按照 n0, method0, n1, method1 设置，0：uniform, 1：block；更多参数约束，请参考 Megatron argument 说明
--recompute-num-layers-per-stage	narg	None	通用	单独设置每个 stage 的重计算层数，覆盖 --recompute-num-layers ；两两一组，按照 n0, num_layer0, n1, num_layer1 设置
--num-layers-per-stage	nargs	None	通用	单独设置每个 stage 的层数，非均衡放置；两两一组，按照 n0, num_layer0, n1, num_layer1 设置
--ixte-cfg	str	None	通用	ixTE 优化参数配置文件，格式为 yaml，可配置参数和优化选项，请参考 优化参数说明
--no-data-cache-local	bool	False	通用	Megatron-LM 默认 Datasets caching 是生成在共享存储中的，而实际运行环中大部分是非共享存储。因此，修改逻辑为每个节点都单独生成 datache，如想采用原生逻辑，设置 --no-data-cache-local

表 1: 新增参数说明

--two-stage-p2p	bool	False	通用	在不开启 SP 的场景下，是否在 PP 通信中采用 P2P+allgather 的方式
--disable-logging	bool	False	通用	关闭部分场景的 logging 显示，减少 D2H 次数，可以提升些许性能
--moe-block-sparse-gemm	bool	False	MoE	Replace grouped gemm with block-sparse gemm
--parallel-group-num	int	None	异构混训	设置不同 TP 组的数量，用于异构混合训练，目前仅支持 2 组不同的 TP 组，且不支持 untie-embeddings-and-output-weights, Context Parallel, Virtual Pipeline Parallel 和 Expert Parallel
--parallel-group	narg	None	异构混训	单独设置不同 TP 组的 3D 并行配置，设置的顺序分别是 TP, DP, PP，用于异构混合训练。假设 --parallel-group-num 中设置了 N 组，则会有 N 组 TP, DP, PP 的组合。其中，每个 3D 并行组的 TP 可以不同，但 DP 必须相同，并且所有 3D 并行组的 PP 总和须等于 --pipeline-model-parallel-size 设置的值。最后这 N 组合经过组合内相乘和组合间相加需等于 world_size
--micro-batch-size-per-dp	nargs	None	异构混训	单独设置每个 DP 并行组的 num micro batches。两两一组，按照 dp0, nmb0, dp1, nmb1, ... 的格式进行设置。使用该参数时，必须与 --use-tp-pp-dp-mapping 和 --micro-batch-size-per-dp 一起使用。最后需要保证 $dp0 * mbs0 * nmb0 + dp1 * mbs1 * nmb1 + \dots = \text{global batch size}$ 且 $dp0 + dp1 + \dots = \text{data parallel size}$
--num-micro-batches-per-dp	narg	None	异构混训	单独设置每个 DP 并行组的 num miro batches。两两一组，按照 dp0, nmb0, dp1, nmb1, ... 的格式进行设置。使用该参数时，必须与 --use-tp-pp-dp-mapping 和 --micro-batch-size-per-dp 一起使用。最后需要保证 $dp0 * mbs0 * nmb0 + dp1 * mbs1 * nmb1 + \dots = \text{global batch size}$ 且 $dp0 + dp1 + \dots = \text{data parallel size}$
--variable-seq-lengths	bool	False	Finetune	是否用 Megatron 进行 Finetune 训练，采用可变长度数据
packing	bool	False	Finetune	Finetune 训练时是否将数据集 pack 到相同长度
--zero-bubble-pipeline-timers-start-iter	int	100	Zero Bubble	指定 zero bubble profiling 的起始 step。zero bubble 会根据 profiling 得到的 F/B/W 耗时结果对 schedule node 进行动态重排序
--zero-bubble-pipeline-timers-end-ite	int	100	Zero Bubble	指定 zero bubble profiling 的结束 step

表 1: 新增参数说明

--zero-bubble-max-pending-backward	str	auto	Zero Bubble	指定 zero bubble schedule 中最大同时缓存的前向 activation 数量，仅对非 v schedule 生效。设置为 PP，PP*2 则分别对应原始论文中的 zb1p，zb2p 结构。设置为 auto 则会根据 --zero-bubble-adaptive-memory-limit-percentile 来调整缓存的前向 activation 数量
--zero-bubble-adaptive-memory-limit-percentile	int	85	Zero Bubble	当 --zero-bubble-max-pending-backward 被设置为 auto 时，限制 schedule 最大使用的显存量为总显存的该百分比值
--enable-optimizer-post-validation	bool	False	Zero Bubble	通过将 step 结尾的 optimizer 更新过程拆分到下一 step 的前向过程中来消除 step 结尾的同步操作，从而减少非 steady 阶段的 pp bubble。生效与否受设置的 clip_grad 值影响，为保证训练精度仅在累计 10 steps 未触发 clip_grad 后才会开启
--enable-exactly-numeric-match	bool	False	Zero Bubble	开启后会在 optimizer post validation 阶段使用更为精确的比对方式，可能会导致显存占用上升
--enable-zero-bubble	bool	False	Zero Bubble	开启常规 zero bubble pipeline schedule
--zero-bubble-v-schedule	bool	False	Zero Bubble	使用 zero bubble v pipeline schedule 来替换常规的 zero bubble pipeline schedule
--allow-padding-num-layers	bool	False	Zero Bubble	当 layer 数量无法被 pp stage 整除即各 stage 上 layer 数不一致时 (主要针对 v schedule)，可以通过开启该参数假设 stage 上 layer 数一致，再决定哪个 stage 上分配较少的 layer。在 v0.8.0 版本后已支持 v schedule 手动放置非平衡 layer，逻辑上与该参数互斥
--lora-rank	int	0	Lora Fine-tune	设置 LoRA 微调的固定维度
--lora-alpha	float	0	Lora Fine-tune	设置 LoRA 微调的 Scaling Factor
--lora-dropout	float	0	Lora Fine-tune	设置 LoRA 微调的 Dropout Rate

表 1: 新增参数说明

--lora-targets	nargs=None	Lora Fine-tune	设置 LoRA 微调的 layer name (不需要完整的 layer name, 例如, "linear_qkv, linear_proj, linear_fc1"), layer name 使用"," 间隔, 仅支持 linear layer
----------------	------------	----------------	--

1.4 支持的运行模式

天数智芯适配版 Megatron-LM 目前支持以下 4 种运行模式。

Legacy/MCore: Legacy 模式是 Megatron-LM 原始支持的运行模式, 需要依赖 Megatron-LM 的外层代码; MCore (Megatron Core) 模式, 仅依赖 Megatron-Core 相关的代码, 方便其它大模型框架集成 Megatron 的核心逻辑。

Local/TE: Local 模式是使用 Megatron-LM 框架自带的 Transformer Layer 实现; TE 为依赖 TransformerEngine (Corex 对应的适配框架为 ix-TransformerEngine, 简称 ixTE) 运行的实现, 包含 TE 针对大模型的优化。

1.4.1 Legacy+Local

Megatron-LM 原生逻辑, 模型支持范围更大。

1.4.2 Legacy+TE

包含非均衡放置、自定义重计算, TP Overlap, PP Overlap 等优化。

1.4.3 MCore+Local

Megatron Core 原生逻辑, 模型支持范围更大。

1.4.4 MCore+TE

包含 TP Overlap, PP Overlap 等优化, 未包含非均衡放置、自定义重计算等优化策略, 部分融合算子未加入。

1.5 支持的加速库

1.5.1 ix-TransformerEngine

天数智算软件栈提供适配 Transformer Engine 的大模型训练加速库 ix-TransformerEngine (ixTE), 当前发布的版本为 v1.1.0。ixTE 提供了一系列优化的大模型构建模块, 通过这些模块可以很方便地构建出各种目前主流

的大模型架构。同时，ixTE 优化了张量并行 (TP)、模型并行 (PP)、序列并行 (CP) 中的计算与通信 Overlap，让大模型训练可以在天数智芯硬件上达到最有效果。

1.5.1.1 版本更新

- v1.1.0

当前版本为 ixTE v1.1.0，适配 [NV-TransformerEngine v2.1.0](#)。

同样新增 MoE 相关接口支持，优化算子和模型性能，增加了部分配置项以提供更高的灵活性。

- v0.2.4

ixTE v0.2.4 新增 MoE 相关接口支持，优化算子和模型性能，增加了部分配置项以提供更高的灵活性。

1.5.1.2 支持的 API

天数智算软件栈支持以下 TransformerEngine API (您可以参考 [官方文档](#) 了解这些 API 的使用详情):

```
transformer_engine.common.recipe.DelayedScaling
transformer_engine.common.recipe.Format
transformer_engine.common.recipe.MXFP8BlockScaling
transformer_engine.pytorch.checkpoint
transformer_engine.pytorch.CudaRNGStatesTracker
transformer_engine.pytorch.DotProductAttention
transformer_engine.pytorch.fp8_autocast
transformer_engine.pytorch.fp8_model_init
transformer_engine.pytorch.get_cpu_offload_context
transformer_engine.pytorch.GroupedLinear
transformer_engine.pytorch.InferenceParams
transformer_engine.pytorch.LayerNorm
transformer_engine.pytorch.LayerNormLinear
transformer_engine.pytorch.LayerNormMLP
transformer_engine.pytorch.Linear
transformer_engine.pytorch.make_graphed_callables
transformer_engine.pytorch.moe_permute
transformer_engine.pytorch.moe_permute_with_probs
transformer_engine.pytorch.moe_sort_chunks_by_index
transformer_engine.pytorch.moe_sort_chunks_by_index_with_probs
transformer_engine.pytorch.moe_unpermute
transformer_engine.pytorch.MultiheadAttention
transformer_engine.pytorch.RMSNorm
transformer_engine.pytorch.TransformerLayer
```

以下是 ixTE 支持的 API，主要用于优化算子和配置 Overlap 选项。不调用这些参数，上述 API 的功能也可以正常使用。

如果您需要在天数智芯硬件平台上调优训练效果，可以通过 **以下 API** 对模型进行优化。

transformer_engine.common.initialize_ixte

功能描述

设置 ixTE 专用的优化参数的 API。

函数签名

```
def initialize_ixte(use_fp8: bool = False, opt_cfgs: Optional[dict] = None) -> None
```

参数说明

- use_fp8: bool 类型, 是否使用 fp8, 暂不起作用
- opt_cfgs: dict 类型, Key-Value 类型的 ixte 的优化参数, 可配置的参数列表和含义请参考[优化参数说明](#)

transformer_engine.pytorch.vocab_parallel_cross_entropy

功能描述

ixTE 融合优化的 vocab cross entropy 函数。

函数签名

```
def vocab_parallel_cross_entropy(vocab_parallel_logits,
                                target, label_smoothing=0.0,
                                world_size=1,
                                vocab_start_index=0,
                                vocab_end_index=320000,
                                group=None)
```

参数说明

- vocab_parallel_logits: torch.tensor 类型, vocab 输入 logit tensor
- target: torch.tensor 类型, logit tensor 对应的 label
- label_smoothing: float 类型, 如果为 0.0, 表示不开启 label smoothing
- world_size: int 类型, TP group 的大小
- vocab_start_index: int 类型, 当前 TP rank 的 vocab 起始 index
- vocab_end_index: int 类型, 当前 TP rank 的 vocab 结束 index
- group: ProcessGroup 类型, TP group

transformer_engine.pytorch.moe.FusedMoEMLP

功能描述

ixTE 实现的优化融合版本的 MoE Layer。

init 函数签名

```
def __init__(
    self,
    hidden_size: int,
    ffn_hidden_size: int,
    num_local_experts: int,
    sequence_parallel: bool = True,
    expert_parallel: bool = False,
    get_rng_state_tracker: Optional[Callable] = None,
    tp_group: Optional[dist_group_type] = None,
```

```
tp_size: int = 1,
init_method: Optional[Callable] = None,
activation: str = "gelu",
fuse_wgrad_accumulation: bool = True,
params_dtype: Optional[torch.dtype] = None,
gemm_type: str = "sparse",
device: Union[torch.device, str] = "cuda",
padded_input: bool = False,
) -> None:
```

参数说明

- hidden_size: int 类型, 隐含层 size
- ffn_hidden_size: int 类型, feedforward 层 size
- num_local_experts: int 类型, 本地专家数量
- sequence_parallel: bool 类型, 是否开启 SP
- expert_parallel: bool 类型, 是否开启专家并行
- get_rng_state_tracker: Callable 类型, 保证随机一致性
- tp_group: dist_group_type, TP 通信组
- tp_size: int 类型, TP size
- init_method: Callable 类型, 参数初始化方法
- activation: str 类型, 激活函数, gelu、silu 等
- fuse_wgrad_accumulation: bool 类型, 是否梯度累加融合
- params_dtype: torch.dtype 类型, 参数数据类型
- gemm_type: str 类型, MoE gemm 模式, 支持以下几种:
 - sparse
 - group
 - sequential
- device: str 类型, 运行设备
- padded_input: bool 类型, input 是否为每个 expert token num pad 到整数倍, 目前仅支持 256 和 128

1.5.1.3 开启 Overlap 环境配置

TP Overlap 依赖 Driver KMD 开启多 ring, 同时需要将固件刷为最新版本, 参考步骤如下:

```
# Driver KMD 开启多 ring
$ insmod iluvatar.ko itr_multi_compute_engine=1

# 查看 Driver 是否自动刷新了固件
$ ixdriver/build/bin/ixdebugger 0 dr 1f380
0x0001f380: 0x00007eee # 如果寄存器返回 7eee, 表示刷新固件成功
```

固件刷新失败的处理方法

如果加载 KMD 时 dmesg 打印如下 (示例), 表示固件刷新失败:

```
[ +0.129065] iluvatar 0000:26:00.0: DEV-5 is okay.
[ +0.001104] iluvatar 0000:30:00.0: Direct firmware load for iluvatar_cp.bin failed with error -2
[ +0.000004] iluvatar 0000:30:00.0: Failed to open firmware : iluvatar_cp.bin (-2)
[ +0.131060] iluvatar 0000:30:00.0: DEV-6 is okay.
[ +0.000718] iluvatar 0000:33:00.0: Direct firmware load for iluvatar_cp.bin failed with error -2
[ +0.000004] iluvatar 0000:33:00.0: Failed to open firmware : iluvatar_cp.bin (-2)
[ +0.131332] iluvatar 0000:33:00.0: DEV-7 is okay.
[ +0.000725] iluvatar 0000:39:00.0: Direct firmware load for iluvatar_cp.bin failed with error -2
[ +0.000004] iluvatar 0000:39:00.0: Failed to open firmware : iluvatar_cp.bin (-2)
[ +0.132599] iluvatar 0000:39:00.0: DEV-8 is okay.
[ +0.000777] iluvatar 0000:3c:00.0: Direct firmware load for iluvatar_cp.bin failed with error -2
[ +0.000006] iluvatar 0000:3c:00.0: Failed to open firmware : iluvatar_cp.bin (-2)
[ +0.130758] iluvatar 0000:3c:00.0: DEV-9 is okay.
[ +0.001068] iluvatar 0000:44:00.0: Direct firmware load for iluvatar_cp.bin failed with error -2
[ +0.000005] iluvatar 0000:44:00.0: Failed to open firmware : iluvatar_cp.bin (-2)
[ +0.131465] iluvatar 0000:44:00.0: DEV-10 is okay.
[ +0.001043] iluvatar 0000:47:00.0: Direct firmware load for iluvatar_cp.bin failed with error -2
[ +0.000005] iluvatar 0000:47:00.0: Failed to open firmware : iluvatar_cp.bin (-2)
[ +0.130940] iluvatar 0000:47:00.0: DEV-11 is okay.
[ +0.001042] iluvatar 0000:50:00.0: Direct firmware load for iluvatar_cp.bin failed with error -2
[ +0.000004] iluvatar 0000:50:00.0: Failed to open firmware : iluvatar_cp.bin (-2)
[ +0.132537] iluvatar 0000:50:00.0: DEV-12 is okay.
```

图 4: 固件刷新失败

如果在容器内加载的 KMD，固件未刷新成功的可能原因是：未在主机上找到 bin 文件。解决方法如下：

1. 挂载 /lib/firmware/ 目录到容器内；
2. 手动拷贝容器内的 /lib/firmware/iluvatar_cp.bin 文件到主机对应位置；
3. 再次通过 `ixdriver/build/bin/ixdebugger 0 dr 1f380` 命令检查寄存器状态查看固件是否刷新成功。如果寄存器返回 7eee，表示刷新固件成功。

1.5.1.4 设置优化参数方式

方式 1: 通过 API

您可以通过调用 `transformer_engine.common.initialize_ixte` API 来设置 ixTE 的优化参数。

方式 2: 通过 Yaml 文件

您也可以通过在 Megatron-LM 中传入 Yaml 文件进行 ixTE 优化参数的设置。请联系您的应用工程师获取 `ixte_opt.yml` 文件。

Note

该文件中的参数值均为默认值，请根据您的实际情况进行设置。

1.5.1.5 优化参数说明

在 `initialize_ixte` 接口中可配置的优化项及其说明如下。

1.5.1.5.1 TP Overlap

TP Overlap 相关的参数设置和说明如下。

- `tp_overlap_mode`: int 类型, 默认值为 0
 - 0 表示不开启 TP Overlap
 - 1 表示 TP Overlap 实现方案一, 即阶跃项目的实现方案, 需要手动设置 TP 切分参数
 - 2 表示 TP Overlap 实现方案二, 理论上该方案通信和计算可以做到完全 Overlap
 - TP2 情况下, 方案二比方案一效果好, TP4+130B shape 方案二和方案一效果相差不大。不同场景下可以切换方案并进行对比
- `mlp_g1_overlap_size`: int 类型, 默认值为 1。当 `tp_overlap_mode=1` 时需要设置的参数, mlp 第一个 gemm TP Overlap tensor 切分的参数, 一般设置为 4、2
- `mlp_g2_overlap_size`: int 类型, 默认值为 1。当 `tp_overlap_mode=1` 时需要设置的参数, mlp 第二个 gemm TP Overlap tensor 切分的参数, 一般设置为 4、2
- `attn_g1_overlap_size`: int 类型, 默认值为 1。当 `tp_overlap_mode=1` 时需要设置的参数, attn 第一个 gemm TP Overlap tensor 切分的参数, 一般设置为 4、2
- `attn_g2_overlap_size`: int 类型, 默认值为 1。当 `tp_overlap_mode=1` 时需要设置的参数, attn 第二个 gemm TP Overlap tensor 切分的参数, 一般设置为 4、2
- `tp_overlap_sync_with_event`: bool 类型, 默认值为 True。当 `tp_overlap_mode=2` 时可以设置此参数, 表示计算和通信 Overlap 时是否通过 CudaEvent 来同步
- `use_gemm_overlap_rs_v2`: bool 类型, 默认值为 True。v2 通过 ring 通信的方式将 gemm 和 reduce scatter 进行 overlap, 会增加一次 Add 计算, 但是按 ring 方式通信效率更高, 一般场景下 V2 效果更好
- `tp_use_direct`: bool 类型, 默认值为 False。表示使用 directCopy 优化, 同 `IXCCL_USE_DIRECT` 环境变量的作用
`IXCCL_USE_DIRECT` 环境变量: 默认值为 0, 表示使用 directCopy 优化 (存在 maskrcnn 遗留问题时, 默认关闭)
- `tp_prim_p2p_level`: int 类型, 默认值为 0, 同 `IXCCL_PRIM_P2P_LEVEL` 环境变量的作用
`IXCCL_PRIM_P2P_LEVEL` 环境变量: 默认值为 0, 表示控制 p2p engine (CU/dma)
 - 0: 表示使用 kernel mode, 即所有 p2p 传输都通过 CU
 - 1: 表示使用 dma mode, 即所有 p2p 传输都通过 dma engine
 - 2: 使用 mixed mode, 按照操作类型亲和度动态使用上述两种模式

1.5.1.5.2 内存优化

内存优化配置大部分是空间换时间的优化策略, 相关参数设置和说明如下。

- `mlp_g1_save_total_input_for_backward`: bool 类型, 默认值为 False
 - 当 `Sequence Parallelism=True` 时有效
 - 是否保留前向 allgather 的完整结果, 减少一次反向的 allgather 通信, 会占用更多的 GPU Memory, 用空间换时间
 - mlp 第一个 gemm 是否开启此策略
- `attn_g1_save_total_input_for_backward`: bool 类型, 默认值为 False。attn 第一个 gemm 是否开启此策略, 说明同上
- `logits_gemm_save_total_input_for_backward`: bool 类型, 默认值为 False。整个模型最后的 logit gemm 是否开启此策略, 说明同上

- `save_total_input_for_backward`: bool 类型, 默认值为 False。用于统一控制上述三个变量, 设置为 True, 表示上述三个选项都为 True; 设为 False, 表示每个选项单独控制
- `attention_use_memory_efficient`: bool 类型, 默认值为 True。FlashAttention Impl Model, 设置为 True 表示占用更少内存, 性能可能会降低

1.5.1.5.3 CP Overlap

CP overlap 相关的参数设置, 相关参数设置和说明如下。

- `cp_overlap_sync_with_event`: bool 类型, 默认值为 False。表示计算和通信 Overlap 时是否通过 CudaEvent 来同步

最新的多 Ring KMD 支持了 Event 同步, 如果使用过程中发现存在精度问题, 可以尝试关闭此选项

- `cp_use_direct`: bool 类型, 默认值为 False。表示使用 directCopy 优化, 同 `IXCCL_USE_DIRECT` 环境变量的作用
- `cp_prim_p2p_level`: int 类型, 默认值为 0, 同 `IXCCL_PRIM_P2P_LEVEL` 环境变量的作用
 - 0: 表示使用 kernel mode, 即所有 p2p 传输都通过 CU
 - 1: 表示使用 dma mode, 即所有 p2p 传输都通过 dma engine
 - 2: 表示使用 mixed mode, 按照操作类型亲和度动态使用上述两种模式

1.5.1.5.4 MoE

MoE 相关的参数设置, 相关参数设置和说明如下。

- `moe_token_dispatcher_pad_num`: int 类型, 默认值为 0。表示是否在 token dispatcher 中对每个 expert 的 token num 做 paddle
设置合适的数值可以提升 experts 部分的性能, 但会占用更多内存。0 表示不做 pad
- `moe_tp_overlap_mode`: int 类型, 默认值为 0
 - 0: 不开启 MoE Layer 的 TP Overlap
 - 1: Overlap MoE token dispatcher 的计算和通信
- `moe_mlp_save_g1_for_backward`: bool 类型, 默认值为 True。表示是否保存 mlp 的中间结果, 开启该选项可减少一次 gemm 计算。默认开启该选项
- `moe_grouped_gemm_stream_num`: int 类型, 默认值为 4。表示指定多 stream GroupGemm 实现中 stream 的数量

1.5.1.5.5 其它参数

- `grad_norm_use_tree`: bool 类型, 默认值为 False。表示设置 GradNorm 的通信是否采用 Tree 算法
多机场景进行 grad_norm 的 allreduce ring 算法性能较差, 强制设置为 Tree 算法
- `deterministic_algo`: bool 类型, 默认值为 False。表示设置 ixTE 中某些随机算法是否使用确定性实现
在 debug 一些问题时开启该选项可以排除随机性的影响, 但可能会带来性能损失

- `attention_use_memory_efficient`: bool 类型, 默认值为 True。表示 Attention 计算是否使用显存节省模式
- `enable_zero_bubble`: bool 类型, 默认值为 False。表示是否开启 Zero Bubble 优化, 需要与 Megatron-LM 同步设置

1.6 支持的模型

天数智芯适配版的 Megatron-LM 支持的模型如下所示:

- LLaMA2-7B
- LLaMA2-13B
- LLaMA2-34B
- LLaMA2-70B
- LLaMA2-130B
- Mixtral-8*7B
- GPT3-5B
- GPT20-20B
- Qwen

本次发布提供 LLaMA2-34B 和 LLaMA2-70B 大模型训练演示脚本, 请向您的应用工程师了解详情。

商标声明

- 天数智芯、天数智芯 logo、Iluvatar CoreX 等商标、标识、组合商标为上海天数智芯半导体有限公司之注册商标或商标，受法律保护。
- CentOS 标识为 Red Hat 公司的商标。
- Docker 为 Docker 公司在美国和其他国家的商标或注册商标。
- Linux 为 Linus Torvalds 在美国和其它国家的注册商标。
- NVIDIA、CUDA、GeForce 和 GeForce GTX 为 NVIDIA 公司在美国和/或其它国家的商标和/或注册商标。
- PyTorch 为 Facebook 公司的商标。
- TensorFlow 为 Google 公司的商标。
- Ubuntu 为 Canonical 公司的注册商标。

除上述明确列出的商标外，本内容中可能存在的任何其他未明示的产品名称、服务名称、企业名称、标识、口号、域名或其他商业标记 (无论是否标注 ™ 或 ® 符号)，均假定归属于其各自合法的商标权人所有。