



天数智芯
Iluvatar CoreX

天数智芯

ONNXRuntime 框架功能说明

版本：V4.3.0 (x86)|V4.3.6 (ARM)

日期：2025.6.30

适用产品：天垓 150| 智铠系列

声明

版权与保密声明

本文档（属未发表作品）版权归属于天数智芯全权所有，且本声明不构成对本文档已发表的承认。本文档所载全部信息均为天数智芯保密信息（包括但不限于天数智芯技术信息、经营信息、专属于接收方的未公开资料等）。未经天数智芯事先书面许可，严禁任何形式的使用、复制、传播、转录或翻译。

免责声明

天数智芯可以随时对本文档或本文档中描述的产品进行改进和/或更改。本文档包括与天数智芯产品有关的信息，作为说明典型应用的一种方式，因此，不一定提供足以进行生产设计的完整信息。对于本文档中内容的准确性或完整性，天数智芯不做任何陈述或保证。

联系方式

地址：上海闵行区陈行公路 2168 号 3 幢

电话：021-68886607

网址：www.iluvatar.com

目录

1 ONNXRuntime 框架功能说明	4
1.1 修订记录	4
1.2 ONNXRuntime 框架概览	4
1.3 支持的特性	4
1.4 已验证通过的网络模型	7
1.5 常见问题	7

1 ONNXRuntime 框架功能说明

1.1 修订记录

- COREX01-BI430-RF04-00: 2025/6/30
无内容更新
- COREX01-BI420-RF04-00: 2025/1/24
 - 更新天数智芯适配版 ONNXRuntime 的版本为 v1.17.1
 - 更新 ONNXRuntime 单元测试用例目录为 build/Linux/Release
 - 删除“运行推理示例脚本”，内容已不适用当前版本，如需获取推理示例脚本，请联系您的应用工程师了解详情
- COREX01-BI411-RF04-00: 2024/8/26
 - “运行推理示例脚本”提供如下内容：
 - * “安装软件栈和深度学习框架”步骤说明
 - * “安装示例脚本和推理测试数据集”步骤说明

1.2 ONNXRuntime 框架概览

天数智算软件栈提供天数智芯适配版的 ONNXRuntime v1.17.1。

ONNXRuntime 是一个跨平台的深度学习加速器，用于从 PyTorch, TensorFlow 等深度学习框架导出为 ONNX 模型，将其部署到生产环境的高性能推理引擎，也可用作模型训练。具体内容可参考 [ONNXRuntime 官方文档](#) 以及 [GitHub 主页](#)。

1.3 支持的特性

ONNXRuntime 官方提供了全面的单元测试用例，在手动编译后可在文件夹 build/Linux/Release 下执行多种测试程序。

您可运行以下命令验证天数智芯适配版 ONNXRuntime 功能：

```
./onnxruntime_test_all --gtest_filter=${test_case}
```

例如，若希望执行第一个 GraphTransformationTests 大类中所有测试 case，则可输入以下指令，命令结尾星号 (*) 代表通过正则表达式匹配所有测试子类：

```
./onnxruntime_test_all --gtest_filter=GraphTransformationTests\*
```

天数智芯适配版支持以下单元测试用例：

- GraphTransformationTests

- OptimizerTest
- CUDAFenceTests
- InferenceSessionTests
- ActivationOpTest
- AttentionTest
- BiasDropoutTest
- BiasSoftmaxTest
- CropOpTest
- DecoderAttentionTest
- DynamicSliceTest
- MathOpTest
- BiasGeluTest
- EmbedLayerNormTest
- FastGeluTest
- FusedConvTest
- FusedMatMulOpTest
- GridsampleContribOpTest
- InverseContribOpTest
- LayerNormTest
- LongformerAttentionTest
- NGramRepeatBlockTest
- QAttentionTest
- DequantizeLinearOpTest
- QuantizeLinearContribOpTest
- SkipLayerNormTest
- CropContribOpTest
- ImageScalerContribOpTest
- TriluContribOpTest
- ActivationOpNoInfTest
- ReluGradInferenceTest
- SigmoidGradInferenceTest
- TanhGradInferenceTest
- If
- Loop
- ConstantOfShape
- Random
- RangeTest
- CumSumTest
- GemmOpTest
- LogSoftmaxOperator
- MatmulIntegerOpTest
- RoundTest
- SoftmaxOperator
- TopKOperator
- BatchNormTest
- ConvTransposeTest
- Dropout

- InstanceNormalizationOpTest
- LRNTest
- PoolTest
- NonMaxSuppressionOpTest
- RoiAlignTest
- SequenceOpsTest
- CastOpTest
- CompressTest
- ConcatOpTest
- QuantizeLinearOpTest
- ExpandOpTest
- EyeLikeOpTest
- GatherElementsOpTest
- GatherNDOpTest
- GatherOpTest
- NonZeroOpTest
- OneHotOpTest
- PadOpTest
- ResizeOpTest
- UpsampleOpTest
- ReverseSequenceTest
- ScatterNDOpTest
- Scatter
- SliceTest
- TensorOpTest
- SplitOperatorTest
- TransposeOpTest
- TriluOpTest
- TriluTest
- WhereOpTest
- GeluGradTest
- FastGeluGradTest
- BiasGeluGradDxTest
- BiasFastGeluGradDxTest
- ReluGradTest
- SigmoidGradTest
- TanhGradTest
- IsFiniteTest
- IsAllFiniteTest
- DropoutTest
- DropoutGradTest
- AllOpTest
- ConcatTrainingOpTest
- GatherGradOpTest
- GatherGradOpTest
- GatherNDGradOpTest
- SliceGradOpTest

- SplitTrainingOpTest
- ConvGradTest
- GatherElementsGrad
- GradientUtilsTest
- GradientGraphBuilderTest
- TrainingRunnerTest
- TrainingSessionTest
- ReductionOpTestWrapper/ReductionOpTest

1.4 已验证通过的网络模型

天数智芯适配版深度学习框架已验证对如下网络模型的支持：

- ResNet50
- VGG16
- BERT
- Conformer

注：

- 本次发布提供 BERT-Base 模型推理演示脚本，请向您的应用工程师了解详情。
- 已验证天数智芯适配版对上述模型在单机单卡环境的支持，暂不支持多卡分布式。

1.5 常见问题

问题 1：在 ARM 平台上安装 onnxruntime 包遇到如下报错：

```
CMake Error at CMakeLists.txt:1252 (target_compile_definitions):
```

```
Error evaluating generator expression:
```

```
$<TARGET_PROPERTY:Python::Module,INTERFACE_COMPILE_DEFINITIONS>
```

```
Target "Python::Module" not found.
```

```
Call Stack (most recent call first):
```

```
onnxruntime_python.cmake:76 (onnxruntime_add_include_to_target)
```

```
CMakeLists.txt:1968 (include)
```

```
CMake Error at CMakeLists.txt:1252 (target_compile_definitions):
```

```
Error evaluating generator expression:
```

```
$<TARGET_PROPERTY:Python::NumPy,INTERFACE_COMPILE_DEFINITIONS>
```

```
Target "Python::NumPy" not found.
```

执行以下命令进行安装解决该问题：

```
yum install python3-numpy
```

问题 2：在 ARM 平台上安装 onnxruntime 包遇到如下报错：

```
/data/iluvatar/onnxruntime/build/Linux/Release/tml.pb.cc:103:76: error: temporary of  
↳ non-literal type ~@Xonnxruntime::proto::MapStringToFloat~@~Y in a constant  
↳ expression
```

这与 <https://github.com/microsoft/onnxruntime/issues/9225> 是同样的问题，与天数智算软件栈无关。

安装 GCC 版本 7.4 以上可解决该问题。

商标声明

- 天数智芯、天数智芯 logo、Iluvatar CoreX 等商标、标识、组合商标为上海天数智芯半导体有限公司之注册商标或商标，受法律保护。
- CentOS 标识为 Red Hat 公司的商标。
- Docker 为 Docker 公司在美国和其他国家的商标或注册商标。
- Linux 为 Linus Torvalds 在美国和其它国家的注册商标。
- NVIDIA、CUDA、GeForce 和 GeForce GTX 为 NVIDIA 公司在美国和/或其它国家的商标和/或注册商标。
- PyTorch 为 Facebook 公司的商标。
- TensorFlow 为 Google 公司的商标。
- Ubuntu 为 Canonical 公司的注册商标。

除上述明确列出的商标外，本内容中可能存在的任何其他未明示的产品名称、服务名称、企业名称、标识、口号、域名或其他商业标记 (无论是否标注 ™ 或 ® 符号)，均假定归属于其各自合法的商标权人所有。