



天数智芯
Iluvatar CoreX

天数智芯

PaddlePaddle 框架功能说明

版本：V4.3.0 (x86)|V4.3.6 (ARM)

日期：2025.6.30

适用产品：天垓 150| 智铠系列

声明

版权与保密声明

本文档（属未发表作品）版权归属于天数智芯全权所有，且本声明不构成对本文档已发表的承认。本文档所载全部信息均为天数智芯保密信息（包括但不限于天数智芯技术信息、经营信息、专属于接收方的未公开资料等）。未经天数智芯事先书面许可，严禁任何形式的使用、复制、传播、转录或翻译。

免责声明

天数智芯可以随时对本文档或本文档中描述的产品进行改进和/或更改。本文档包括与天数智芯产品有关的信息，作为说明典型应用的一种方式，因此，不一定提供足以进行生产设计的完整信息。对于本文档中内容的准确性或完整性，天数智芯不做任何陈述或保证。

联系方式

地址：上海闵行区陈行公路 2168 号 3 幢

电话：021-68886607

网址：www.iluvatar.com

目录

1 PaddlePaddle 框架功能说明	4
1.1 修订记录	4
1.2 PaddlePaddle 框架简介	4
1.3 支持的特性	5
1.3.1 分布式训练	5
1.3.2 AMP 自动混合精度训练	5
1.3.3 推理部署	5
1.3.4 FlashAttention 支持	6
1.3.5 版本更新	6
1.3.6 支持 warpctc 部分功能	6
1.4 已验证通过的网络模型	6
1.5 运行训练示例脚本	8
1.5.1 开始之前	8
1.5.1.1 安装软件栈和深度学习框架	8
1.5.1.2 安装示例脚本和训练测试数据集	8
1.5.2 测试步骤	9

1 PaddlePaddle 框架功能说明

1.1 修订记录

- COREX01-BI430-RF04-00: 2025/6/30
 - 更新天数智芯适配版 PaddlePaddle 的版本为 v3.0.0 Beta
 - 提供 v3.0.0 Beta **版本更新** 内容
 - 更新**测试步骤**
- COREX01-BI420-RF04-01: 2025/3/21
 - 更新解压 deeplearningsamples-{v.r.m}.tgz 后 deeplearningsamples 的存放目录
- COREX01-BI420-RF04-00: 2025/1/24
 - 新增支持 warpctc 部分功能 特性
 - **已验证通过的网络模型** 新增支持 LLaMA-13B 的 AMP 分布式训练
- COREX01-BI411-RF04-00: 2024/8/26
 - **开始之前** 提供如下内容:
 - * **安装软件栈和深度学习框架** 步骤说明
 - * **安装示例脚本和训练测试数据集** 步骤说明
- COREX01-BI410-RF04-00: 2024/6/30
 - 无内容更新
- COREX01-BI340-RF04-00: 2024/3/25

文档本次发布内容与 V3.3.0-BI150 文档相比 (COREX01-BI330-RF04-00), 有以下更新:

 - 更新天数智芯适配版 PaddlePaddle 的版本为 v2.5.2
 - 新增**FlashAttention** 支持
 - 更新**版本更新**

1.2 PaddlePaddle 框架简介

天数智算软件栈提供天数智芯适配版的 PaddlePaddle v3.0.0 Beta 深度学习编程框架。

飞桨 PaddlePaddle 以百度多年的深度学习技术研究和业务应用为基础, 是中国首个自主研发、功能完备、开源开放的产业级深度学习平台, 集深度学习核心训练和推理框架、基础模型库、端到端开发套件和丰富的工具组件于一体。更多使用说明, 您可参考官方主页 [飞桨 PaddlePaddle-源于产业实践的开源深度学习平台](#) 和 [GitHub](#)。

1.3 支持的特性

天数智芯适配版 PaddlePaddle 支持 x86 架构，已在一个或多个模型训练推理中验证以下特性。

以下两个环境变量为保证性能，默认值与 PaddlePaddle 官方文档中不同：

- FLAGS_cudnn_exhaustive_search，默认值为 True，PaddlePaddle 官方文档中为 False
- FLAGS_cudnn_batchnorm_spatial_persistent，默认值为 True，PaddlePaddle 官方文档中为 False

1.3.1 分布式训练

天数智芯适配版 PaddlePaddle 目前支持单机多卡和多机多卡训练，后端为 ixCCL，详细说明请参考 [分布式训练-使用文档-PaddlePaddle 深度学习平台](#)。

多机多卡训练已在 ResNet50 4 机 32 卡中验证通过。

1.3.2 AMP 自动混合精度训练

天数智芯适配版 PaddlePaddle 目前支持 PaddlePaddle 混合精度训练 AMP O1 和 AMP O2 级别的优化运行。

混合精度训练是指在训练过程中，同时使用单精度（FP32）和半精度（FP16），其目的是相较于使用单精度（FP32）训练模型，在保持精度持平的条件下，能够加速训练。使用飞桨框架提供的 API，能够在原始训练代码基础上快速开启自动混合精度训练（Automatic Mixed Precision, AMP），即在相关 OP 的计算中，根据一定的规则，自动选择 FP16 或 FP32 计算。

依据 FP16 在模型中的使用程度划分，飞桨的 AMP 分为两个等级：

- level = 'O1': 采用黑白名单策略进行混合精度训练，黑名单中的 OP 将采用 FP32 计算，白名单中的 OP 将采用 FP16 计算，训练过程中框架会自动将白名单 OP 的输入参数数据类型从 FP32 转为 FP16，使用 FP16 与 FP32 进行计算的 OP 列表可参考[paddle.amp 官方文档](#)。
- level = 'O2': 该模式采用了比 O1 更为激进的策略，除了框架不支持 FP16 计算的 OP，其它全部采用 FP16 计算，框架会预先将网络参数从 FP32 转换为 FP16，相比 O1，训练过程中无需做 FP32 转为 FP16 的操作，训练速度会有更明显的提升，但可能会存在精度问题，为此，框架提供了自定义黑名单，您可通过该名单指定一些存在精度问题的 OP 执行 FP32 运算。

1.3.3 推理部署

天数智芯适配版 PaddlePaddle 支持 PaddlePaddle 框架原生的推理库 Paddle Inference。您可以使用 Paddle Inference 进行云端、服务器端的推理部署加速。

由于能力直接基于飞桨的训练算子，因此 Paddle Inference 可以通用支持飞桨训练出的所有模型。

Paddle Inference 功能特性丰富，性能优异，针对不同平台不同的应用场景进行了深度的适配优化，做到高吞吐、低时延，保证了飞桨模型在服务器端即训即用，快速部署。

详细说明文档参考：[推理部署-使用文档-PaddlePaddle 深度学习平台](#)

1.3.4 FlashAttention 支持

天数智芯适配版 PaddlePaddle 支持通过自有算子库加速的 FlashAttention 算法，大幅提高了大模型训练的效率。

1.3.5 版本更新

- 天数智芯适配版 PaddlePaddle 从 v2.5 版本升级到 v3.0 Beta 版本，核心特性主要包括动静统一自动并行技术和神经网络编译器自动优化等新技术。

详细得更新信息，请参考 [PaddlePaddle v3.0.0 Beta Release Note](#)。

- 天数智芯适配版 PaddlePaddle 从 v2.4 版本升级到 v2.5 版本，支持动静统一新架构，大幅提升了调度性能；PHI 算子库算子架构统一，提升了架构统一性，降低了框架开发的理解成本。

详细的更新信息，请参考 [PaddlePaddle v2.5.0 Release Note](#)。

1.3.6 支持 warpctc 部分功能

目前 warpctc 中的部分函数被迁移到了 GPU 上，从而可以提升算子性能，您可以通过将环境变量 **FLAGS_disable_warpctc_gpu** 设置为 **False** 进行控制。该环境变量的默认值为 **True**，表示禁用 warpctc 通过 GPU 传输。

Note

将环境变量 **FLAGS_disable_warpctc_gpu** 设置为 **False** 后，如果在运行过程中遇到部分暂未支持的函数，会抛出错误。此时您需要将环境变量值还原为 **True**。

1.4 已验证通过的网络模型

本次发布选取了多种模型做移植，并进行了多种类型测试。表格中“支持”表明对功能做了验证。这些测试结果表明天数智芯适配版 PaddlePaddle 框架可以支持主流网络模型。

模型名称	FP32 分 布式训练	AMP 分 布式训练	推理 部署
ResNet50	支持	支持	支持
Bert	支持	支持	支持
CRNN	支持	支持	支持
YoloV3	支持		支持
VGG16	支持	支持	支持
MobileNetV3	支持		支持

模型名称	FP32 分 布式训 练	AMP 分 布式训 练	推理 部署
PP-YOLOE	支持		支持
Mask R-CNN	支持	支持	支持
SSD-MobileNetV1	支持		支持
DeepLabv3	支持		支持
UNet	支持	支持	支持
Transformer	支持	支持	支持
DeepFM	支持		支持
Wide&Deep	支持		支持
PSE		支持	支持
GoogleNet		支持	支持
PP-HumanSegV1		支持	支持
PP-HumanSegV2		支持	支持
MobileSeg	支持		支持
OCRNet	支持		支持
STDCSeg	支持		支持
GCN	支持		支持
DQN	支持		支持
PP-TTS-FastSpeech2	支持		支持
PP-TTS-HiFiGAN	支持		支持
GAT	支持		支持
GraphSage	支持		支持
ERNIE 3.0	支持		支持
PP-ASR-Conformer	支持		支持
ByteTrack		支持	支持
OC_SORT		支持	支持
PP-PicoDet	支持		支持
OCR-DB	支持		支持
PP-LCNet_x1_0	支持		支持

模型名称	FP32 分 布式训 练	AMP 分 布式训 练	推理 部署
HRNet (keypoint)	支持		支持
PP-LiteSeg	支持		支持
blazeface	支持		支持
FastFCN	支持		支持
FFM	支持		支持
JDE_darknet	支持		支持
XLNET	支持		支持
SVTR	支持		支持
LLaMA-13B		支持	

1.5 运行训练示例脚本

1.5.1 开始之前

1.5.1.1 安装软件栈和深度学习框架

按照《软件栈安装指南》完成以下前置条件：

- 安装天数智算软件栈
- 安装天数智芯适配版深度学习训练框架

1.5.1.2 安装示例脚本和训练测试数据集

Note

- 本文档中，安装包和路径中的“{v.r.m}”表示待安装的示例脚本和测试数据集的版本号。
- 本文档中，安装包和路径中的“{ARCH}”表示示例脚本安装包适用的架构，与您当前设备环境的架构保持一致。

安装示例脚本和训练测试数据集，请先确保以下准备工作已完成：

- CMake 版本不低于 v3.16
- unzip
- pip3 并通过 **sudo pip3 install --upgrade pip** 升级到新版本，以避免运行网络模型训练示例脚本出现报错
- 确保您的安装环境可以访问外网
- 通过以下方式获取安装示例脚本 `deeplearningsamples-{v.r.m}.tgz`：

- 登录 [天数智芯官网](#)，进入 **客户支持 > 资源中心** 页面进行下载
- 联系您的应用工程师获取
- 联系您的应用工程师获取训练测试数据集 `corex-test-tools-data-4.0.0.tar` (您可以使用 v4.0.0 版本的数据集进行测试，于当前软件栈版本无影响)

参考如下步骤安装示例脚本和训练测试数据集：

1. 安装示例脚本 `deeplearningsamples-{v.r.m)}.tgz`：

```
$ tar -xvf deeplearningsamples_{v.r.m)}.tgz
```

Tip

- 为确保可以顺利使用测试数据集，请选择空间足够大的 `{COREX_SAMPLES_PATH}`。
- 解压后的 `deeplearningsamples` 将存放在 `deeplearningsamples-{v.r.m)}.tgz` 包所在目录。

2. 移动训练测试数据集 `corex-test-tools-data-4.0.0.tar` 至 `${path_to_package}/deeplearningsamples` 目录下。

3. 解压训练测试数据集：

```
$ cd ${path_to_package}/deeplearningsamples
$ sudo tar xf corex-test-tools-data-4.0.0.tar
```

训练测试数据集中还包括模型权重和 whl 包，文件较大，解压耗时可能较长，请您耐心等待。

4. 准备环境：

```
$ cd ${path_to_package}/deeplearningsamples
$ bash quick_build_environment.sh # 运行训练示例脚本前准备环境
```

该脚本会解压数据集并安装必要的一些包。

1.5.2 测试步骤

PaddlePaddle 框架训练模型的示例脚本命名方式是 `${model}/train_${model_suffix}_paddle.sh`。

本次发布提供以下测试脚本：

- ResNet50 和 BERT 模型的单精训练脚本
- ResNet50 模型的 4 机 32 卡训练脚本（已在 x86 平台验证通过）

运行模型训练脚本，以 root 用户的示例脚本默认安装路径 `${path_to_package}/deeplearningsamples` 为例：

```
$ cd ${path_to_package}/deeplearningsamples/executables
$ cd resnet
$ bash init_paddle.sh # 运行模型初始化脚本
$ bash train_resnet50_dist_paddle.sh
```

商标声明

- 天数智芯、天数智芯 logo、Iluvatar CoreX 等商标、标识、组合商标为上海天数智芯半导体有限公司之注册商标或商标，受法律保护。
- CentOS 标识为 Red Hat 公司的商标。
- Docker 为 Docker 公司在美国和其他国家的商标或注册商标。
- Linux 为 Linus Torvalds 在美国和其它国家的注册商标。
- NVIDIA、CUDA、GeForce 和 GeForce GTX 为 NVIDIA 公司在美国和/或其它国家的商标和/或注册商标。
- PyTorch 为 Facebook 公司的商标。
- TensorFlow 为 Google 公司的商标。
- Ubuntu 为 Canonical 公司的注册商标。

除上述明确列出的商标外，本内容中可能存在的任何其他未明示的产品名称、服务名称、企业名称、标识、口号、域名或其他商业标记 (无论是否标注 ™ 或 ® 符号)，均假定归属于其各自合法的商标权人所有。