



天数智芯
Iluvatar CoreX

天数智芯

Triton 框架功能说明

版本：V4.3.0-BI150 (x86)|V4.3.6-BI150 (ARM)

日期：2025.6.30

适用产品：天垓 150

声明

版权与保密声明

本文档（属未发表作品）版权归属于天数智芯全权所有，且本声明不构成对本文档已发表的承认。本文档所载全部信息均为天数智芯保密信息（包括但不限于天数智芯技术信息、经营信息、专属于接收方的未公开资料等）。未经天数智芯事先书面许可，严禁任何形式的使用、复制、传播、转录或翻译。

免责声明

天数智芯可以随时对本文档或本文档中描述的产品进行改进和/或更改。本文档包括与天数智芯产品有关的信息，作为说明典型应用的一种方式，因此，不一定提供足以进行生产设计的完整信息。对于本文档中内容的准确性或完整性，天数智芯不做任何陈述或保证。

联系方式

地址：上海闵行区陈行公路 2168 号 3 幢

电话：021-68886607

网址：www.iluvatar.com

目录

1 Triton 框架功能说明	4
1.1 修订记录	4
1.2 Triton 框架概览	4
1.3 支持的特性	4
1.4 支持的算子	6
1.4.1 triton.language 算子支持列表	6
1.4.1.1 Programming Model	6
1.4.1.2 Creation Ops	6
1.4.1.3 Shape Manipulation Ops	6
1.4.1.4 Linear Algebra Ops	6
1.4.1.5 Memory/Pointer Ops	7
1.4.1.6 Indexing Ops	7
1.4.1.7 Math Ops	7
1.4.1.8 Reduction Ops	7
1.4.1.9 Atomic Ops	8
1.4.1.10 Random Number Generation	8
1.4.1.11 Iterators	8
1.4.1.12 Compiler Hint Ops	8
1.4.1.13 Debug Ops	8
1.4.2 tl.math ops	9
1.4.3 tl.ops	13
1.5 支持的模型	13

1 Triton 框架功能说明

1.1 修订记录

- COREX01-BI430-RF10-00: 2025/6/30
 - 更新天数智芯适配版 Triton 的版本为 v3.1.0, 当前版本中 Triton 后端以更加解耦的方式被添加到 third_party 目录中
- COREX01-BI420-RF10-00: 2025/1/24
 - 更新本次发布适配的 Triton 仓库为 [1af893d8a2](#)
- COREX01-BI411-RF10-00: 2024/8/26
 - 更新支持的模型
 - 删除“运行训练演示脚本”
- COREX01-BI410-RF10-00: 2024/6/30
文档首次对外发布

1.2 Triton 框架概览

天数智算软件栈提供天数智芯适配版的 Triton v3.1.0 深度学习语言和编译器。

Triton 是一种用于编写高效的自定义深度学习原语的语言和编译器。Triton 的目标是提供一个开源环境, 比 CUDA 更高效快速地编写代码, 同时比其他现有的领域特定语言 (Domain-specific Language, DSL) 更具灵活性。

关于 Triton 的详情, 请参考 [Triton 官方页面](#)。

官方 Triton 提供了 [系列教程](#) 供您参考 (包括 vector-add, fused-softmax, matrix-multiplication, fused-attention 等)。

本次发布适配 Triton v3.1.x 版本 (commit ID: [cf34004b8a](#))。相较于 Triton v2.1.0 版本, 本次发布适配的版本有很大的不同: Triton 后端以更加解耦的方式被添加到 third_party 目录中。

- 在天数智芯适配版 Triton v2.1 版本中, 天数智芯所有适配的代码都存放在公共的 include, lib 目录下
- 在天数智芯适配版 Triton v3.1 版本中, 与其它多后端保持一致, Triton 也在 third_party 下新建 iluvatar 子目录, 一些特有的适配和优化逻辑也尽可能存放在 {third_party}/iluvatar/include 和 {third_party}/iluvatar/lib 目录下

1.3 支持的特性

天数智芯适配版 Triton 适配了原生的编译和优化流程, 并针对天数智芯加速卡的硬件特性做了优化, 例如对于矩阵乘运算, 数据可以使用 SME (Share Memory Engine) 加载, 计算使用天数智算软件栈的 mma 指令。

受益于对 LLVM 生态的兼容与对通用 GPU 架构的优势, 天数智芯对于 Triton 的编译流程可以做到完美支持。为了支持天数智芯加速卡硬件特性, 天数智算软件栈基于 Triton 自身提供的通用 GPU 优化流程, 重点对

Triton GPU IR 的优化转换进行了适配和开发，使得相同的 triton kernel 代码以高性能运行在天数智芯加速卡上。目前，天数智算软件栈已经对 [Triton Tutorials](#) 下的典型算子进行了支持和优化。一些带宽受限的算子 (如 vector-add, fused-softmax 等) 的性能和 PyTorch 原生算子基本持平或更优，而矩阵乘法算子也已经达到手写 CUDA 算子库的 90% 以上。未来，天数智芯还会继续进行其他算子开发、指令优化、性能调优等工作。另外，从模型层面，天数智芯也会持续关注使用 Triton 手写算子或基于 PyTorch 2.x inductor 自动生成 triton kernels 的项目，不断优化和完善 Triton 的适配和开发工作。

Triton 的编程系统架构如下图所示：




图 1: Triton 编程系统架构图

1.4 支持的算子

天数智芯适配版 Triton 的算子可以分为两类，一类是 triton.language 下的基础算子，一类是使用 Triton 基础算子搭建的复合算子 (在 triton.ops 下)。目前，天数智芯已经适配并验证了所有 Triton 算子。

1.4.1 triton.language 算子支持列表

1.4.1.1 Programming Model

```
tensor  
program_id  
num_programs
```

1.4.1.2 Creation Ops

```
arange  
ones  
full  
zeros  
zeros_like
```

1.4.1.3 Shape Manipulation Ops

```
broadcast  
broadcast_to  
expand_dims  
ravel  
reshape  
trans  
view  
cat
```

1.4.1.4 Linear Algebra Ops

```
dot
```

1.4.1.5 Memory/Pointer Ops

```
load  
store  
make_block_ptr  
advance
```

1.4.1.6 Indexing Ops

```
where  
swizzle2d
```

1.4.1.7 Math Ops

```
abs  
cdiv  
cos  
exp  
fdiv  
log  
maximum  
minimum  
sigmoid  
sin  
softmax  
sqrt  
umulhi
```

1.4.1.8 Reduction Ops

```
argmax  
argmin  
max  
min  
reduce  
sum  
xor_sum
```

1.4.1.9 Atomic Ops

```
atomic_add  
atomic_and  
atomic_cas  
atomic_max  
atomic_min  
atomic_or  
atomic_xchg  
atomic_xor
```

1.4.1.10 Random Number Generation

```
rand  
rand4x  
randint  
randint4x  
randn  
randn4x
```

1.4.1.11 Iterators

```
static_range
```

1.4.1.12 Compiler Hint Ops

```
debug_barrier  
max_constancy  
max_contiguous  
multiple_of
```

1.4.1.13 Debug Ops

```
static_print  
static_assert  
device_print  
device_assert
```

1.4.2 tl.math ops

该类 ops 实际调用的是 libdevice.bc 中的实现。

```

clz
popc
byte_perm
min
max
mulhi
mul24
brev
sad
abs
floor
rcp64h
rsqrt
ceil
trunc
exp2
saturatef
fma_rn
fma_rz
fma_rd
fma_ru
fast_dividef
div_rn
div_rz
div_rd
div_ru
rcp_rn
rcp_rz
rcp_rd
rcp_ru
sqrt_rn
sqrt_rz
sqrt_rd
sqrt_ru
sqrt
add_rn
add_rz
add_rd
add_ru
mul_rn
mul_rz
mul_rd
mul_ru
double2float_rn
double2float_rz
double2float_rd

```

double2float_ru
double2int_rn
double2int_rz
double2int_rd
double2int_ru
double2uint_rn
double2uint_rz
double2uint_rd
double2uint_ru
int2double_rn
uint2double_rn
float2int_rn
float2int_rz
float2int_rd
float2int_ru
float2uint_rn
float2uint_rz
float2uint_rd
float2uint_ru
int2float_rn
int2float_rz
int2float_rd
int2float_ru
uint2float_rn
uint2float_rz
uint2float_rd
uint2float_ru
hiloInt2double
double2loint
double2hiint
float2l1_rn
float2l1_rz
float2l1_rd
float2l1_ru
float2u1l_rn
float2u1l_rz
float2u1l_rd
float2u1l_ru
double2l1_rn
double2l1_rz
double2l1_rd
double2l1_ru
double2u1l_rn
double2u1l_rz
double2u1l_rd
double2u1l_ru
l12float_rn
l12float_rz
l12float_rd
l12float_ru

ull2float_rn
ull2float_rz
ull2float_rd
ull2float_ru
ll2double_rn
ll2double_rz
ll2double_rd
ll2double_ru
ull2double_rn
ull2double_rz
ull2double_rd
ull2double_ru
int_as_float
float_as_int
uint_as_float
float_as_uint
longlong_as_double
double_as_longlong
fast_sinf
fast_cosf
fast_log2f
fast_logf
fast_expf
fast_tanf
fast_exp10f
fast_log10f
fast_powf
hadd
rhadd
sub_rn
sub_rz
sub_rd
sub_ru
rsqrt_rn
ffs
rint
llrint
nearbyint
isnan
signbit
copysign
finitef
isinf
nextafter
sin
cos
sinpi
cospi
tan
log2

exp
exp10
cosh
sinh
tanh
atan2
atan
asin
acos
log
log10
log1p
acosh
asinh
atanh
expm1
hypot
rhypot
norm3d
rnorm3d
norm4d
rnorm4d
cbrt
rcbrt
j0
j1
y0
y1
yn
jn
cyl_bessel_i0
cyl_bessel_i1
erf
erfinv
erfc
erfcx
erfcinv
normcdfinv
normcdf
lgamma
ldexp
scalbn
fmod
remainder
fma
pow
tgamma
round
llround
fdim

```
ilogb  
logb  
isfinitd
```

1.4.3 tl.ops

```
matmul  
attention  
cross_entropy  
blocksparse.matmul  
blocksparse.softmax
```

1.5 支持的模型

天数智芯适配版的 Triton 支持的模型如下所示：

- torchbench alexnet
- torchbench resnet50
- torchbench mobilenet_v2
- torchbench yolov3
- torchbench vgg16
- TIMM inception_v3
- TIMM visformer_small
- Huggingface GPT2ForSequenceClassification
- Huggingface MegatronBertForQuestionAnswering
- Huggingface BertForQuestionAnswering

Note

- 天数智芯适配版的 Triton 从 PyTorch/Benchmarks/Dynamo (TorchBench, TIMM, Huggingface 三类) 中挑选了以上模型进行验证和支持。
- 这些模型使用 `torch.compile()` 编译，后端使用 inductor，将 `fx_graph` 中的一些算子融合并生成 triton kernels，另外一些算子择优走 torch native 或 triton 实现。

商标声明

- 天数智芯、天数智芯 logo、Iluvatar CoreX 等商标、标识、组合商标为上海天数智芯半导体有限公司之注册商标或商标，受法律保护。
- CentOS 标识为 Red Hat 公司的商标。
- Docker 为 Docker 公司在美国和其他国家的商标或注册商标。
- Linux 为 Linus Torvalds 在美国和其它国家的注册商标。
- NVIDIA、CUDA、GeForce 和 GeForce GTX 为 NVIDIA 公司在美国和/或其它国家的商标和/或注册商标。
- PyTorch 为 Facebook 公司的商标。
- TensorFlow 为 Google 公司的商标。
- Ubuntu 为 Canonical 公司的注册商标。

除上述明确列出的商标外，本内容中可能存在的任何其他未明示的产品名称、服务名称、企业名称、标识、口号、域名或其他商业标记 (无论是否标注 ™ 或 ® 符号)，均假定归属于其各自合法的商标权人所有。