



天数智芯
Iluvatar CoreX

天数智芯

天垓加速卡大模型性能优化指南

版本：V4.1 及以上

日期：2025.6.30

适用产品：天垓 150

声明

版权与保密声明

本文档（属未发表作品）版权归属于天数智芯全权所有，且本声明不构成对本文档已发表的承认。本文档所载全部信息均为天数智芯保密信息（包括但不限于天数智芯技术信息、经营信息、专属于接收方的未公开资料等）。未经天数智芯事先书面许可，严禁任何形式的使用、复制、传播、转录或翻译。

免责声明

天数智芯可以随时对本文档或本文档中描述的产品进行改进和/或更改。本文档包括与天数智芯产品有关的信息，作为说明典型应用的一种方式，因此，不一定提供足以进行生产设计的完整信息。对于本文档中内容的准确性或完整性，天数智芯不做任何陈述或保证。

联系方式

地址：上海闵行区陈行公路 2168 号 3 幢

电话：021-68886607

网址：www.iluvatar.com

目录

1 天玑加速卡大模型性能优化指南	5
1.1 修订记录	5
1.2 性能优化指南	5
1.2.1 单机/多机优化场景	5
1.2.1.1 设置 CPU 模式以提升性能	5
1.2.1.2 合理选择 CUDA_VISIBLE_DEVICES 排布方式以提升性能	6
1.2.1.3 更高效的 Flash-Attention 算子	7
1.2.2 多机优化场景	7
1.2.2.1 合理设定数据集存放路径以释放带宽	7
1.2.2.2 配置 RoCE/IB 带宽网络以保证带宽足够	8
1.2.2.3 合理设置 NCCL_ALGO 环境变量以降低优化器更新计算时间	8
1.2.2.4 合理设置 NCCL_SHM_DISABLE 和 NCCL_P2P_LEVEL 环境变量以降低通讯时间	9
1.2.2.5 配置 PFC 队列以提高训练性能和稳定性	9
1.2.2.6 合理选择 IB 网卡插法以提高数据传输效率	9
1.3 常见问题	11
1.3.1 Megatron-LM + ixTE 训练报错	12
1.3.1.1 问题 1: 多机训练中 Megatron-LM 在生成数据集 cache 时出现遗漏	12
1.3.1.2 问题 2: 多机训练中未生成 megatron/core/datasets/helpers.so 文件	12
1.3.1.3 问题 3: 出现 bin_buffer_map 相关报错	12
1.3.1.4 问题 4: flash-attn 报错 batch size must be positive	12
1.3.1.5 问题 5: ixCCL 报错 Gloo connectFullMesh failed	12
1.3.1.6 问题 6: ixCCL 初始化成功后出现 error 12	13
1.3.1.7 问题 7: 训练过程出现其它报错	13
1.3.1.8 问题 8: numpy 相关报错	13
1.3.2 Megatron-LM + ixTE 训练性能异常	13
1.3.2.1 问题 1: 频率长期波动导致性能不佳	13
1.3.2.2 问题 2: 服务器 topo 不同导致性能变化	13
1.3.3 Megatron-LM 混合训练报错	14
1.3.3.1 问题 1: 执行 run_mixed_device.sh 脚本后没有执行训练就结束进程	14
1.3.3.2 问题 2: 执行训练脚本报错 invalid argument, NCCL version 2.14.3	14
1.3.3.3 问题 3: 执行训练脚本报错 NCCL version 2.14.3 Unknow NCCL error	14
1.3.3.4 问题 4: 使用 IB 网络后执行脚本报错 internal error, NCCL version 2.14.3	15
1.3.4 LLaMA-Factory 训练报错	15
1.3.4.1 问题 1: 使用 ds_z3_offload_config.json 配置进行训练, 出现报错 launcher.py FAILED, exitcode 显示 -9	15
1.3.4.2 问题 2: 训练时提示 peft 版本不对 ImportError: peft>=0.11.1, <=0.12.0 is required for a normal functioning of this module, but found peft==0.10.0	15
1.3.4.3 问题 3: 训练时提示环境内未包含适配的 accelerate 库 ImportError: Megatron is not installed. please build it from source.	16
1.3.5 环境相关	16
1.3.5.1 问题 1: 机器重启后训练失败	16
1.3.5.2 问题 2: 训练时未使用 RMDA, 提示 NET/IB No device found	16

1.3.5.3	问题 3: 训练时报错 NCCL WARN Call to ibv_create_cq failed with error Cannot allocate memory	17
1.3.5.4	问题 4: 重装驱动时, itr_peer_mem_drv.ko 无法正常安装	17
1.3.5.5	问题 5: 多机训练在 IB 或 socket 通讯阶段 hang 住, 通过 ixSMI 查看加速卡利用率为 0, htop 查看 CPU 利用率为 100%	17
1.3.5.6	问题 6: torchrun 启动训练时直接退出, 报错类似 dmesg 出现 Pid xxxx (python3) over core_pipe_limit	17
1.3.5.7	问题 7: 进行大模型训练时发现 hang, 报错 iluvatar xxx: pciw outbound complete timeout...	18

1 天垓加速卡大模型性能优化指南

本文档旨在为用户提供常见的大模型性能优化场景和手段，相关问题及对应的解决方法。

1.1 修订记录

- COREX-LLMFAQ-RF01-03：2025/6/30
 - 更新合理设置 `NCCL_SHM_DISABLE` 和 `NCCL_P2P_LEVEL` 环境变量以降低通讯时间，新增 `NCCL_P2P_LEVEL` 环境变量的设置
- COREX-LLMFAQ-RF01-02：2025/1/24
 - 新增LLaMA-Factory 训练报错
- COREX-LLMFAQ-RF01-01：2024/11/8
 - 新增问题 7：进行大模型训练时发现 hang，报错 `iluvatar xxx: pciw outbound complete timeout...`
- COREX-LLMFAQ-RF01-00：2024/9/9
文档首次对外发布

1.2 性能优化指南

1.2.1 单机/多机优化场景

1.2.1.1 设置 CPU 模式以提升性能

描述

想要提升性能，通常建议将 CPU 模式设置为 performance。

优化方式

通过以下指令查看模式：

```
$ cat /sys/devices/system/cpu/cpu0/cpufreq/scaling_governor
```

通常情况下，一台服务器中所有 Core 的模式是相同的，因此仅需查看 cpu0 的模式即可。但这不是绝对的，如果想要进一步确认其它 Core 的模式，请在每台服务器下执行一次下述修改指令，将模式设置为 performance：

```
$ bash env_prof.sh
```

env_prof.sh 的文件内容如下

```
function set_cpu_performance()
```

```
{
CPU_NUM=`cat /proc/cpuinfo | grep processor | wc -l`
echo "set cpu performance mode"
for((i=0;i<CPU_NUM;i++))
do
    if [ -f "/sys/devices/system/cpu/cpu${i}/cpufreq/scaling_governor"
    ↪ ];then
        echo performance > /sys/devices/system/cpu/cpu${i}/cpufreq/
        ↪ scaling_governor
    fi
done
}
set_cpu_performance
```

预期效果

示例:

LLaMA2-70B 在 H3C 5200 G5 环境中, 4 台服务器均为 performance 模式, 相较于 3 台模式为 performance 的服务器加 1 台 powersave 模式的服务器, 性能提升 1.8%。

1.2.1.2 合理选择 CUDA_VISIBLE_DEVICES 排布方式以提升性能

描述

根据服务器不同的拓扑结构, 选择合适的 CUDA_VISIBLE_DEVICES 排布。常见的情况有两种, 分别是串联和并联; 另外还有 HPC, 直连 CPU 等情况。

优化方式

以 H3C 5200 G5 服务器为例, 提供以下设置建议 (不同品牌的服务器可能会有不同情况):

```
# 串联
$ export CUDA_VISIBLE_DEVICES=14,15,4,5,2,3,0,1,12,13,10,11,8,9,6,7

# 并联
$ export CUDA_VISIBLE_DEVICES=0,1,2,3,4,5,6,7,8,9,10,11,12,13,14,15
```

以上设置原则为根据物理 PCIe 的链路设置 GPU 排序, 尽量将同一个 switch 上的 GPU 安排相近以减少 GPU 间的通讯损耗。

预期效果

示例:

LLaMA2-70B 在 H3C 5200 G5 环境中, 排布方式切换为串联后, 性能提升 0.1%。

说明

具体排布方式, 需要参考[拓扑图](#)进行改变。

1.2.1.3 更高效的 Flash-Attention 算子

描述

使用更加高效的 Flash-Attention 实现。

优化方式

使用 ixDNN 的优化后的 Flash-Attention 实现，通过 `attention_use_memory_efficient` 调节两种实现选择：

- 设置为 `True`：表示消耗内存更少，但通常性能更低
- 设置为 `False`：表示消耗内存更多 (上限为 1GB)，但通常性能更高

设置 `attention_use_memory_efficient` 的方式：

在 Megatron-LM 框架中训练时，指定 `ixte_opt.yaml` 文件 (使用 Megatron-LM 框架训练支持传入 `yaml` 文件进行配置，支持用户自定义该 `yaml` 文件) 并在该文件中进行设置。`ixte_opt.yaml` 文件内容如下：

```
tp_overlap_mode: 0
mlp_g1_overlap_size: 1
mlp_g2_overlap_size: 1
attn_g1_overlap_size: 1
attn_g2_overlap_size: 1
mlp_g1_save_total_input_for_backward: False
attn_g1_save_total_input_for_backward: False
logits_gemm_save_total_input_for_backward: False

tp_overlap_sync_with_event: True
attention_use_memory_efficient: True
```

参考《Megatron-LM 框架功能说明》中的“ix-TransformerEngine > 优化参数说明”，了解可设置的优化参数和详情。

预期效果

Flash-Attention 算子在调优后性能大幅提升。

1.2.2 多机优化场景

1.2.2.1 合理设定数据集存放路径以释放带宽

描述

建议数据集的存放路径设定在各自的服务器中，**请勿设定在共享文件夹中**。这是因为当数据读写需求较大时，会受限于共享文件的读写带宽。

1.2.2.2 配置 RoCE/IB 带宽网络以保证带宽足够

描述

配置 RoCE/IB 高速带宽网络，在确认多机互通后，尽可能多地使用 RoCE/IB 网络端口以保证带宽足够。

优化方式

1. 确认是否开启 RoCE/IB 网络。

训练时开启 **NCCL_DEBUG=TRACE**，并确认训练 log 中显示使用 GDRDMA 连接方式 (以下示例显示表示使用 GDRDMA 连接方式，即开启 RoCE/IB 网络)：

```
gpuserver:1018391:1020065 [0] NCCL INFO Channel 00/0 : 191[94000] ->
    ↪ 192[d000] [receive] via NET/IB/0/GDRDMA
```

2. 如果 RoCE/IB 网络未开启，通过以下步骤进行开启：

- a. 先加载 **itr_peer_mem_drv** 驱动。
- b. 选择对应的网卡设备。提供以下两种选择方式：
 - 通过 **export** 命令手动指定网卡设备,例如 **export NCCL_IB_HCA=mlx5_0,mlx5_1,mlx5_2,mlx5_3**
 - 由 ixCCL 自行选择相关的网络端口

预期效果

多机之间的网络通信性能 (如 PP、DP 等) 大幅提升。

1.2.2.3 合理设置 NCCL_ALGO 环境变量以降低优化器更新计算时间

描述

请合理选择设置 **NCCL_ALGO=Tree**。

ixCCL 的 Collective 通信算子会根据通信设备数量/通信数据量等选择相关算法。

- 设置 **NCCL_ALGO=Ring**：
 - 通常为默认选择算法
 - 适用于 ReduceScatter, Allgather, Allreduce
 - 较小的通信组内可以达到较高的通信带宽
- 设置 **NCCL_ALGO=Tree**：
 - 需要手动设置
 - 适用于 Allreduce
 - 较大的通信组内可以达到相比于 Ring 算法更高的通信带宽

优化方式

目前，在大规模集群训练时，观察到 DP x CP Group 会出现较大 group 在优化器更新计算时的大量小 Tensor Allreduce 操作。此时，选择 **Tree** 算法有利于性能的提升。

参考如下方法设置 **NCCL_ALGO=Tree**：

在 Megatron-LM 框架中训练时，指定 **ixte_opt.yaml** 文件 (使用 Megatron-LM 框架训练支持传入 yaml 文件进行配置，支持用户自定义该 yaml 文件) 并在该文件中设置 **grad_norm_use_tree = True**。

预期效果

优化器更新计算时间下降。

1.2.2.4 合理设置 NCCL_SHM_DISABLE 和 NCCL_P2P_LEVEL 环境变量以降低通讯时间

描述

根据服务器拓扑与网卡配置，利用合理设置 NCCL_SHM_DISABLE 和 NCCL_P2P_LEVEL 环境变量，可以设定节点内 GPU 间通讯通过网络传输，不经过 SHM/P2P。

当使用并联服务器并且配置两张以上网卡时，推荐使用 NCCL_SHM_DISABLE=1 和 NCCL_P2P_LEVEL=PX8。

优化方式

设置 `export NCCL_SHM_DISABLE=1` 和 `export NCCL_P2P_LEVEL=PX8`。

预期效果

通讯时间下降。

1.2.2.5 配置 PFC 队列以提高训练性能和稳定性

描述

使用 RoCE 环境时，需配置 PFC 队列来减少丢包并提高训练的性能和稳定性。

优化方式

针对每个网口进行如下设置 (以网卡 mlx5_0、网口 ens2f0np0 为例):

1. 此配置将网络传输与队列 5 绑定:

```
$ echo 160 >/sys/class/infiniband/mlx5_0/tc/1/traffic_class
mlx_qos -i ens2f0np0 --pfc 0,0,0,0,0,1,0,0 --trust dscp
```

2. 在训练脚本中添加:

```
$ export NCCL_IB_TC=160
```

预期效果

训练性能和稳定性均得到提高。

说明

具体的队列，需要根据实际网络情况和交换机设置进行选择。

1.2.2.6 合理选择 IB 网卡插法以提高数据传输效率

描述


根据服务器物理拓扑的不同，IB 网卡需选择不同的 PCIe slot 来提高 GPU -> CPU -> IB 网卡的数据传输效率。

优化方式

以 H3C 5300 G5 AI 串联与 AI 并联服务器为例，提供 IB 网卡的推荐插法。

H3C 5300 G5 AI 串联推荐插法：

- 单卡：slot4
- 双卡：slot4, slot1



其中，各连线说明如下：




图 1: 串联推荐插法

H3C 5300 G5 AI 并联推荐插法：

- 单卡：slot4 或 slot2，并联架构下不推荐只插一张网卡
- 双卡：slot, slot2




图 2: 并联推荐插法

IB 网卡插法的主要原则是数据经过的 PCIe 链路越少越好，最佳选择是数据从 GPU 到 IB 网卡的过程中不通过 CPU 而是只通过 PCIe switch。

Tip

部分服务器厂家的白皮书中会提到推荐的网卡安装配置。

预期效果

按照推荐插法设置后，通讯性能有较大提升。

1.3 常见问题

1.3.1 Megatron-LM + ixTE 训练报错

1.3.1.1 问题 1：多机训练中 Megatron-LM 在生成数据集 cache 时出现遗漏

问题描述

多机训练中,某些版本 Megatron-LM 会在生成数据集 cache 时出现遗漏,例如 506dcb2b8eb87c52b16ee5eb06e9f871-GPTDataset-document_index.npy 文件未在所有机器上生成。

解决方法

可以使用共享存储存放数据集,或者将主节点 cache 文件复制到其它节点。

1.3.1.2 问题 2：多机训练中未生成 megatron/core/datasets/helpers.so 文件

问题描述

多机训练中,未能正常生成 megatron/core/datasets/helpers.so 文件。

解决方法

请确认 python-config 版本并尝试手动编译 megatron/core/datasets/helpers.so 文件。在 megatron/core/datasets/ 目录下执行 **make** 命令即可编译 helpers.so。

该问题的核心原因是当前 Python 版本和 python-config 版本不匹配 (例如, Python 版本是 v3.10, 而 python-config 版本是 v3.6), 可以尝试重新进行软链接, 将 python-config 链接为与 Python 相同的版本, 如 v3.10, 再重新发起训练 (此时使用自动编译的 3.10 版本的 helpers.so)。

1.3.1.3 问题 3：出现 bin_buffer_map 相关报错

解决方法

请确认数据集完整且路径正确。

1.3.1.4 问题 4：flash-attn 报错 batch size must be positive

解决方法

该问题的原因是 ixTE 版本与 flash-attn 版本不匹配, 请使用相匹配的发布版本, 即使用同一个天数智算软件栈下发布的 ixTE 和 flash-attn 安装包。

注意: 当使用新版 ixTE 搭配旧版 flash-attn 时可能不会报错, 但是存在正确性问题。

1.3.1.5 问题 5：ixCCL 报错 Gloo connectFullMesh failed

解决方法

排查以下可能的情况:

- 当前环境存在残留程序, 需要进行清理并重置天数智芯加速卡驱动 (使用 **ixsmi -r** 命令重置加速卡驱动)
- 网络端口名不匹配, 需要确认 NCCL_SOCKET_IFNAME 和 GLOO_SOCKET_IFNAME 环境变量已设置为可用的网口

1.3.1.6 问题 6: ixCCL 初始化成功后出现 error 12

解决方法

并联机器请尝试设置环境变量 NCCL_SHM_DISABLE, 详情请联系您的应用工程师。

1.3.1.7 问题 7: 训练过程出现其它报错

问题描述

训练过程中出现其它报错, 与 Megatron-LM 或 ixTE 不符合, 例如提示参数不存在, 但实际代码中存在此参数。

解决方法

检查当前环境中的 Megatron 和 Transformer_engine 是否是天数智芯发布的适配版 Megatron-LM 和 ixTE, 而不是开源实现版本。例如, megatron_lm-0.6.0+corex.4.1.1-cp310-cp310-linux_x86_64.whl 和 ixte-0.2.0+corex.4.1.1-cp310-cp310-linux_x86_64.whl。

训练前请先卸载已安装的开源版本的 Megatron-LM 或其它版本附带的 Megatron 和 Transformer_engine, 并使用天数智芯适配的版本进行安装。

1.3.1.8 问题 8: numpy 相关报错

解决方法

尝试替换 numpy 版本。

当前版本的天数智算软件栈验证 numpy v1.26.4 可正常进行大模型训练。

1.3.2 Megatron-LM + ixTE 训练性能异常

1.3.2.1 问题 1: 频率长期波动导致性能不佳

解决方法

请联系您的应用工程师帮助确认 dmesg 是否有高温降频告警。

1.3.2.2 问题 2: 服务器 topo 不同导致性能变化

解决方法

部分机型默认 GPU 顺序与物理顺序不匹配, 导致 TP 通讯发生在物理距离较远的 GPU 之间。

可以通过 `ixsmi topo -t` 命令查看当前 GPU 与 PCIe 的连接情况, 再使用 CUDA_VISIBLE_DEVICES 重新规划 GPU 的使用顺序。

并联或 HPC 架构, 如搭载多张网卡, 可以尝试设置环境变量 NCCL_SHM_DISABLE, 详情请联系您的应用工程师。

1.3.3 Megatron-LM 混合训练报错

1.3.3.1 问题 1：执行 run_mixed_device.sh 脚本后没有执行训练就结束进程

解决方法

请确认 run_mixed_device.sh 脚本中的参数是否输错，可能有以下几种情况需要排查：

- 当前节点的 IP 必须为 Master Node 的 IP
- 数据集的路径是否正确，如 c4 数据集的路径为 /datasets/c4_text_document_text_document/c4_text_document_text_document，最后的 c4_text_document_text_document 代表的并非文件夹而是数据集前缀
- 其它可能存在的路径或 IP 地址错误

1.3.3.2 问题 2：执行训练脚本报错 invalid argument, NCCL version 2.14.3

问题描述

执行训练脚本后报错：

```
torch.distributed.DistBackendError: NCCL error in: /opt/pytorch/pytorch/torch/
  ↳ csrc/distributed/c10d/NCCLUtils.hpp:207, invalid argument, NCCL version
  ↳ 2.14.3
ncclInvalidArgument: Invalid value for an argument.
```

解决方法

请确保混训环境中 ixCCL 和 NCCL 的版本是匹配的，如：

- ixCCL 需要使用 V4.1.0-BI150 的软件栈
- 若仍有报错，需要向您的应用工程师获取 v2.14.3 的混训 ixCCL 的 .so 文件进行替换
- 另外，也请检查链接文件的指向是否正确，即 libnccl.so 以及 libnccl.so.2 链接文件的指向

1.3.3.3 问题 3：执行训练脚本报错 NCCL verison 2.14.3 Unknow NCCL error

问题描述

执行训练脚本后报错：

```
NCCL watchdog thread terminated with exception: NCCL error: remote process exited
  ↳ or there was a network error, NCCL verison 2.14.3 Unknow NCCL error!
```

或者执行脚本后 hang 住。

解决方法

请确保指定的 IB 网卡之间是可以连通的，具体需要检查：

- 指定的环境变量 NCCL_IB_HCA 中设置的网卡是否互通
- 环境变量 NCCL_SOCKET_IFNAME 和 GLOO_SOCKET_IFNAME 是否和 ifconfig 中的 IB 网卡名称对应
- 如遇到 NVIDIA 设备和天数智芯加速卡需要分别设定 NCCL_IB_HCA 和 NCCL_SOCKET_IFNAME 的情况，可以在脚本 run_ddp_mm() 方法的 if 语句内根据设备类型来分别设置

1.3.3.4 问题 4：使用 IB 网络后执行脚本报错 internal error, NCCL version 2.14.3

问题描述

使用 IB 网络后执行脚本报错：

```
NCCL WARN Call to ibv_modify_qp failed with error Invalid argument
...
NCCL error in: ..... internal error, NCCL version 2.14.3
```

解决方法

请检查容器中是否存在 IB 库 libibverbs.so。

若不存在，可从主机上拷贝至容器中。

1.3.4 LLaMA-Factory 训练报错

1.3.4.1 问题 1：使用 ds_z3_offload_config.json 配置进行训练，出现报错 launcher.py FAILED, exitcode 显示 -9

问题描述

4 机环境下对大模型进行 SFT 全量微调并使用 ds_z3_offload_config.json 配置，出现报错 launcher.py FAILED, exitcode 显示 -9。

解决方法

exitcode 显示 -9，表示主机内存不足导致进程被 kill。在大模型训练时如果使用 ds_z3_offload_config.json 配置，为了确保主机内存够用，建议将主节点的主机内存配置为 1TB。

1.3.4.2 问题 2：训练时提示 peft 版本不对 ImportError: peft>=0.11.1,<=0.12.0 is required for a normal functioning of this module, but found peft==0.10.0

问题描述

在 Docker 镜像中使用 LLaMA-Factory 训练，提示 peft 版本不对 ImportError: peft>=0.11.1,<=0.12.0 is required for a normal functioning of this module, but found peft==0.10.0。

解决方法

LLaMA-Factory 和 TGI 都依赖 peft，但依赖版本不同。在生成 Docker 镜像时，TGI 的安装顺序后于 LLaMA-Factory，因此 peft 被重装，导致 LLaMA-Factory 依赖的 peft 版本不可用，需要您再手动安装一次 (安装开源版本即可)，参考步骤如下：

```
# 安装开源版本 peft
$ pip3 install peft==0.11.1

# 检查 LLaMA-Factory 是否存在依赖问题
$ pip3 check | grep llamafactory
```

1.3.4.3 问题 3：训练时提示环境内未包含适配的 accelerate 库 ImportError:Megatron is not installed.please build it from source

问题描述

在 Docker 镜像中使用 LLaMA-Factory 训练，提示环境内未包含适配的 accelerate 库 ImportError:Megatron is not installed.please build it from source。

解决方法

由于 Docker 镜像中安装了 TGI，会自动安装 accelerate，导致原有的 accelerate 不可用，需要您再手动安装一次 (需安装天数适配版)，参考步骤如下：

```
$ pip3 install accelerate-0.34.2+corex.{v.r.m}-py3-none-any.whl
```

1.3.5 环境相关

1.3.5.1 问题 1：机器重启后训练失败

解决方法

机器重启后网络环境可能发生改变，需要检查以下几个方面：

- 网口名称是否发生变化
- IB/RoCE 网络以及交换机是否正常运行，IB 不通时可以尝试重启 opensmd 服务
- 天数智芯加速卡硬件是否可被正常查询到

1.3.5.2 问题 2：训练时未使用 RMDA，提示 NET/IB No device found

解决方法

- 请确认环境中是否存在 libibverbs.so, libmlx5-rdmacv34.so, libnl*.so 文件，以及是否与主机环境冲突。
- 请确认训练时未强制指定 NCCL_NET=Socket。

1.3.5.3 问题 3：训练时报错 NCCL WARN Call to ibv_create_cq failed with error Cannot allocate memory

解决方法

这是由于分配的主机内存不足。如果是云环境，需要先解除内存限制。

1.3.5.4 问题 4：重装驱动时，itr_peer_mem_drv.ko 无法正常安装

解决方法

首先，确保 IB 卡状态正常。

其次，检查相关头文件路径问题，请使用如下命令设置路径链接：

```
$ ln -s /usr/src/ofa_kernel/x86_64/$(uname -r)/ /etc/alternatives/
↪ ofa_kernel_headers
```

1.3.5.5 问题 5：多机训练在 IB 或 socket 通讯阶段 hang 住，通过 ixSMI 查看加速卡利用率为 0，htop 查看 CPU 利用率为 100%

解决方法

通过 **ibstat** 确认每个服务器的 IB 卡状态是否正常，如果存在异常状态的 IB 卡，可以尝试通过 **service opensmd restart** 指令修复。如不能正常修复，建议更换服务器。

1.3.5.6 问题 6：torchrun 启动训练时直接退出，报错类似 dmesg 出现 Pid xxxx (python3) over core_pipe_limit

问题描述

报错示例如下图所示：

```
> building Llama2Tokenizer tokenizer ...
> padded vocab (size: 32000) with 0 dummy tokens (new size: 32000)
> initializing torch distributed ...
> initialized tensor model parallel with size 4
> initialized pipeline model parallel with size 2
> setting random seeds to 1234 ...
> compiling dataset index builder ...
>>> done with dataset index builder. Compilation time: 0.001 seconds
> compiling and loading fused kernels ...
>>> done with compiling and loading fused kernels. Compilation time: 2.104 seconds
[2024-08-29 13:34:44,520] torch.distributed.elastic.multiprocessing.api: [ERROR] failed (exitcode: -7) local_rank: 0 (pid: 3029251) of binary: /usr/local/bin/python3.10
Traceback (most recent call last):
  File "/usr/local/bin/torchrun", line 8, in <module>
    sys.exit(main())
  File "/usr/local/lib/python3.10/site-packages/torch/distributed/elastic/multiprocessing/errors/__init__.py", line 346, in wrapper
    return f(*args, **kwargs)
  File "/usr/local/lib/python3.10/site-packages/torch/distributed/run.py", line 806, in main
    run(args)
  File "/usr/local/lib/python3.10/site-packages/torch/distributed/run.py", line 797, in run
    elastic_launch(
  File "/usr/local/lib/python3.10/site-packages/torch/distributed/launcher/api.py", line 134, in __call__
    return launch_agent(self._config, self._entrypoint, list(args))
  File "/usr/local/lib/python3.10/site-packages/torch/distributed/launcher/api.py", line 264, in launch_agent
    raise ChildFailedError:
torch.distributed.elastic.multiprocessing.errors.ChildFailedError:
```

图 3: 报错示例

解决方法

该问题产生可能是因为 Docker 容器启动时未添加 `--ipc=host` 参数，请参考以下命令启动 Docker 容器：

```
$ docker run -it --name ${container_name} --privileged --pid=host --ipc=host
  --cap-add=ALL -v /dev:/dev -v /lib/modules:/lib/modules -v /usr/src:/usr/
  src -v /home:/home --network=host ${image_name} /bin/bash
```

1.3.5.7 问题 7：进行大模型训练时发现 hang，报错 iluvatar xxx: pciw outbound complete timeout...

问题描述

进行大模型训练时发现 hang，同时 dmesg 中报错 iluvatar xxx: pciw outbound complete timeout: complete teg 0, complete length 64 (or 32), attr 0。其中，xxx 为天数智芯加速卡对应的 BDF。

问题分析

产生上述报错，说明链路的 timeout 时间设置过短，需要对 PCIe 链路进行 disable 操作。**注意，disable PCIe 链路具有一定风险，请按需决定是否需要进行。**

解决方法

向您的应用工程师获取 `change_timeout_dis.sh` 脚本并执行该脚本。

Note

执行 `change_timeout_dis.sh` 脚本需要 root 权限，且执行前需要为脚本加权限 `sudo chmod a + x change_timeout_dis.sh`。

商标声明

- 天数智芯、天数智芯 logo、Iluvatar CoreX 等商标、标识、组合商标为上海天数智芯半导体有限公司之注册商标或商标，受法律保护。
- CentOS 标识为 Red Hat 公司的商标。
- Docker 为 Docker 公司在美国和其他国家的商标或注册商标。
- Linux 为 Linus Torvalds 在美国和其它国家的注册商标。
- NVIDIA、CUDA、GeForce 和 GeForce GTX 为 NVIDIA 公司在美国和/或其它国家的商标和/或注册商标。
- PyTorch 为 Facebook 公司的商标。
- TensorFlow 为 Google 公司的商标。
- Ubuntu 为 Canonical 公司的注册商标。

除上述明确列出的商标外，本内容中可能存在的任何其他未明示的产品名称、服务名称、企业名称、标识、口号、域名或其他商业标记 (无论是否标注 ™ 或 ® 符号)，均假定归属于其各自合法的商标权人所有。