



天数智芯
Iluvatar CoreX

天数智芯

天数智芯加速卡大模型推理测试参考指南

版本：V4.3.0 (x86)|V4.3.6 (ARM)

日期：2025.7.22

适用产品：天垓 150| 智铠 100| 智铠 100 DUO

声明

版权与保密声明

本文档（属未发表作品）版权归属于天数智芯全权所有，且本声明不构成对本文档已发表的承认。本文档所载全部信息均为天数智芯保密信息（包括但不限于天数智芯技术信息、经营信息、专属于接收方的未公开资料等）。未经天数智芯事先书面许可，严禁任何形式的使用、复制、传播、转录或翻译。

免责声明

天数智芯可以随时对本文档或本文档中描述的产品进行改进和/或更改。本文档包括与天数智芯产品有关的信息，作为说明典型应用的一种方式，因此，不一定提供足以进行生产设计的完整信息。对于本文档中内容的准确性或完整性，天数智芯不做任何陈述或保证。

联系方式

地址：上海闵行区陈行公路 2168 号 3 幢

电话：021-68886607

网址：www.iluvatar.com

目录

1 天数智芯加速卡大模型推理测试参考指南	4
1.1 修订记录	4
1.2 软硬件推荐配置	4
1.3 部署 TGI 框架下的大模型测试环境	6
1.3.1 Qwen2.5-7B-Instruct 测试步骤	6
1.4 部署 vLLM 框架下的大模型测试环境	7
1.4.1 LLaMA3.1-70B-Instruct W8A8 测试步骤	7
1.4.2 Mixtral-8x22B-W8A8 测试步骤	8
1.4.3 InternVL2-26B 测试步骤	8
1.4.4 Qwen2.5-72B-Instruct 测试步骤	8
1.4.5 Qwen2.5-72B-Instruct W8A8 测试步骤	8
1.4.6 Qwen2.5-72B-Instruct-GPTQ-Int4 测试步骤	9
1.4.7 Qwen2.5-72B-Instruct-AWQ-Int4 测试步骤	9
1.4.8 Qwen2.5-14B-Instruct 测试步骤	10
1.4.9 Qwen2-VL-7B 测试步骤	10
1.4.10 Yi-1.5-34B-Chat 测试步骤	10
1.4.11 DeepSeek-R1-W4A8 测试步骤	10
1.5 部署 Diffusers 框架下的大模型测试环境	11
1.5.1 Stable Diffusion3 测试步骤	12

1 天数智芯加速卡大模型推理测试参考指南

本指南提供在天数智芯加速卡上进行大模型推理测试的详细步骤。

1.1 修订记录

- COREX01-MR430-RF03-01：2025/7/22
 - 新增**DeepSeek-R1-W4A8 测试步骤**
- COREX01-MR430-RF03-00：2025/6/30
 - 部署 **vLLM 框架下的大模型测试环境**，删除 LLaMA2-7B/LLaMA2-13B/ChatGLM2-6B 模型测试示例
 - 更新**Qwen2-VL-7B 测试步骤**
 - 更新**Stable Diffusion3 测试步骤**
- COREX01-MR420-RF03-00：2025/1/24
 - 更新部署 **TGI 框架下的大模型测试环境** 提供的模型测试示例
 - 更新部署 **vLLM 框架下的大模型测试环境** 提供的模型测试示例
 - 删除“部署 TensorRT-LLM 框架下的大模型测试环境”，本次发布包中不含该类模型
- COREX01-MR412-RF03-01：2024/9/20
 - “Qwen1.5-110B 测试步骤”，提示 Qwen1.5-110B 模型推理需要使用 16 张智铠 100 加速卡
 - 部署 **vLLM 框架下的大模型测试环境**，更新 LLaMA2-7B-lora 模型推理需要用到的权重文件
- COREX01-MR412-RF03-00：2024/9/2
 - 更新本次发布测试所包含的大模型及对应测试步骤
 - 更新本次发布测试的**软硬件推荐配置**
- COREX01-MR400-RF03-00：2024/4/12

文档本次发布内容与 V3.2.1-MR 文档相比 (COREX01-MR321-RF03-00)，有以下更新：

 - 更新本次发布测试所包含的大模型
 - 更新本次发布测试的**软硬件推荐配置**
 - 更新“部署测试环境”和“测试步骤”

1.2 软硬件推荐配置

表 1: 天垓 150 加速卡硬件推荐配置

硬件	型号与要求
显卡	BI-V150 * 8

硬件	型号与要求
主机	新华三 R5300 G5
芯片	Intel(R) Xeon(R) Platinum 8380 CPU @ 2.30GHz * 2
内存	1TB DDR4
网卡	ETH 网卡: H3C NIC-ETH561F-3S-2P * 1, H3C UNIC-NIC-GE-4P-360T-B2 * 1; IB 网卡: CX555A - ConnectX-5 QSFP28 * 2

表 2: 智铠 100 加速卡硬件推荐配置

硬件	型号与要求
显卡	MR-V100 * 8 (Qwen1.5-110B 模型推理需要 16 张加速卡)
主机	浪潮 SSINSPURMBX-XI6-E711
芯片	Intel(R) 6630 CPU @ 2.0GHz * 2
内存	512 GiB: 64 GiB DDR4 * 8
网卡	Intel Corporation 82599ES 10-Gigabit SFI/SFP+ Network Connection (rev 01) * 1

表 3: 软件推荐配置

软件	版本与要求
OS	Docker: Ubuntu 20.04.6 LTS
Kernel	5.4.0-174-generic
GPU Driver	天数智芯加速卡驱动 v4.3.0
SDK	天数智算软件栈 v4.3.0
CUDA	v10.2
Python	v3.10
PyTorch	天数智芯适配版 v2.4.1
Transformers	>=v4.40.0
Ray	>=v2.9.0
vLLM	天数智芯适配版 v0.8.3

软件	版本与要求
TGI	天数智芯适配版 v2.1.1
ixFormer	v0.6.0
TensorRT-LLM	天数智芯适配版 v0.12.0

1.3 部署 TGI 框架下的大模型测试环境

请您按照以下要求完成测试环境的部署：

- 参考《软件栈安装指南》安装天数智芯加速卡驱动，并以 Docker 安装方式安装天数智算软件栈
- 进入 Docker 容器并安装以下依赖包 (登录 [天数智芯官网](#)，进入 **客户支持** > **资源中心** 页面进行下载)：
 - text-generation-inference-2.1.1.run
 - llm-inference-benchmark-corex-{v.r.m}.run
- 下载并解压数据集：<https://huggingface.co/datasets/THUDM/LongBench/resolve/main/data.zip>

执行以下命令：

```
$ docker exec -it {your_test_container} /bin/bash
$ cd /root
$ bash text-generation-inference-2.1.1.run
$ bash llm-inference-benchmark-corex-{v.r.m}.run
```

Note

以下是模型权重文件下载链接 (需要注册并向 Meta Website 申请方可下载)：

- Qwen2.5-7B-Instruct: <https://huggingface.co/Qwen/Qwen2.5-7B-Instruct>

若无法访问，可以向您的应用工程师获取以上文件。

1.3.1 Qwen2.5-7B-Instruct 测试步骤

```
$ cd /root/llm-inference-benchmark/tgi
$ bash test_perf.sh --model-id /path/to/model --sharded false --disable-custom-kernels
↪ --port 8001 --max-input-length 6144 --max-batch-prefill-tokens 8192
↪ --max-total-tokens 20000 --max-batch-total-tokens 20000 --cuda-memory-fraction 0.95
↪ --cuda-graphs 0, --host localhost --port 8001 --model2path /path/to/model --batchsize
↪ 10 --n-runs 1 --input-tokens 2048 --generate-tokens 1024
```

1.4 部署 vLLM 框架下的大模型测试环境

请您按照以下要求完成测试环境的部署：

- 参考《软件栈安装指南》安装天数智芯加速卡驱动，并以 Docker 安装方式安装天数智算软件栈
- 进入 Docker 容器并安装以下依赖包 (登录 [天数智芯官网](#)，进入 **客户支持** > **资源中心** 页面进行下载)：
 - llm-inference-benchmark-corex-{v.r.m}.run
 - vLLM 在安装天数智算软件栈时已内置 (Docker 安装方式)
- 下载并解压数据集：<https://huggingface.co/datasets/THUDM/LongBench/resolve/main/data.zip>

执行以下命令：

```
$ docker exec -it {your_test_container} /bin/bash
$ cd /root
$ bash llm-inference-benchmark-corex-{v.r.m}.run
```

Note

以下是模型权重文件下载链接 (需要注册并向 Meta Website 申请方可下载)：

- LLaMA3.1-70B-Instruct: <https://huggingface.co/meta-llama/Llama-3.1-70B-Instruct>
- InternVL2-26B: <https://huggingface.co/OpenGVLab/InternVL2-26B>
- Qwen: <https://huggingface.co/Qwen>
- Yi-1.5-34B: <https://huggingface.co/01-ai/Yi-1.5-34B-Chat>

若无法访问，可以向您的应用工程师获取以上文件。

1.4.1 LLaMA3.1-70B-Instruct W8A8 测试步骤

1. 下载并量化数据集：

```
$ mkdir -p /home/data/nlp
$ cd /home/data/nlp

# 向您的应用工程师获取 ultrachat_200k.tar.gz 文件
$ tar -xvf ultrachat_200k.tar.gz
```

2. 量化权重：

```
$ python3 quantize_w8a8.py \
  --model /path/to/model \
  --dataset-path /home/data/nlp/ultrachat_200k \
  --num-samples 32 \
  --model-type llama
```

Note

- W8A8 权重保存名称以 -W8A8-Dynamic-Per-Token 结尾
- 若权重量化遇阻，可以联系您的应用工程师获取已量化权重

3. 运行 LLaMA3.1-70B-Instruct W8A8 测试:

```
$ cd /root/llm-inference-benchmark/vllm
$ bash test_performance_server.sh --model /path/to/model -tp 4 --host 127.0.0.1
↪ --port 12345 --max-num-seqs 1 --max-num-batched-tokens 20480 --max-model-len
↪ 20480,--model /path/to/model --host 127.0.0.1 --port 12345 --num-prompts 10
↪ --input-tokens 2048 --output-tokens 1024
```

1.4.2 Mixtral-8x22B-W8A8 测试步骤

```
$ cd /root/llm-inference-benchmark/vllm
$ bash test_performance_server.sh --model /path/to/model -tp 8 --host 127.0.0.1 --port
↪ 12345 --enable-chunked-prefill=False --max-num-seqs 1 --max-num-batched-tokens 20480
↪ --max-model-len 20480,--model /path/to/model --host 127.0.0.1 --port 12345
↪ --num-prompts 10 --input-tokens 2048 --output-tokens 1024
```

1.4.3 InternVL2-26B 测试步骤

```
$ cd /root/llm-inference-benchmark/vllm
$ bash test_performance_server_multimodal.sh --model /path/to/model -tp 4 --max-num-seqs 1
↪ --max-num-batched-tokens 8192 --max-model-len 8192 --host 127.0.0.1 --port 12345
↪ --trust-remote-code,--model /path/to/model --host 127.0.0.1 --port 12345
↪ --num-prompts 1 --output-tokens 128 --image-path test.jpg --trust-remote-code true
↪ --image-size "512,512"
```

1.4.4 Qwen2.5-72B-Instruct 测试步骤

```
$ cd /root/llm-inference-benchmark/vllm
$ bash test_performance_server.sh --model /path/to/model -tp 8 --host 127.0.0.1 --port
↪ 12345 --max-num-batched-tokens 20480 --max-num-seqs 1 --max-model-len 20480,--model /
↪ path/to/model --host 127.0.0.1 --port 12345 --num-prompts 10 --input-tokens 2048
↪ --output-tokens 1024
```

1.4.5 Qwen2.5-72B-Instruct W8A8 测试步骤

1. 下载并量化数据集:

```
$ mkdir -p /home/data/nlp
$ cd /home/data/nlp
```

```
# 向您的应用工程师获取 ultrachat_200k.tar.gz 文件
$ tar -xvf ultrachat_200k.tar.gz
```

2. 量化权重:

```
$ python3 quantize_w8a8.py \
  --model /path/to/model \
  --dataset-path /home/data/nlp/ultrachat_200k \
  --num-samples 32 \
  --model-type qwen
```

Note

- W8A8 权重保存名称以 -W8A8-Dynamic-Per-Token 结尾
- 若权重量化遇阻，可以联系您的应用工程师获取已量化权重

3. 运行 Qwen2.5-72B-Instruct W8A8 测试:

```
$ cd /root/llm-inference-benchmark/vllm
$ bash test_performance_server.sh --model /path/to/model -tp 4 --host 127.0.0.1
↪ --port 12345 --max-num-batched-tokens 20480 --max-num-seqs 1 --max-model-len
↪ 20480,--model /path/to/model --host 127.0.0.1 --port 12345 --num-prompts 10
↪ --input-tokens 2048 --output-tokens 1024
```

1.4.6 Qwen2.5-72B-Instruct-GPTQ-Int4 测试步骤

```
$ cd /root/llm-inference-benchmark/vllm

# TP 2
$ VLLM_RPC_TIMEOUT=100000 bash test_performance_server.sh --model /path/to/model
↪ --quantization gptq -tp 2 --host 127.0.0.1 --port 12345 --max-num-batched-tokens 20480
↪ --max-num-seqs 1 --max-model-len 20480,--model /path/to/model --host 127.0.0.1 --port
↪ 12345 --num-prompts 10 --input-tokens 2048 --output-tokens 1024

# TP 4
$ VLLM_RPC_TIMEOUT=100000 bash test_performance_server.sh --model /path/to/model
↪ --quantization gptq -tp 4 --host 127.0.0.1 --port 12345 --max-num-batched-tokens 20480
↪ --max-num-seqs 1 --max-model-len 20480,--model /path/to/model --host 127.0.0.1 --port
↪ 12345 --num-prompts 10 --input-tokens 2048 --output-tokens 1024
```

1.4.7 Qwen2.5-72B-Instruct-AWQ-Int4 测试步骤

```
$ cd /root/llm-inference-benchmark/vllm

# TP 2
$ VLLM_RPC_TIMEOUT=100000 bash test_performance_server.sh --model /path/to/model
↪ --quantization awq -tp 2 --host 127.0.0.1 --port 12345 --max-num-batched-tokens 20480
↪ --max-num-seqs 1 --max-model-len 20480,--model /path/to/model --host 127.0.0.1 --port
COREX2045MR430-RF03-01 10 --input-tokens 2048 --output-tokens 1024 V4.3.0 (x86)|V4.3.6 (ARM)
```

```
# TP 4
$ VLLM_RPC_TIMEOUT=100000 bash test_performance_server.sh --model /path/to/model
↪ --quantization awq -tp 4 --host 127.0.0.1 --port 12345 --max-num-batched-tokens 20480
↪ --max-num-seqs 1 --max-model-len 20480, --model /path/to/model --host 127.0.0.1 --port
↪ 12345 --num-prompts 10 --input-tokens 2048 --output-tokens 1024
```

1.4.8 Qwen2.5-14B-Instruct 测试步骤

```
$ cd /root/llm-inference-benchmark/vllm
$ bash test_performance_server.sh --model /path/to/model -tp 2 --host 127.0.0.1 --port
↪ 12345 --max-num-batched-tokens 20480 --max-num-seqs 1 --max-model-len 20480, --model /
↪ path/to/model --host 127.0.0.1 --port 12345 --num-prompts 10 --input-tokens 2048
↪ --output-tokens 1024
```

1.4.9 Qwen2-VL-7B 测试步骤

```
$ cd /root/llm-inference-benchmark/vllm

# 准备环境
$ pip3 install jieba fuzzywuzzy aioprometheus rouge

# 运行测试
$ bash test_vllm_longbench.sh --model-name qwen2-vl-chat --model /path/to/model --datapath
↪ /path/to/data -tp 1 --max-model-len 32768 --dtype bfloat16 --max-num-seqs 16
↪ --val-data-nums 1 --temperature 0.0 --max-num-batched-tokens 32768 --trust-remote-code
```

1.4.10 Yi-1.5-34B-Chat 测试步骤

```
$ cd /root/llm-inference-benchmark/vllm
$ bash test_performance_server.sh --model /path/to/model -tp 4 --host 127.0.0.1 --port
↪ 12345 --max-num-batched-tokens 20480 --max-num-seqs 1, --model /path/to/model --host
↪ 127.0.0.1 --port 12345 --num-prompts 10 --input-tokens 2048 --output-tokens 1024
```

1.4.11 DeepSeek-R1-W4A8 测试步骤

开启 CUDA Graph 可进一步提升推理吞吐量。下面将以 DeepSeek-R1-W4A8 模型为例，提供开启 CUDA Graph 并进行模型推理的操作步骤。

1. 环境变量配置：

```
# 开启 CUDA Graph
$ export VLLM_ENFORCE_CUDA_GRAPH=1

# 其它环境变量配置
$ export VLLM_ENGINE_ITERATION_TIMEOUT_S=36000
$ export VLLM_RPC_TIMEOUT=36000000
$ export VLLM_W8A8_MOE_USE_W4A8=1
$ export VLLM_PP_LAYER_PARTITION="16,16,16,13"

# 当使用 PP2 测试时，请 export 以下环境变量
$ export VLLM_PP_LAYER_PARTITION="31,30"
```

2. 运行 DeepSeek-R1-W4A8 测试，以 input128,output128,bs1 为例，模型权重路径为 --model /path/to/model \。

```
# 服务端
$ vllm serve /path/to/model --trust_remote_code --pipeline_parallel_size=4
↪ --tensor_parallel_size=4 --max_model_len 8192 --max-num-seqs 1
↪ --gpu-memory-utilization 0.95

# 客户端
# 向您的应用工程师获取 benchmark_serving_contain_min.py 文件
$ python3 benchmark_serving_contain_min.py --num-prompts 1 --model path/to/model
↪ --input-tokens 128 --output-tokens 128 --host 0.0.0.0 --port 8000
```

Note

目前基于 vLLM 框架支持启用 CUDA Graph 配置的大模型列表如下：

- DeepSeek-R1-W4A8
- DeepSeek-R1 蒸馏
- Qwen3-32B
- Qwen2.5-VL
- QwQ-32B
- GLM-4-9b-chat
- Qwen1.5-32B
- ChatGLM2-6B
- Baichuan2-13B
- LLaMA2-70B

1.5 部署 Diffusers 框架下的大模型测试环境

请您按照以下要求完成测试环境的部署：

- 参考《软件栈安装指南》安装天数智芯加速卡驱动，并以 Docker 安装方式安装天数智算软件栈
- 进入 Docker 容器并安装以下依赖包 (登录 [天数智芯官网](#)，进入 **客户支持** > **资源中心** 页面进行下载):
 - llm-inference-benchmark-corex-{v.r.m}.run

执行以下命令：

```
$ docker exec -it {your_test_container} /bin/bash
$ cd /root
$ bash llm-inference-benchmark-corex-{v.r.m}.run
```

Note

以下是模型权重文件下载链接 (需要注册并向 Meta Website 申请方可下载)：

- Stable Diffusion3: <https://huggingface.co/stabilityai/stable-diffusion-3-medium-diffusers/tree/main>

若无法访问，可以向您的应用工程师获取以上文件。

1.5.1 Stable Diffusion3 测试步骤

```
$ cd /root/llm-inference-benchmark/diffusers
```

准备环境

```
$ pip3 install diffusers-{version}+corex.{v.r.m}-py3-none-any.whl # 向您的应用工程师获取该
↔ whl 包
```

```
$ pip3 uninstall apex
```

运行测试

```
$ python3 demo_sd3.py
```

商标声明

- 天数智芯、天数智芯 logo、Iluvatar CoreX 等商标、标识、组合商标为上海天数智芯半导体有限公司之注册商标或商标，受法律保护。
- CentOS 标识为 Red Hat 公司的商标。
- Docker 为 Docker 公司在美国和其他国家的商标或注册商标。
- Linux 为 Linus Torvalds 在美国和其它国家的注册商标。
- NVIDIA、CUDA、GeForce 和 GeForce GTX 为 NVIDIA 公司在美国和/或其它国家的商标和/或注册商标。
- PyTorch 为 Facebook 公司的商标。
- TensorFlow 为 Google 公司的商标。
- Ubuntu 为 Canonical 公司的注册商标。

除上述明确列出的商标外，本内容中可能存在的任何其他未明示的产品名称、服务名称、企业名称、标识、口号、域名或其他商业标记 (无论是否标注 ™ 或 ® 符号)，均假定归属于其各自合法的商标权人所有。