



天数智芯
Iluvatar CoreX

天数智芯

推理示例模型使用指南

版本：V4.3.0 (x86)|V4.3.6 (ARM)

日期：2025.6.30

适用产品：天垓 150 | 智铠系列

声明

版权与保密声明

本文档（属未发表作品）版权归属于天数智芯全权所有，且本声明不构成对本文档已发表的承认。本文档所载全部信息均为天数智芯保密信息（包括但不限于天数智芯技术信息、经营信息、专属于接收方的未公开资料等）。未经天数智芯事先书面许可，严禁任何形式的使用、复制、传播、转录或翻译。

免责声明

天数智芯可以随时对本文档或本文档中描述的产品进行改进和/或更改。本文档包括与天数智芯产品有关的信息，作为说明典型应用的一种方式，因此，不一定提供足以进行生产设计的完整信息。对于本文档中内容的准确性或完整性，天数智芯不做任何陈述或保证。

联系方式

地址：上海闵行区陈行公路 2168 号 3 幢

电话：021-68886607

网址：www.iluvatar.com

目录

1 推理示例模型使用指南	4
1.1 修订记录	4
1.2 安装推理示例模型	4
1.2.1 开始之前	4
1.2.1.1 安装软件栈和深度学习框架	4
1.2.1.2 安装示例脚本	4
1.2.2 安装步骤	5
1.3 推理示例模型脚本概览	6
1.4 推理模型测试步骤示例	6
1.5 常见问题	7

1 推理示例模型使用指南

1.1 修订记录

- COREX01-BI430-UG09-01: 2025/6/30
 - 更新推理示例模型脚本概览
 - 更新推理模型测试步骤示例
 - 更新可使用的数据集为 corex-inference-data-4.0.0.tar
- COREX01-BI420-UG09-01: 2025/3/21
 - 更新解压 inferencesamples-{v.r.m}.tgz 后 inferencesamples 的存放目录
- COREX01-BI420-UG09-00: 2025/1/24
 - 更新天数智芯推理示例脚本压缩包为 inferencesamples-{v.r.m}.tgz
 - 新增常见问题
- COREX01-BI411-UG09-00: 2024/8/26
 - 提供安装推理示例模型的步骤说明
- COREX01-BI410-UG09-00: 2024/6/30
 - 无内容更新
- COREX01-BI340-UG09-01: 2024/4/8
 - 修改 _tensorrt 接口为 _ixrt。

1.2 安装推理示例模型

1.2.1 开始之前

1.2.1.1 安装软件栈和深度学习框架

按照《软件栈安装指南》完成以下前置条件：

- 安装天数智算软件栈
- 安装天数智芯适配版深度学习框架

1.2.1.2 安装示例脚本

Note

- 本文中，安装包和路径中的“{v.r.m}”表示待安装的示例脚本和测试数据集的版本号。
- 本文中，安装包和路径中的“{ARCH}”表示示例脚本安装包适用的架构，与您当前设备环境的架构保持一致。

安装示例脚本，请先确保以下准备工作已完成：

- CMake 版本不低于 v3.16
- unzip
- pip3 并通过 **sudo pip3 install --upgrade pip** 升级到新版本，以避免运行网络模型推理示例脚本出现报错
- 确保您的安装环境可以访问外网
- 通过以下方式获取安装示例脚本 `inferencesamples-{v.r.m}.tgz`:
 - 登录 [天数智芯官网](#)，进入 **客户支持 > 资源中心** 页面进行下载
 - 联系您的应用工程师获取

参考如下步骤安装示例脚本：

安装示例脚本 `inferencesamples-{v.r.m}.tgz`：

```
$ tar -xvf inferencesamples-{v.r.m}.tgz
```

Tip

- 为确保可以顺利使用测试数据集，请选择空间足够大的 `{COREX_SAMPLES_PATH}`。
- 解压后的 `inferencesamples` 将存放在 `inferencesamples-{v.r.m}.tgz` 包所在目录。

1.2.2 安装步骤

1. 移动推理测试数据集 `corex-inference-data-4.0.0.tar` 至 `${path_to_package}/inferencesamples`

- 向您的应用工程师获取推理测试数据集 `corex-inference-data-4.0.0.tar`
- 您可以使用 v4.0.0 版本的数据集进行测试，于当前软件栈版本无影响

2. 解压推理测试数据集：

```
$ cd ${path_to_package}/inferencesamples
$ sudo tar xf corex-inference-data-4.0.0.tar
```

推理测试数据集中还包括模型权重和 whl 包，文件较大，解压耗时可能较长，请您耐心等待。

3. 准备环境：

```
$ cd ${path_to_package}/inferencesamples
$ bash quick_build_environment.sh # 运行推理示例脚本前准备环境
```

该脚本会解压数据集并安装必要的一些包。

4. 请您根据实际需要运行对应的模型初始化脚本 `init.sh`：

```
$ cd ${path_to_package}/inferencesamples/executables/${model}
$ bash init.sh # 运行推理初始化脚本
```

`${model}` 可选值可通过 **tree** 命令查询。

1.3 推理示例模型脚本概览

本次发布提供以下推理示例模型的演示脚本（“/”表示暂未提供对应精度的演示脚本）：

模型	INT8	FP16
BERT-Base	/	支持
BERT-Large	支持	支持
Conformer	/	支持
ResNet50	支持	支持
Transformer	/	支持
VGG16	支持	/
YOLOv3	支持	/
YOLOv5s	/	支持
YOLOv5m	支持	/
YOLOv7	支持	/
YOLOX-m	支持	/

演示脚本命名含义如下：

- `_int8_` 表示精度为 INT8，`_fp16_` 表示精度为 FP16。
- 验证精度或性能：
 - `_accuracy` 以验证精度为主，脚本会把验证集完整跑一遍，得到模型在验证集上的精度。
 - `_performance` 以验证性能为主，会跑若干样本，得到一个 fps 值。
- `_ixrt` 表示使用 IxRT 接口进行推理。

1.4 推理模型测试步骤示例

1. 以使用 ResNet50 模型并使用 IGIE 接口验证在 INT8 精度上的推理性能为例，运行以下演示脚本：

```
$ cd ${path_to_package}/inferencesamples/executables/resnet
$ bash init.sh
$ bash infer_resnet50_int8_performance_igie.sh
```

2. 以使用 ResNet50 模型并使用 IxRT 接口验证在 INT8 精度上的推理性能为例，运行以下演示脚本：

```
$ cd ${path_to_package}/inferencesamples/executables/resnet
$ bash init.sh
$ bash infer_resnet50_int8_performance_ixrt.sh
```

3. 以使用 ResNet50 模型并使用 IGIE 接口验证在 FP16 精度上的验证精度为例，运行以下演示脚本：

```
$ cd ${path_to_package}/inferencesamples/executables/resnet
$ bash init.sh
$ bash infer_resnet50_fp16_accuracy_igie.sh
```

4. 以使用 ResNet50 模型并使用 IxRT 接口验证在 FP16 精度上的推理性能为例，运行以下演示脚本：

```
$ cd ${path_to_package}/inferencesamples/executables/resnet
$ bash init.sh
$ bash infer_resnet50_fp16_accuracy_ixrt.sh
```

1.5 常见问题

问题 1：通过 Docker 镜像生成天数智算软件栈后，运行 Conformer 模型进行推理，出现报错 WARNING:root:Failed to read

问题描述

使用 corex-docker-installer 生成天数智算软件栈镜像后，运行 Conformer 模型进行推理，出现报错 WARNING:root:Failed to read。

问题分析

缺少必要的依赖包 sox 和 libsox-fmt-all。

解决方法

执行 **apt install sox libsox-fmt-all** 命令后，再次运行 Conformer 模型进行推理。

商标声明

- 天数智芯、天数智芯 logo、Iluvatar CoreX 等商标、标识、组合商标为上海天数智芯半导体有限公司之注册商标或商标，受法律保护。
- CentOS 标识为 Red Hat 公司的商标。
- Docker 为 Docker 公司在美国和其他国家的商标或注册商标。
- Linux 为 Linus Torvalds 在美国和其它国家的注册商标。
- NVIDIA、CUDA、GeForce 和 GeForce GTX 为 NVIDIA 公司在美国和/或其它国家的商标和/或注册商标。
- PyTorch 为 Facebook 公司的商标。
- TensorFlow 为 Google 公司的商标。
- Ubuntu 为 Canonical 公司的注册商标。

除上述明确列出的商标外，本内容中可能存在的任何其他未明示的产品名称、服务名称、企业名称、标识、口号、域名或其他商业标记 (无论是否标注 ™ 或 ® 符号)，均假定归属于其各自合法的商标权人所有。