



天数智芯
Iluvatar CoreX

天数智芯

版本发布说明

版本：V4.3.0 (x86) | V4.3.6 (ARM)

日期：2025.7.24

适用产品：天垓 150 | 智铠系列

声明

版权与保密声明

本文档（属未发表作品）版权归属于天数智芯全权所有，且本声明不构成对本文档已发表的承认。本文档所载全部信息均为天数智芯保密信息（包括但不限于天数智芯技术信息、经营信息、专属于接收方的未公开资料等）。未经天数智芯事先书面许可，严禁任何形式的使用、复制、传播、转录或翻译。

免责声明

天数智芯可以随时对本文档或本文档中描述的产品进行改进和/或更改。本文档包括与天数智芯产品有关的信息，作为说明典型应用的一种方式，因此，不一定提供足以进行生产设计的完整信息。对于本文档中内容的准确性或完整性，天数智芯不做任何陈述或保证。

联系方式

地址：上海闵行区陈行公路 2168 号 3 幢

电话：021-68886607

网址：www.iluvatar.com

目录

1 版本发布说明	4
1.1 修订记录	4
1.2 Version 4.3.0-x86/4.3.6-ARM	5
1.3 Version 4.2.1	10
1.4 Version 4.2.0	10
1.5 Version 4.1.1-SP1	15
1.6 Version 4.1.1	15
1.7 Version 4.1.0	16
1.8 Version 3.4.0	17
1.9 Version 3.3.0	19

1 版本发布说明

1.1 修订记录

- COREX01-BI430-RN01-01: 2025/7/24
 - 提供 V4.3.6-ARM 版本发布说明, 功能与 V4.3.0-x86 基本保持一致, 详见Version 4.3.0-x86/4.3.6-ARM
- COREX01-BI430-RN01-00: 2025/6/30
 - 新增"Version 4.3.0", 提供 V4.3.0 的版本发布说明, 该软件栈版本同时适用于天垓 150 加速卡和智铠系列加速卡
- COREX01-BI421-RN01-00: 2025/4/15
 - 新增Version 4.2.1, 提供 V4.2.1 的版本发布说明, 该软件栈版本同时适用于天垓 150 加速卡和智铠 50/100 加速卡
- COREX01-BI420-RN01-00: 2025/1/24
 - 新增Version 4.2.0, 提供 V4.2.0 的版本发布说明, 该软件栈版本同时适用于天垓 150 加速卡和智铠 50/100 加速卡
- COREX01-BI411SP1-RN01-00: 2024/11/28
 - 新增Version 4.1.1-SP1, 提供 V4.1.1-SP1-BI150 的版本发布说明
- COREX01-BI411-RN01-00: 2024/8/26
 - 新增Version 4.1.1, 提供 V4.1.1-BI150 的版本发布说明
 - 删除"发布 whl 包说明", whl 包详情可登录 [天数智芯官网](#), 在 **客户支持 > 资源中心** 页面查看
- COREX01-BI410-RN01-00: 2024/6/30
 - 更新"发布 whl 包说明"
 - 新增Version 4.1.0, 提供 V4.1.0-BI150 的版本发布说明
- COREX01-BI340-RN01-01: 2024/4/12
 - 新增 K8s 插件更新项, 更新 iluvatar-device-plugin.yaml 配置文件内容
 - 新增《天数智芯加速卡 K8s 插件使用指南》文档更新项:
 - * 软件栈版本为 V3.4.0 及以上时, K8s 插件查询地址为 <https://hub.docker.com/r/iluvatarcorex/ix-device-plugin/tags>
 - * 软件栈版本低于 V3.4.0 时, K8s 插件查询地址为 <https://hub.docker.com/r/iluvatarcorex/k8s-device-plugin/tags>
- COREX01-BI340-RN01-00: 2024/3/25

文档本次发布内容与 V3.3.0-BI150 文档相比 (COREX01-BI330-RN01-00), 有以下更新:

 - 新增"发布 whl 包说明", 提供软件栈配套发布的各 whl 包的详情和依赖说明
 - 新增Version 3.4.0, 提供 V3.4.0-BI150 的版本发布说明

1.2 Version 4.3.0-x86/4.3.6-ARM

天数智算软件栈 V4.3.0-x86 和 V4.3.6-ARM 版本同时适用于天垓 150 加速卡和智铠系列加速卡。

在天数智算软件栈 V4.3.0-x86 和 V4.3.6-ARM 版本中，提供了以下功能增强和更新：

- IxFormer v0.6.0
 - FMHA 支持更多场景
 - 优化 MLA
 - 新增 w4a8, AWQ 支持
 - 优化 w8a8 实现
- vLLM v0.8.3
 - vLLM 适配从 0.6.3 升级至 v0.8.3，版本升级包含前版本功能
 - 支持 INT8 MLA 实现，支持 MTP
- (仅支持 x86 架构) TensorRT-LLM v0.12.0
 - 完善对 ixRT v1.0.0 的新架构版本调用，更新接口

Note

ARM 架构暂不支持 TensorRT-LLM。

- IGIE v0.18.1
 - IGIE 升级至 v0.18.1
 - 增加 FMHA, Concat 融合算子模板实现
 - 增加 ixinfer conv3d 实现
 - 增加新的融合 pattern
 - 适配 ixRT v1.0.0 新版本架构
- ixRT v1.0.0
 - ixRT 升级至 v1.0.0
 - 适配 TensorRT v8.4 至 v10.8 的核心功能接口
- Inference Samples
 - 更新模型脚本以适配新版本推理引擎
- ONNXRuntime v1.17.1
 - 补充调用 ixRT v1.0.0 新架构的方式
- IxStream v1.2.7
 - 增加 DCF 算法支持
 - 增加时间戳机制
 - Gst-IxVpuDecode 插件新增 **low-latency-mode** 属性，增加对 IPPP 帧输入的低延迟处理支持
 - 增加 NV12 格式支持
- ixTE (ix-TransformerEngine) v1.1.0
 - ixTE 从 v0.2.4 升级至 v1.1.0

- 适配 nvTE v2.1 版本的新功能和 API
- 为 SparseMLP 支持 Swiglu 激活函数
- 支持 Megatron-LM v0.11.0 版本调用
- 适配 FP8 相关功能实现
- Megatron-LM v0.11.0
 - Megatron-LM 从 v0.8.0 升级至 v0.11.0
 - 支持 MLA
- Megatron-DeepSpeed v2.6.0
 - Megatron-DeepSpeed 适配从 v2.5.0 升级至 v2.6.0
 - 适配 Megatron-LM v0.11.0
- DeepSpeed v0.16.4
 - DeepSpeed 适配从 v0.15.3 升级至 v0.16.4
- Colossal-AI v0.4.8
 - Colossal-AI 适配从 v0.4.4 升级至 v0.4.8
- Flash-Attention v2.6.3
 - 支持调用 ixAttention-Backend 库
- ixHetero v0.1.0
 - 新增非侵入式混训实现
 - 优化混训效果
- LLaMa-Factory v0.9.2
 - LLaMa-Factory 适配从 v0.9.0 升级至 v0.9.2
- PyTorch v2.4.1
 - 对接编译器升级
 - 支持调用 ixAttention-Backend 库
 - 适配 ixCC 新版编译器
- PaddlePaddle v3.0.0 Beta
 - PaddlePaddle 适配从 v2.5.2 升级至 v3.0.0 Beta
 - 适配 ixCC 新版编译器
- TensorFlow v2.16.2
 - TensorFlow 适配从 v2.12.0 升级至 v2.16.2
 - 适配 ixCC 新版编译器
- Triton v3.1.0
 - Triton 适配从 v2.1.0 升级至 v3.1.0
 - 适配 ixCC 新版编译器
- Deeplearning Samples

- 调整优化部分模型脚本
- ixInfer v4.3.0
 - 新增支持 CUDA Graph 相关算子
 - 新增支持 Flash-Attention INT8 相关算子
- ixDNN v4.3.0
 - 增加支持 BF16 conv3d 算子
 - 增加支持 FP32 NHWC/NCHW 格式
 - 新增 bwd filter depthwise 半精算法
 - convFwd 算法支持 biasActive
 - 增加检查 corner case 以避免 addr bug
 - 增加 Transform SME 支持
- ixBLAS v4.3.0
 - 支持 FP8 相关 gemm
 - 为 GEMM 提供 ixmma 支持
- ixFFT v4.3.0
 - 增加 cufftXt API 支持
 - 增加 FP16 和 FP64 的 SME 支持
 - 增加 double API 支持
 - 增加 nvrtdc 支持与优化
- ixSolver v4.3.0
 - 为小矩阵优化 DnCheevjBatched 函数
 - 新增 DnSgebrd(m>=n) 函数实现
 - 新增 DnSpotri 函数实现
 - 新增 cusolverDnSgesvdjBatched 实现并优化 cusolverDnSgesvdj 调用
- ixAttention-Backend v4.3.0
 - 新增 Flash-Attention 相关的 API 接口支持
- ixCCL v2.3.0.2143
 - 优化多机间通信 Pipeline 性能
 - 优化单机内跨 CPU 自动选择通过 SHM/NIC 的逻辑
- ixCC v4.3.0-x86/v4.3.6-ARM
 - LLVM 适配从 v16.x 升级至 v18.x
 - Function call 功能支持
- ixDriver v4.3.0-x86/v4.3.6-ARM
 - 完善 CUDA Graph 支持
 - Launch Kernel 性能优化
 - 增加离散显存支持
- ixDCGM v3.1.0

- ixDCGM 从 v2.0.0 升级至 v3.1.0
- 支持部分官方 DCGM v4.0 版本功能
- 增加 XID (Exception ID, 异常报错码) 的相关功能支持
- 完善 Field 相关的 API 支持
- ixHWPerf v4.3.0
 - 支持 FP64
 - 增加 parallelHostDeviceLatency 测试工具
- ixSMI v4.3.0
 - 增加以 1ms 为周期的采样功能
 - 支持 HBM 温度显示
 - 支持 XID (Exception ID, 异常报错码) 功能
- ixSYS v4.3.0
 - 优化大 Trace 处理能力
 - 支持 CUDA Graph Profiling, 命令行的分析功能
- ixGDB v4.3.0
 - 完善对变量查看的支持
- ixKN v4.3.0
 - 支持查看汇编伪码
- ixSAN v4.3.0
 - 新增内存检测工具
- ixObjdump v4.3.0
 - 新增二进制文件分析工具
- ixLogCollect v4.3.0
 - 新增 Log 收集工具
- ix-Container-Toolkit v1.0.0
 - 支持 Containerd v3 Config 功能
- K8s ix-Device-Plugin v4.3.0
 - 支持 volcano mode
 - 支持 custom resource
- K8s ix-Exporter v4.3.0
 - 支持通过 ixDCGM 获取进程信息
 - 新增支持 Helm Chart 部署
 - 实时响应 ix-Config 中的 Splitboard Flag 变动
- K8s ix-GPU-Operator v4.3.0

- 新增支持 Helm Chart 部署
- 统一并格式化 Operator 和各组件镜像的 Repository 和 Version
- 优化部署逻辑
- Torch Debug v0.1.0
 - 新增 Flash_attn 框架算子和部分通信算子的 dump 支持
 - 优化误差评价指标和算子对比功能
- corex-installer 安装包
 - 修复驱动文件被 DKMS 写入 initramfs 问题
 - 移除性能测试工具目录 /usr/local/corex/extra
 - 新增性能测试工具子包，目录为 /usr/local/corex/toolbox
- corex-toolbox 安装包
 - 新增 corex-toolbox 安装包，包含性能测试工具

在天数智算软件栈 V4.3.0-x86 版本中，存在以下已知问题：

- 部分单元测试 Case 偶现精度不达标问题
- TensorFlow v2.16.2 存在部分小模型训练失败问题

在天数智算软件栈 V4.3.6-ARM 版本中，存在以下已知问题：

- 在非标准安装的环境中，如安装了 InfiniBand 网卡及其驱动但未安装 ofa_kernel，机器可能因 mlx5_core 异常而挂掉
- 部分场景下软件栈无法分配内存，出现 OOM，并且 KMD 部分资源被占用
- Flash-Attention 部分单元测试 Case 偶现精度不达标问题
- TensorFlow v2.16.2 (ResNet50, FaceNet, SSD, BERT) 存在模型训练失败问题
- Transformer bs_32/bs_64 性能较 V4.1.3-arm 有下降，将在后续版本修复验证
- YOLOX bs_64 性能较 V4.1.3-arm 版本有下降，将在后续版本修复
- 使用 DKMS 模式安装和卸载驱动包时，会将 iluvatar.conf 文件写入 initramfs 镜像
- ixRT 运行 Convnext_tiny, Convnext_small, Convnext_large 模型时出现 coredump
- ixRT 运行 YOLOv9e 模型时，在部分 batch size 下出现异常
- 小模型推理 (YOLOv5m, YOLOX, Transformer) 性能较之前版本有下降
- Conformer 和 Dbnet 模型训练时报错
- 大模型 DeepSeek-R1-W4A8 单并发推理性能较之前版本有下降
- 大模型 Codeshell-7b-chat-4bit 推理乱码
- IxStream 插件 IxTracker 开启 DCF 模式会出现 Dagger Error 报错导致进程退出

Note

ARM 架构暂不支持 Bitsandbytes。

在天数智算软件栈 V4.3.0-x86 版本中，有以下问题已修复：

- IxStream 修复了 Gst-IxJpuEncode 结束时的报错问题
- 修复了单进程多卡 (DP) 分布式训练可能存在 Tensor 地址未 64 字节对齐导致的计算精度问题

在天数智算软件栈 V4.3.6-ARM 版本中，有以下问题已修复：

- 修复了部分 ARM 服务器上大量的 Page Fault 会造成 CPU Stuck 问题

- 修复了 cublasCgetrfBatched 和 cublasCgetriBatched 精度误差
- 修复了 Conformer 模型偶现 NotImplementedError 报错或 hang 住的问题
- 修复了 YOLOv5 模型训练报错的问题
- 修复了 Maskrcnn ResNet50 模型训练的问题
- 修复了个别场景下 vLLM 服务启动异常的问题
- 修复了 LLaMA2 预训练稳定性问题

1.3 Version 4.2.1

天数智算软件栈 V4.2.1 版本同时适用于天垓 150 加速卡和智铠 50/100 加速卡。

在天数智算软件栈 V4.2.1 版本中，修复了以下问题：

- ixRT 修复 Sample 配置错误及优化与文档一致

Note

产品文档请参考 V4.2.0 版本。

1.4 Version 4.2.0

天数智算软件栈 V4.2.0 版本同时适用于天垓 150 加速卡和智铠 50/100 加速卡。

在天数智算软件栈 V4.2.0 版本中，提供了以下功能增强和更新：

- PyTorch v2.4.1
 - PyTorch 从 v2.1.1 升级至 v2.4.1
 - 完善 torch.compile 功能
 - 新增支持 Tensor Parallelism
- PaddlePaddle v2.5.2
 - 新增支持 FP32 Flash-Attention
 - 优化 OCR 训练性能
- TensorFlow v2.12.0
 - 新增支持 BF16 GEMM
 - 优化 XLA
- DeepSpeed v0.15.3
 - DeepSpeed 从 v0.14.3 升级至 v0.15.3
 - 新增 Inference 支持 torch.compile
 - 新增 linear 兼容 PyTorch v2.4
 - 新增 MoE 支持 Topk Gate 等
- Megatron-LM Core v0.8.0
 - Megatron-LM Core 从 v0.6.0 升级至 v0.8.0
 - 新增支持 TP Overlap 的 Token Dispatcher
 - Megatron-LM-Example 新增支持精度和性能校验

- 新增支持 Zero Bubble Pipeline Parallelism (ZBPP) 并行策略等
- ix-TransformerEngine (ixTE) v0.2.4
 - ixTE 从 v0.2.0 升级至 v0.2.4
 - 优化支持 Token Dispatcher 和 Fused Mlp
 - 优化并支持 MoE
- Flash-Attention v2.6.3
 - Flash-Attention 从 v2.5.8 升级至 v2.6.3
 - 对接 ixDNN 支持相关优化
- LLaMA-Factory v0.9.0
 - 首次发布 LLaMA-Factory v0.9.0 框架，添加了 Megatron-LM 后端支持以优化天数智芯加速卡大模型微调性能。针对 LLaMA3-8B, LLaMA3-70B, Qwen2.5-7B, Qwen2.5-72B 等 LLaMA 和 Qwen 系列模型的 SFT 全量微调，大幅提升性能
 - 支持 LLaMA-Factory 原生功能
- Triton v2.1.0
 - 优化缓存文件磁盘占用
 - 新增 FP32 dotOperand Load+trans 实现
- Apex v0.1
 - 更新 MHA 相关功能
- Megatron-DeepSpeed v2.5.0
 - 代码重构，基于 Megatron-LM Core v0.8.0 重新适配
 - 使用入口变为 Megatronspeed.megatron_adaptor
- Colossal-AI v0.4.4
 - Colossal-AI 从 v0.3.6 升级至 v0.4.4
 - 新增 Colossal-Inference 和批数据广播机制功能
 - 优化 LLaMA2/Mixtral 等模型性能
 - 支持 DeepSeek-7B, Open-Sora, LLaMA3
- ONNXRuntime v1.17.1
 - ONNXRuntime 从 v1.13.1 升级至 v1.17.1
 - 支持 ixRT, IGIE, GPU, CPU 后端的推理
- ixFormer v0.6.0
 - 新增支持双卡通信量化，优化通信算法、跨 NUMA 通讯等
- vLLM v0.6.3
 - vLLM 从 v0.5.0 升级至 v0.6.3
 - 支持多种量化，W8A8, W8A16 等；支持 LORA；支持 W8A8 MoE
 - 支持 Chunk-Prefill
 - 支持 Prefix Caching
 - 支持 TP Overlap, PP 混合等
 - 支持 Speculative Decoding，新增 Encoder-Decoder 模型 (LLamav-3.2)
 - 支持通信量化

- 新增支持 Text Generation, Text Embedding, Reward Modeling, Multimodal 模型
- TGI v2.1.1
 - 优化更新
 - 新增支持多模态大模型 Mllama (3.2, 视觉模型), Flashed, Unpadded
 - 改进 MoE 性能等
- TensorRT-LLM v0.12.0
 - TensorRT-LLM 从 v0.9.0 升级至 v0.12.0
- ixRT v0.10.0
 - ixRT 从 v0.9.1 升级至 v0.10.0
 - 新增支持 TensorRT 新版核心功能接口和 IR
 - 插件算子库新增 MultiscaleDeformableAttn 等多个业务专用算子
- IGIE v0.18.0
 - IGIE 从 v0.9.1 升级至 v0.18.0, 升级适配 TVM v0.18.0 版本
 - 近一步丰富 Relay IR 及前端算子解析
 - 新增更灵活的 Relax IR 及配套机制, 兼容升级前基于 Relay 的功能
 - 新增对 CV/NLP 场景下的 Dynamic Shape 模型推理支持等
- ixInfer v4.2.0
 - 新增 PageAttention API 和性能优化
 - 优化 FP16 Conv 和 INT8 Conv, Flash-Attention 任意 SeqLen, W8A8 Group Gemm 的性能
 - 完善 RNN 功能
 - 优化 Gemm 性能
- ixDNN v4.2.0
 - Flash-Attention 新增 FP16, BF16, FP32 功能支持, Mask 支持, 优化控制逻辑等
- ixBLAS v4.2.0
 - 新增 INT32 Gemm 支持
 - 增加对 Strsm, Gemv 的性能优化等
- ixFFT v4.2.0
 - 支持 32 位 Index, 部分 (fft1d 2 次幂) 支持双精度 (约 8bit Exponent, 49bit Mantissa), 部分 (2 次幂) 支持半精度 (Half, BF16)
 - 优化 2D 和 3D 的 FFT 性能
- ixStream v1.2.2
 - 新增支持 YOLOv9, YOLOv10
 - 增加 ixStream_Samples 示例代码
 - Gst-IxTracker 增加对 ixRT 模型引擎文件的支持
 - 优化日志输出
 - 优化 Gst-IxConverter 功能以支持更多格式转换
 - 修复若干问题
- ixCCL v2.14.3
 - 启用新版本编号 v2.2.0.2143

- 优化通信算子性能
- 修复 Profiling 功能
- 修复混训问题
- 修复稳定性问题
- ixCC v16.x
 - 优化编译器指令
- UMD Driver v4.2.0
 - 新增支持 CUDA Graph 功能
 - 优化完善日志系统
 - 新增支持 NUMA 亲和性设置，默认关闭
- KMD Driver v4.2.0
 - Page Fault 处理优化
 - Warm Reset 优化处理逻辑
- ixSMI v4.2.0
 - 新增支持 MR-V100 DUO, MR-V50 等新 PID
 - 新增支持电源芯片温度读取
 - 新增支持新 PID 适配方案
- ixPROF v4.2.0
 - 适配 PTI 的功能升级
- ixGDB v4.2.0
 - 新增支持寄存器变量查看，全局变量和静态 SLB 变量的查看
 - 修复变量查询错误的问题
- ixSYS v4.2.0
 - 新增支持 Event Sync 分析功能
 - 新增支持 IB NIC Metric Sampling 功能
 - 新增提供性能分析脚本和 Trace Diff 脚本
 - UI 新增 ARM_64 Trace_Processor_Shell 下载
 - UI 新增顶部工具栏，支持搜索、SQL 查询以及命令菜单，包含多个预定义命令
 - UI 新增 ixSYS 命令生成器，支持用户生成 ixSYS 命令参数
- ixDCGM v2.0.0
 - 新增支持 Pulse Test, Target_Power 测试
 - 新增支持 Health Check，主要是 PCIe 相关的健康检查功能
 - 新增支持功耗、ECC、Thermal、内存带宽等相关的事件查询
 - 新增提供 ixdcgmi 命令行工具
 - ixDCGM 工具集成到 Docker 镜像
- ix-Container-Toolkit v1.0.0
 - 新增支持 Docker, Containerd, Cri-o 运行时
 - 新增支持 CDI 标准
 - 新增支持创建包含天数智芯加速卡的容器

- K8s ix-Feature-Discovery v1.0.0
 - 新增支持天数智芯加速卡硬件信息标签生成
 - 新增支持天数智算软件栈信息标签生成
- K8s ix-GPU-Operator v1.0.0
 - 包含 ix-Device-Plugin 和 ix-Exporter 配置
 - 新增支持一键部署包含的天数云原生插件
- K8s ix-Exporter v4.2.0
 - 新增支持 Process Metrics
 - 新增支持 Node/Namespaces Metrics
 - 接入 GO-ixML API
 - 接入 GO-DCGM API, 对齐 ixDCGM Metrics 部分功能
- K8s ix-Device-Plugin v4.2.0
 - 新增支持单芯/单卡感知和分配
 - 新增支持多 Pod 共享单芯功能
 - 新增支持 Podman
 - 接入 GO-ixML API
- Torch Debug v0.1.0
 - 修复 OR_Range 传参的类型检查

在天数智算软件栈 V4.2.0 版本中, 提供了以下基础组件的更新:

- ixSPARSE, 完善 API 接口, 优化性能
- CUTLASS, 新增 Merge Sort 算法
- CUB, 新增支持 Merge Sort API
- ixThrust, 新增支持 Shuffle 算法
- 新增提供 ixSolver 函数库
- ixKN 工具新增 Local Memory 的 Trace, 及新增命令行查询 kernel 的算力和带宽信息
- ixPTI 工具新增支持 Profiling Ptsz 相关接口, 并解决接口 UT 测试中发现的问题和优化兼容性
- LLM-Inference-Benchmark 新增提供以下大模型推理示例:
 - Qwen2.5-72B-Instruct
 - Qwen2.5-72B-Instruct-GPTQ-Int4
 - Qwen2.5-72B-Instruct-awq-Int4
 - Qwen2.5-14B-Instruct
 - Mixtral-8x22B-Instruct-v0.1
 - Qwen2-VL-7B

在天数智算软件栈 V4.2.0 版本中, 存在以下已知问题:

- Docker installer 环境中缺少 sox 和 libsox-fmt-all 导致 Conformer 模型报错, 更新依赖可解决该问题
- Python v3.8 的兼容性问题由于官方已经 EOL, 故不修复, 建议后续升级 Python 版本
- TensorRT-LLM LLaMA2-7B Beam Search 由于未在 chat 推理任务上微调, 会出现因精度较差而导致输出结果低于预期
- TensorRT-LLM Llama3-8B Build engine enable use_fused_mlp 输出乱码
- 部分 LLaMA-Factory 微调的模型 (LLaMA3-70B, Qwen2.5-7B, Qwen2.5-72B) 性能低于预期

- 单进程多卡 (DP) 分布式训练可能存在 Tensor 地址未 64 字节对齐导致的计算精度问题，需要设置环境变量来规避：**export PYTORCH_DP_BYTE_ALIGNED=1**
- 建议使用 Numpy v2.0.0 及以下版本，其它版本可能会有兼容性问题，从而导致部分模型运行异常
- 多流功能默认关闭，手动设置开启后有较低概率触发 Hang，该问题将在后续版本修复

在天数智算软件栈 V4.2.0 版本中，有以下问题已修复：

- PyTorch 框架修复了 Flash-Attention 中内存分配失败继续运行导致的 Hang 问题
- PaddlePaddle 框架修复了 Layernorm 精度问题和 CTCAlign 导致的 Hang 问题
- TensorFlow 框架修复了 Profiling 获取不到 OP Name 信息的问题
- Triton 框架修复了 Cache 策略导致的测试报错
- Apex 框架修复了 Layernorm 精度问题
- ixCC 编译器修复了 YOLOv5s FP16 Batch Size 在 4 至 128 之间的性能下降问题
- ixCC 编译器修复了 Token Attention Flash Decoding 性能下降问题
- ixSMI 工具修复了内存泄漏问题

1.5 Version 4.1.1-SP1

在天数智算软件栈 V4.1.1-SP1-BI150 版本中，提供了以下功能增强和更新：

- 新增天核 150 OAM 型号加速卡的适配支持
- 新增 ixSMI 工具对电源温度的读取功能

在天数智算软件栈 V4.1.1-SP1-BI150 版本中，修复了以下问题：

- 修复大部分模型训练 Hang 及训练异常等问题
- 修复 Docker 安装环境中部分任务出现的随机报错问题

在天数智算软件栈 V4.1.1-SP1-BI150 版本中，存在以下已知问题：

- Numpy 建议使用 v2.0.0 以下版本，其它版本可能会有兼容性问题导致部分模型运行异常
- 在循环重启驱动时，有较低概率触发 CPU 卡死，该问题将在后续版本修复

1.6 Version 4.1.1

在天数智算软件栈 V4.1.1-BI150 版本中，提供了以下功能增强和更新：

- 新增 ixDCGM v1.0.0 版本工具集发布，支持在集群环境中管理和监控天数智芯数据中心加速卡
- 新增支持异构混训产品特性
- 优化 Megatron-LM Core v0.6.0 适配
- 优化 Megatron-DeepSpeed v2.4.1 适配
- 完善 ix-TransformerEngine v0.2.0 对低版本 Python 兼容
- 优化 TensorFlow v2.12.0 和 PyTorch v2.1.1 适配
- 优化 Torch Debug v0.1.0 工具支持，增加多进程及使用 GPU 对比数据功能支持
- 优化 ixSMI 工具的 Topo 显示
- 优化 ixKN 和 ixSYS 工具

在天数智算软件栈 V4.1.1-BI150 版本中，存在以下已知问题：

- PyTorch scaled_dot_product_attention 接口仅支持 512 及以下的 Embedding Dimension，后续版本根据需求情况完善
- Numpy 建议使用 v2.0.0 以下版本，其它版本可能会有兼容性问题导致部分模型运行异常
- 多流功能默认关闭，手动设置开启后有较低概率触发 Hang，该问题将在后续版本修复
- 在循环重启驱动时，有较低概率触发 CPU 卡死，该问题将在后续版本修复
- TensorFlow 框架下 ResNet50 模型训练存在 Core Dumped 问题，概率约为 25%，该问题将在后续版本修复

1.7 Version 4.1.0

在天数智算软件栈 V4.1.0-BI150 版本中，框架与引擎提供了以下功能增强和更新：

框架与引擎：

- 新增适配应用加速库 ix-TransformerEngine v0.2
- 新增适配深度学习框架 Colossal-AI v0.3.6
- 新增 Torch Debug 工具，可为 PyTorch 框架下的网络层算子提供精度分析对比等功能
- 优化 PyTorch v2.1.1 框架适配，新增 Torch FMHA 切到 ixDNN，新增 FP32 支持等相关功能，并修复相关已知问题
- 优化 TensorFlow v2.12 框架适配，并修复相关已知问题
- 优化 PaddlePaddle v2.5.2 框架适配，并修复相关已知问题
- 优化 Triton v2.1.0 框架适配，并修复相关已知问题
- 优化 Megatron-DeepSpeed v2.4.1 框架适配，代码更新至最新，并修复相关已知问题
- Megatron-LM 框架适配从 v0.4.0 升级至 v0.6.0，新增支持 Overlap 方案，并优化大模型训练性能
- DeepSpeed 框架适配从 v0.11.1 升级至 v0.14.3，新增支持 ZeRO-Offload++ 等功能
- FlashAttention 加速库适配从 v2.0.1 升级至 v2.5.8，优化算法库性能，新增 Sliding Window Attention 支持及相关功能完善
- ixFormer 推理框架从 v0.4.0 升级至 v0.5.0，优化相关算法并完善相关功能
- vLLM 推理引擎适配从 v0.2.6 升级至 v0.3.3，并完善相关功能
- TGI 推理引擎适配从 v1.1.0 升级至 v1.4.3，支持 n-gram 并行解码技术以及 Qwen AWQ 推理
- ixRT 推理引擎从 v0.9.0 升级至 v0.9.1，并完善相关功能

在天数智算软件栈 V4.1.0-BI150 版本中，模型与示例提供了以下功能增强和更新：

模型与示例：

- 优化主流通用深度学习训练模型性能，提供 DeepLearning Samples 模型示例
- 优化主流通用深度学习推理模型性能，提供 Inference Samples 模型示例
- 优化大模型 LLaMa2-7B / LLaMa2-34B / LLaMa2-70B 预训练、LLaMa2-34B / ChatGLM2-6B SFT 全量微调训练、ChatGLM2-6B 高效微调训练 P-Tuning v2

在天数智算软件栈 V4.1.0-BI150 版本中，函数库提供了以下功能增强和更新：

函数库：

- 优化 ixCCL 通信库，新增 Send / Recv 融合功能实现，并优化 Allreduce / Allgather 等功能
- 优化并完善高性能加速库 ixDNN、ixBLAS、ixFFT、ixINFER、CUB、THRUST、ixSPARSE 等
- 优化多媒体编解码库 ixCODEC 和 ixJPEG，并修复相关已知问题

在天数智算软件栈 V4.1.0-BI150 版本中，软件栈工具提供了以下功能增强和更新：

软件栈工具：

- 优化 ixSMI 系统管理工具，
 - 新增调节 TDP 功能，支持 350W 和 450W 两档
 - 新增 SM_ACTIVE、SM_OCCUPANCY、PCIE throughput 等 Metrics 查询功能
 - 完善 Event 和 topo 查询功能等
- 优化 ixSYS 系统性能分析工具，新增 CUDA_Device 的子集，并完善 UI 功能界面
- 优化 ixKN 核函数性能分析工具的 HBM 利用率的实现，并修复相关已知问题

在天数智算软件栈 V4.1.0-BI150 版本中，编译器提供了以下功能增强和更新：

编译器：

- 优化并完善 ixCC 编译器，并修复相关已知问题

在天数智算软件栈 V4.1.0-BI150 版本中，驱动提供了以下功能增强和更新：

驱动：

- 优化 ixDriver 驱动，新增支持 Overlap 方案，以及 GDS 加入非 4K 对齐 Read/Write 兼容支持，并修复丢中断、Pagefault、内存泄漏等问题

在天数智算软件栈 V4.1.0-BI150 版本中，固件升降级工具提供了以下功能增强和更新：

固件升降级工具：

- 优化 Firmware 版本升级/降级工具，并完善 Flash 写保护问题处理逻辑

在天数智算软件栈 V4.1.0-BI150 版本中，K8s 插件提供了以下功能增强和更新：

K8s 插件：

- 优化 K8s ix-Device-Plugin GPU 访问插件，新增 GPU 优选调度逻辑，并完善 GPU 健康状态监测功能
- 优化 K8s ix-Exporter GPU 远程监控插件，并完善相关功能

在天数智算软件栈 V4.1.0-BI150 版本中，文档提供以下更新：

文档：

- 新增《TorchDebug 精度调试工具使用指南》、《Colossal-AI 框架功能说明》和《天数智芯加速卡常见问题分析手册》
- 其他更新项，请参考各文档详情

1.8 Version 3.4.0

框架与引擎：

- 新增适配训练框架 Megatron-LM v0.4.0
- 新增适配训练框架 Triton v2.1.0，支持 PyTorch v2.1.1 训练
- 新增适配推理引擎 vLLM v0.2.6，支持 BF16；支持 Rope Scaling；支持 AWQ 等内容
- 新增适配推理引擎 TGI v1.1.0
- 新增适配应用加速库 Flash-Attention v2
- PyTorch 框架适配从 v1.13.1 升级至 v2.1.1，并优化相关功能

- PaddlePaddle 框架适配从 v2.4.1 升级至 v2.5，并支持相关大模型训练
- DeepSpeed 框架适配从 v0.10.0 升级至 v0.11.1，并修复相关已知问题
- Megatron-DeepSpeed 框架适配从 v0.2.0 升级至 v2.4.1，并支持相关大模型微调
- TensorFlow v2.12 框架适配优化，并修复相关已知问题
- ixFormer 推理框架适配从 v0.3.0 升级至 v0.4.0，支持 Flash-Attn ALiBi 位置编码；优化 Tensor 转换开销，支持 INT8 和 INT4 算子等内容
- APEX v0.1 应用框架适配优化，包含 Swiglu，RMSNorm Residual 等内容

模型与示例：

- 新增支持 Aquila2-70B 预训练、Aquila2-34B 预训练与 SFT 全量微调、ChatGLM2-6B 全量参数微调与 P-Tuning v2 微调等大模型训练性能，支持 LLaMA2-7B TinyLLaMA 大模型 RLHF 微调训练
- 优化 LLaMA2-7B、LLaMA2-13B、ChatGLM2-6B 等大模型推理能力
- 优化主流通用深度学习训练模型性能，提供 DeepLearning Samples 模型示例
- 优化主流通用深度学习推理模型性能，提供 Inference Samples 模型示例

函数库：

- 升级 ixCCL 通信库，优化大模型训练、推理通信等相关内容
- 优化并完善高性能加速库 ixDNN、ixBLAS、ixFFT、ixINFER、CV-CUDA
- 优化多媒体编解码库 ixCODEC 和 ixJPEG，并修复相关已知问题

软件栈工具：

- 优化 ixSMI 系统管理工具，适配更多硬件版本，并优化显示
- 优化 ixSYS 系统性能分析工具，并修复相关已知问题
- 优化 ixKN 核函数性能分析工具的 HBM、ALU 利用率实现，并修复相关已知问题

编译器：

- 优化并完善 ixCC 编译器，并修复 LLVM 16 适配中的已知问题

固件升降级工具：

- 优化 Firmware 版本升级/降级工具，增加对不同板卡 Data 校验功能

K8s 插件：

- 更新 iluvatar-device-plugin.yaml 配置文件内容

文档：

- 新增《Megatron-LM 框架功能说明》和《Triton 框架功能说明》
- 更新《天数智芯加速卡 K8s 插件使用指南》中查询 K8s 插件版本的地址：
 - 软件栈版本为 V3.4.0 及以上时，查询地址为 <https://hub.docker.com/r/iluvatarcorex/ix-device-plugin/tags>
 - 软件栈版本低于 V3.4.0 时，查询地址为 <https://hub.docker.com/r/iluvatarcorex/k8s-device-plugin/tags>
- 其他更新项，请参考各文档详情

已知问题：

- PyTorch scaled_dot_product_attention 接口仅支持 64、128、256 的 Embedding Dimension，后续版本会完善支持。

- 手动打开并使用多流时，会小概率出现 hang，后续版本会完善支持。
- 在循环重启驱动时，有较低概率触发 CPU 卡死，该问题将在后续版本修复。

1.9 Version 3.3.0

本次发布为天垓 150 加速卡配套软件栈的第一次发布。

软件栈主要支持以下特性：

- 支持主流大模型训练框架 DeepSpeed v0.10.0 和 Megatron-DeepSpeed v0.2.0
- 支持天数大模型推理引擎 ixFormer v0.3.0
- 支持主流基本框架 PyTorch v1.13、TensorFlow v2.12、PaddlePaddle v2.4.1、ONNXRuntime v1.13
- 支持主流相关应用框架 Horovod v0.27.0、APEX v0.1、DALI v1.21.0，支持 Flash-Attention 高性能算子库
- 支持天数推理框架 IGIE v0.9、推理引擎 ixRT v0.8.0
- 支持天数开发或适配的高性能加速库 ixDNN、ixBLAS、ixFFT、ixINFER、ixSPARSE、ixRAND、CUB、CUTLASS、THRUST、CV-CUDA
- 支持 ixCCL 通信库，优化多卡大模型推理通信等特性
- 支持多媒体编解码库 ixCODEC 和 ixJPEG
- 支持 ixCC 编译器并升级适配 LLVM16
- 支持云原生 K8s ix-Device-Plugin GPU 访问插件和 K8s ix-Exporter GPU 远程监控插件

提供以下开发工具：

- ixSMI 系统管理工具
- ixSYS 系统性能分析工具支持大模型性能分析
- ixPROF 系统分析工具
- ixGDB 代码调试工具
- ixKN 核函数性能分析工具
- 硬件相关性能测试工具，包括带宽测试工具 BandwidthTest、矩阵算力测试工具 ixGEMM (INT8, FP16, FP32)、P2P 性能测试工具 P2pBandwidthTest 等

模型支持及示例：

- 支持主流通用深度学习训练模型，提供 DeepLearning Samples 模型示例
- 支持主流通用深度学习推理模型，提供 Inference Samples 模型示例
- 支持 LLaMa2-70B 和 ChatGLM2-6B Pretrain 大模型训练，Aquila-34B SFT 大模型微调，LLaMa2-13B 和 ChatGLM2 -6B 大模型推理等应用

商标声明

- 天数智芯、天数智芯 logo、Iluvatar CoreX 等商标、标识、组合商标为上海天数智芯半导体有限公司之注册商标或商标，受法律保护。
- CentOS 标识为 Red Hat 公司的商标。
- Docker 为 Docker 公司在美国和其他国家的商标或注册商标。
- Linux 为 Linus Torvalds 在美国和其它国家的注册商标。
- NVIDIA、CUDA、GeForce 和 GeForce GTX 为 NVIDIA 公司在美国和/或其它国家的商标和/或注册商标。
- PyTorch 为 Facebook 公司的商标。
- TensorFlow 为 Google 公司的商标。
- Ubuntu 为 Canonical 公司的注册商标。

除上述明确列出的商标外，本内容中可能存在的任何其他未明示的产品名称、服务名称、企业名称、标识、口号、域名或其他商业标记 (无论是否标注 ™ 或 ® 符号)，均假定归属于其各自合法的商标权人所有。