



天数智芯
Iluvatar CoreX

天数智芯

软件栈概述

版本：V4.3.0 (x86) | V4.3.6 (ARM)

日期：2025.6.30

适用产品：天垓 150 | 智铠系列

声明

版权与保密声明

本文档（属未发表作品）版权归属于天数智芯全权所有，且本声明不构成对本文档已发表的承认。本文档所载全部信息均为天数智芯保密信息（包括但不限于天数智芯技术信息、经营信息、专属于接收方的未公开资料等）。未经天数智芯事先书面许可，严禁任何形式的使用、复制、传播、转录或翻译。

免责声明

天数智芯可以随时对本文档或本文档中描述的产品进行改进和/或更改。本文档包括与天数智芯产品有关的信息，作为说明典型应用的一种方式，因此，不一定提供足以进行生产设计的完整信息。对于本文档中内容的准确性或完整性，天数智芯不做任何陈述或保证。

联系方式

地址：上海闵行区陈行公路 2168 号 3 幢

电话：021-68886607

网址：www.iluvatar.com

目录

1 软件栈概述	4
1.1 修订记录	4
1.2 软件栈概述	5
1.3 组件概览	6
1.4 支持框架生态	7
1.5 自研加速框架和引擎	8
1.6 自研异构混训框架	8
1.7 高性能加速库	9
1.7.1 函数库	9
1.7.2 通信库	9
1.8 编译器	9
1.9 驱动和运行库	9
1.10 工具	9
1.11 精度调试工具	11
1.12 数据流分析工具包	11
1.13 云原生部署与管理工具	11
1.13.1 管理简化工具	11
1.13.2 K8s 插件	12
1.13.3 容器工具包	12
1.14 虚拟化支持	12
1.15 示例项目	12
1.16 产品文档	13
1.17 联系我们	15
2 附录：天数智芯产品术语表	16

1 软件栈概述

1.1 修订记录

- COREX01-BI430-OV01-00: 2025/6/30
 - 更新“天数智算软件栈配置”图
 - 支持框架生态:
 - * 更新 TensorFlow 适配版本 v2.16.2
 - * 更新 PaddlePaddle 适配版本为 v3.0.0 Beta
 - * 更新 DeepSpeed 适配版本为 v0.16.4
 - * 更新 Megatron-DeepSpeed 适配版本为 v2.6.0
 - * 更新 Megatron-LM 适配版本为 v0.11.0
 - * 更新 Colossal-AI 适配版本为 v0.4.8
 - * 更新 LLaMA-Factory 适配版本为 v0.9.2
 - 新增自研异构混训框架 ixHetero
 - 工具 新增:
 - * 内存检测工具集 ixSAN
 - * 二进制文件分析工具 ixobjdump
 - * GPU 性能调试工具 ix-gpu-tuner
 - 更新示例项目 目录
 - 产品文档:
 - * 新增《ixHetero 异构混训框架功能说明》和《天数智芯加速卡调试指南和相关工具使用指》
 - * 删除《大模型应用迁移指南》，如有大模型应用迁移需求，请参考该大模型在 GitHub 开源仓库中的操作步骤
- COREX01-BI420-OV01-01: 2025/3/24
 - 示例项目 更新深度学习网络模型训练和推理示例脚本的存放目录
- COREX01-BI420-OV01-00: 2025/1/24
 - 更新“天数智算软件栈配置”图
 - 支持框架生态:
 - * 新增天数智芯适配版大模型训练框架 LLaMA-Factory v0.9.0
 - * 更新 PyTorch 适配版本为 v2.4.1
 - * 更新 ONNXRuntime_gpu 适配版本为 v1.17.1
 - * 更新 Colossal-AI 适配版本为 v0.4.4
 - * 更新 Flash-Attention 适配版本为 v2.6.3
 - * 更新 DeepSpeed 适配版本为 v0.15.3
 - * 更新 Megatron-DeepSpeed 适配版本为 v2.5.0
 - * 更新 Megatron-LM 适配版本为 v0.8.0
 - 工具 新增 Log 收集工具 ixlogcollect
 - 新增数据流分析工具包 ixStream
 - 云原生部署与管理工具 新增天数智芯加速卡特性标记插件，容器工具包 和管理简化工具
 - 虚拟化支持 新增 svGPU 方案

- **产品文档：**
 - * 对文档进行分类
 - * 新增《LLaMA-Factory 框架功能说明》、《IxStream 流分析工具包使用指南》和《天数智芯加速卡云原生工具和插件使用指南》
- COREX01-BI411-OV01-01：2024/11/18
 - **自研加速框架和引擎** 补充 IxFormer 的相关描述
- COREX01-BI411-OV01-00：2024/8/26
 - **工具** 新增加速卡管理工具集 ixDCGM 和 DMA 测试工具
 - 删除《深度学习训练和推理示例模型安装指南》，内容分别合并到《推理示例模型使用指南》、《PyTorch 框架使用演示》、《TensorFlow 框架使用演示》、《PaddlePaddle 框架功能说明》、《ONNXRuntime 框架功能说明》中
 - 新增“附录：天数智芯产品术语表”
- COREX01-BI410-OV01-00：2024/6/30
 - **支持框架生态：**
 - * 更新 Flash-Attention 适配版本为 v2.5.8
 - * 更新 DeepSpeed 适配版本为 v0.14.3
 - * 更新 Megatron-LM 适配版本为 v0.6.0
 - * 新增天数智芯适配版训练框架 Colossal-AI v0.3.6
 - **高性能加速库：**
 - * 新增 ix-TransformerEngine v0.2.0 大模型训练加速库
 - * ixCCL 接口兼容 NCCL 版本更新为 v2.14.3
 - **工具** 新增 GDS 基准测试工具
 - 新增**精度调试工具** TorchDebug v0.1.0
 - **示例项目** 更新 CUDA 官方示例代码项目和 CUTLASS 官方示例代码项目
 - **产品文档** 新增《TorchDebug 精度调试工具使用指南》、《Colossal-AI 框架功能说明》和《天数智芯加速卡常见问题分析手册》
- COREX01-BI340-OV01-00：2024/3/25

文档本次发布内容与 V3.3.0-BI150 文档相比 (COREX01-BI330-OV01-00)，有以下更新：

 - **支持框架生态：**
 - * 新增 Megatron-LM 和 Triton 框架说明
 - * 更新适配的框架版本
 - **工具** 新增通讯库性能测试工具
 - **产品文档** 新增《Megatron-LM 框架功能说明》和《Triton 框架功能说明》

1.2 软件栈概述

天数智算软件栈是一个针对天数智芯加速卡打造的高性能异构计算平台，针对通用计算和深度学习应用的开发和部署提供了一套完善而高效的软件栈工具，支持 x86 和 ARM 等架构。天数智算软件栈集成了多种主流的深度学习编程框架，并且提供了基于 C/C++ 的编程接口拓展和高性能函数库，赋予模型训练及推理更优异的性能

表现，还提供了一系列调试和调优工具，可以满足不同层次的应用开发及调试需求，为高性能计算和人工智能应用的开发和部署提供了便利。

开发者可以简单高效地实现深度学习以及各类数据科学应用的开发和调试。得益于天数智算软件栈对主流深度学习编程框架及主流算子及网络模型的支持，开发者可以基于天数智芯加速卡开发更加简洁且通用的应用。天数智算软件栈支持数据并发任务，适用于并行运算场景，提供了高性能函数库，带来更高的程序执行效率。

1.3 组件概览

天数智算软件栈兼容主流 GPU 通用计算模型，提供支持主流 GPU 通用计算模型的等效组件、特性、API 和算法，可助力用户便捷地实现系统或应用的无痛迁移。天数智算软件栈支持常用的主流 GPU 通用计算 API，因此，多数情况下用户无需修改代码即能完成迁移。

天数智芯智算平台 IXUCA




图 1: 天数智算软件栈配置

如图所示，天数智算软件栈包括人工智能深度学习应用、主流框架、函数库、编译器及工具、运行时库及驱动。

- 天数智算软件栈集成了 TensorFlow、PyTorch、百度飞桨 PaddlePaddle 等国内外主流的深度学习框架，提供与官方开源框架一致的算子，并针对天数智芯加速卡持续优化性能。
- 天数智算软件栈提供 IGIE 推理框架和 ixRT 推理引擎，支持在天数智芯加速卡上实现最优推理性能。
- 天数智算软件栈的函数库不仅支持通用计算还提供了深度学习应用开发所需的基础算子，开发者可以便捷地调用这些算子灵活地构造各类深度神经网络模型以及其他机器学习领域的算法。

- ixJPEG 多媒体库为深度学习和超大规模多媒体应用程序中常用的图像格式提供高性能、GPU 加速的图片解码功能。
- ixCODEC 多媒体库提供全加速硬件视频解码能力，支持多路同时解码，完全独立运行于计算/图形引擎。
- 天数智芯编译器兼容主流 GPU 通用计算模型，且针对天数智芯加速卡的汇编语言做了多种优化。
- ixSMI 工具能够采集天数智芯加速卡的底层硬件信息，并实时获取上层软件对硬件资源调度状态等。
- ixPROF 工具能够收集和查看追踪数据，可针对天数智芯加速卡进行性能剖析。
- ixKN 工具在 CUDA 核函数 (kernel) 执行期间，抓取性能分析指标 (event/metric) 的数据。
- ixSYS 工具在 CUDA 应用程序运行时对系统进行采样抓取 trace，trace 信息可用 web 图形化方式统计及展示。
- ixGDB 工具是基于 CUDA-GDB 并提供针对天数智芯加速卡的 CUDA 应用程序的开源调试工具。
- ixDCGM 工具集用于在集群中管理和监控天数智芯数据中心的加速卡。
- ixLogCollect 工具用于一键收集系统 Log 以及 UMD/KMD 相关 Log，方便用户排查问题。
- 运行时库提供了一套针对天数智芯加速卡的上层编程接口，用于与 GPU 硬件之间进行交互和调度硬件资源。

1.4 支持框架生态

天数智算软件栈提供以下深度学习框架的天数智芯适配版，天数智芯加速卡兼容主流 GPU 通用计算模型，支持深度学习框架大多数算子 (op)。您无需修改代码就可进行模型训练和推理，无需特殊设置您就可以尝试直接运行应用。

- TensorFlow v2.16.2
- PyTorch v2.4.1
- PaddlePaddle v3.0.0 Beta
- ONNXRuntime_gpu v1.17.1
- Horovod v0.27.0
- Colossal-AI v0.4.8
- LLaMA-Factory v0.9.2

支持常见网络模型及以下功能特性：

- 自动混合精度
 - PyTorch：支持 [torch.cuda.amp](#) 和 [Apex 加速库](#)
 - TensorFlow：支持，详见 https://www.tensorflow.org/guide/mixed_precision
 - PaddlePaddle：支持混合精度训练 AMP O1 和 AMP O2 级别的优化运行
- 多卡分布式训练
 - PyTorch：支持 Gloo 并兼容 NCCL，支持 [Horovod](#) 深度分布式训练框架，支持多机多卡
 - TensorFlow：支持 gRPC，支持 Horovod 深度分布式训练框架
 - PaddlePaddle：支持多机多卡分布式训练
- 支持加速库 (PyTorch)
 - [APEX](#)：Apex(A PyTorch Extension) 是 NVIDIA 的一个 PyTorch 扩展库，目前适配的版本是 v0.1
 - [DALI](#)：加速计算机视觉和音频深度学习应用程序的数据加载和预处理，目前适配的版本是 v1.21.0
 - [Flash-Attention](#)：开源高性能 Attention 算子库，目前适配的版本是 v2.6.3
- 支持主流大模型训练框架

- **DeepSpeed**：深度学习训练优化库，用以优化超大规模模型训练，目前适配版本是 v0.16.4
- **Megatron-DeepSpeed**：基于 PyTorch 并面向大规模语言模型的分布式训练框架，目前适配版本是 v2.6.0
- **Megatron-LM**：基于 PyTorch 并面向大规模语言模型的分布式训练框架，目前适配的版本是 v0.11.0
- **Triton**：用于编写高效的自定义深度学习原语的语言和编译器，目前适配的版本是 v3.1.0
- **Colossal-AI**：为用户提供一套综合的训练方法，目前适配的版本是 v0.4.8
- **LLaMA-Factory**：无需编写代码即可帮助用户在本地完成上百种预训练模型的微调方法，目前适配的版本是 v0.9.2

需了解详情，请参考：

- 《PyTorch 框架功能说明》
- 《TensorFlow 框架功能说明》
- 《PaddlePaddle 框架功能说明》
- 《ONNXRuntime 框架功能说明》
- 《DeepSpeed 框架功能说明》
- 《Megatron-DeepSpeed 框架功能说明》
- 《Megatron-LM 框架功能说明》
- 《Triton 框架功能说明》
- 《Colossal-AI 框架功能说明》
- 《LLaMA-Factory 框架功能说明》

1.5 自研加速框架和引擎

为了发挥天数加速卡的极致性能，软件栈还提供以下天数智芯自研框架和引擎：

- **IxFormer**：专用于大模型推理优化的加速框架，支持业界目前主流大模型的推理加速，实现大模型在天数智芯加速卡上的最佳推理性能。IxFormer 还提供了对 vLLM、TGI、Xinference 等框架进行推理加速的支持。
- **IGIE**：高性能、高通用、全流程的神经网络推理框架，可为推理场景提供易部署、高吞吐量、低延迟的完整方案。
- **ixRT**：天数智芯专用推理加速引擎，支持对业界主流训练框架的模型进行解析及优化，实现视觉、语音、推荐、自然语言等领域模型在天数智芯加速卡上的最优推理性能。

需了解详情，请参考：

- 《IxFormer(vLLM) 大模型推理框架使用指南》
- 《IGIE 推理框架使用指南》
- 《ixRT 推理引擎使用指南》

1.6 自研异构混训框架

为了能够充分利用开发者和各平台的计算资源，软件栈提供大模型异构混训框架 ixHetero。

ixHetero 是天数智芯自研的一款基于 Megatron-LM 框架的大模型异构混训框架，适用于天数智芯加速卡以及其他厂商加速卡之间进行大模型异构混训训练。

需了解详情，请参考《ixHetero 异构混训框架功能说明》。

1.7 高性能加速库

需了解高性能加速库详情，请参考《软件栈 API 参考》。

1.7.1 函数库

天数智芯适配版的函数库可用于多种数据类型 (如单精度浮点数、半精度浮点数) 的计算：

- ixBLAS：一系列基本向量和矩阵运算函数的接口标准
- ixFFT：快速傅里叶变换库
- ixDNN：深度神经网络基元库
- ixRAND：随机数库
- CUB：用于为 GPU 提供高性能的并行算法和数据结构
- CUTLASS：用于实现高性能的 GEMM 计算
- THRUST：用于简化高性能并行应用的开发
- ixSPARSE：线性代数运算高性能库
- CV-CUDA：适配 CV-CUDA v0.4
- ix-TransformerEngine：大模型训练加速库

1.7.2 通信库

天数智芯 ixCCL 通信库接口兼容 NCCL v2.14.3，并优化多卡大模型推理通信等相关内容。

1.8 编译器

天数智算软件栈提供编译器，采用了 LLVM 16 架构，适配天数智芯加速卡，支持以下功能：

- 提供适配天数智芯加速卡的汇编器和反汇编器
- 支持 Clang 16

如需了解详情，请参考《编译器使用指南》。

天数智芯还提供适配基于官方 CMake v3.25.2 的配版 CMake 构建工具，减少您迁移既有的 CUDA 程序时做的手动修改。

1.9 驱动和运行库

天数智算软件栈提供兼容 CUDA 的驱动 API (Driver API) 和运行时 API (Runtime API)，支持 CUDA 示例应用及深度学习框架。需了解更多关于软件栈支持的 API，请参考《软件栈 API 参考》。

1.10 工具

安装完天数智算软件栈后您可以使用以下工具：

工具	描述
系统管理工具	ixML 库提供了监控和管理天数智芯加速卡多种状态的 API。 ixSMI 工具提供系统管理信息，您可使用该工具对天数智芯加速卡进行监控。
Profiler 工具	ixPROF 工具收集和查看追踪数据，您可使用该工具了解天数智芯加速卡运行状态，并进行系统性能分析。
性能分析工具	ixKN 工具在 CUDA 核函数 (kernel) 执行期间，抓取性能分析指标 (event/metric) 的数据并进行图形化展示。 ixSYS 工具在 CUDA 应用程序运行时对系统进行采样抓取 trace，trace 信息可用 web 图形化方式统计及展示。
代码调试工具	ixGDB 工具是针对天数智芯加速卡中 CUDA 应用程序的开源调试工具。
加速卡管理工具集	ixDCGM 工具集用于在集群中管理和监控天数智芯数据中心的加速卡。
Log 收集工具	ixLogCollect 工具旨在帮助用户一键收集系统 Log 以及 UMD/KMD 相关 Log，方便排查问题。
内存检测工具集	ixSAN 工具集用于检查 CUDA 应用程序功能正确性，且包含多种检测工具。
二进制文件分析工具	ixobjdump 工具用于查看可执行文件中或库文件中包含的 elf 和 IR 文件，并执行查看和提取等相应的操作。

天数智芯测试工具将随天数智算软件栈同时安装。您可以使用以下测试工具：

工具	描述
带宽测试工具	bandwidthTest 工具提供 GPU memcpy 带宽以及 PCIe 中的 memcpy 带宽数据，可以测试 host 和 device，以及 device 间的传输带宽。
矩阵算力测试工具	gemm_perf 工具执行用户指定数据类型、循环次数和矩阵大小的 GEMM 运算。 CUTLASS Profiler 工具提供的算力信息中包括了 Tensor Core Unit 算力。
P2P 性能测试工具	p2pBandwidthTest 工具提供基于 DMA 的 P2P 传输性能测试。

工具	描述
通讯库性能测试工具	ixCCL-tests 工具用于验证 all gather、all reduce、all to all、broadcast、reduce scatter 等多卡通信 OP 的功能和性能。
GDS 基准测试工具	ixGDS 工具用于验证 GDS 功能是否可用。GDS 通过 DMA 使 GPU 与磁盘之间可以直接传输数据，避免了数据通过 CPU，可以提升数据传输带宽，降低 CPU 负载。
GPU 性能调试工具	ix-gpu-tuner 工具用于检测影响 GPU 最优性能使用的因素，例如，iommu, acs, 拓扑等。
(第三方类 FPGA 设备) DMA 测试工具	DMA 测试工具用于读写用户设备的内存。

需了解详情，请参考《软件栈工具使用指南》和《测试工具使用指南》。

1.11 精度调试工具

天数智芯提供 TorchDebug v0.1.0 调试工具，该工具基于 PyTorch 并用于调试模型算子精度问题。开发者可以使用 TorchDebug 工具在整个网络中提取模型前向/反向计算过程中每个算子的输入与输出信息，用于和参考对象的值进行比较，并对导出的精度异常数据和精度正常数据中包含的 Tensor 信息进行比对和误差计算，以定位计算有问题的算子。

1.12 数据流分析工具包

IxStream (Iluvatar Stream) SDK 是天数智芯提供的面向 AI 智能视频分析 (IVA) 以及多传感器数据流处理的工具包，旨在支持用户能够在部署了天数智芯加速卡和软件栈的硬件平台上快速开发和部署实时数据流分析 Pipeline。

1.13 云原生部署与管理工具

1.13.1 管理简化工具

天数智算软件栈提供 ix-GPU-Operator，用于帮助用户在 K8s 集群中一键配置、部署和管理天数智芯加速卡组件。ix-GPU-Operator 目前已集成天数智芯加速卡 K8s 设备插件 ix-Device-Plugin 和天数智芯加速卡 K8s 集群资源监控插件 ix-Exporter。您可以使用 ix-GPU-Operator 一键部署这两个插件。

需了解详情，请参考《天数智芯加速卡容器管理简化工具使用指南》。

1.13.2 K8s 插件

天数智算软件栈提供以下插件，方便您管理搭载天数智芯加速卡的 K8s 集群：

- 天数智芯加速卡 K8s 设备插件，可根据用户的请求动态地分配天数智芯加速卡资源。
- 天数智芯加速卡 K8s 集群资源监控插件，支持集群用户远程实时获取天数智芯加速卡的多项指标。
- 天数智芯加速卡特性标记插件，支持集群用户自动标记加速卡特性，优化资源管理并排查与监控故障。

需了解详情，请参考《天数智芯加速卡 K8s 插件使用指南》。

此外，天数智算软件栈支持 Docker 部署方式，方便用户在各种环境下快速入门。

1.13.3 容器工具包

天数智算软件栈提供 ix-Container-Toolkit，帮助用户简化在容器环境中使用天数智芯加速卡的过程。ix-Container-Toolkit 通过集成容器运行时与天数智芯加速卡驱动，使容器能够无缝利用加速卡资源。

需了解详情，请参考《天数智芯加速卡容器工具包使用指南》。

1.14 虚拟化支持

提供 svGPU (Software-assistant Virtualization GPU) 虚拟化方案，保证宿主机虚拟化整体安全隔离性的前提下，尽可能地让客户机直接操作 GPU 硬件，减小虚拟化带来的性能开销。

提供 vGPU 方案，针对天数智芯加速卡实现的基于 Kubernetes(K8s) 集群系统的 GPU 虚拟化，部署此方案后可以实现多用户同时使用天数智芯加速卡。

1.15 示例项目

以天数智算软件栈默认安装路径和 root 用户的示例脚本默认安装路径为例，天数智芯提供以下示例代码，方便您快速上手并熟悉天数智算软件栈的使用方式，也显示了您从主流生态可以无痛迁移到天数智芯加速卡：

- /usr/local/corex/examples：提供 Math API 示例代码
- /root/corex-samples-{v.r.m}_x86_64/samples/cudasamples/samples：提供以下 CUDA 官方示例代码
 - alignedTypes
 - asyncAPI
 - BlackScholes
 - clock
 - cppIntegration
 - cppOverload
 - deviceQuery
 - deviceQueryDrv
 - fastWalshTransform
 - jpegDec
 - jpegDecEnc

- jpegEnc
 - matrixMul
 - matrixMulDrv
 - matrixMul_nvrtc
 - mergeSort
 - reduction
 - shfl_scan
 - simpleCallback
 - simpleCUBLAS
 - simpleCUFFT
 - simpleMultiCopy
 - simpleMultiGPU
 - simplePrintf
 - simpleTemplates
 - simpleVoteIntrinsics
 - simpleZeroCopy
 - template
 - transpose
 - vectorAdd
 - vectorAddDrv
 - vectorAdd_nvrtc
- /root/corex-samples-{v.r.m}_x86_64/samples/cutlass/examples：提供以下 CUTLASS 官方示例代码
 - 00_basec_gemm
 - 01_cutlass_utilities
 - 02_dump_reg_shmem
 - 03_visualize_layout
 - 04_tile_iterator
 - 05_batched_gemm
 - 06_splitK_gemm
 - 07_volta_tensorop_gemm
 - 08_turing_tensorop_gemm
 - 10_planar_complex
 - 11_planar_complex_array
 - 12_gemm_bias_relu
 - 13_fused_two_gemms
 - \${path_to_package}/deeplearningsamples：提供深度学习网络模型训练示例脚本
 - \${path_to_package}/inferencesamples：提供深度学习网络模型推理示例脚本

1.16 产品文档

软件栈的功能还处于完善和扩展阶段，产品文档也在逐步完善，目前提供以下产品文档供您参考。

了解

- 《软件栈概述》：介绍天数智算软件栈的主要功能。

- 《版本发布说明》：版本发布内容的总体介绍。

安装验证

- 《固件升级工具使用指南》：提供升级固件的具体步骤。
- 《软件栈安装指南》：提供安装软件栈的具体步骤。
- 《软件栈安装快速入门》：提供快速安装软件栈的基本步骤。
- 《推理示例模型使用指南》：提供安装示例脚本和推理示例模型的具体步骤，以及推理模型测试步骤示例。
- 《软件栈工具使用指南》：描述 ixSMI、ixPROF、ixSYS、ixGDB 等工具的主要功能和使用方法。
- 《测试工具使用指南》：描述带宽测试工具、矩阵算力测试工具、P2P 性能测试等测试工具的主要功能和使用方法。
- 《天数智芯加速卡大模型推理测试参考指南》：提供使用天数智芯加速卡进行大模型推理的环境配置和测试步骤。
- 《智铠加速卡测试参考指南》：提供天数智芯加速卡的整体测试项与测试步骤，包含通信带宽、算力、功耗、视频解码、模型推理、压力测试等。

框架应用

- 《PyTorch 框架功能说明》：描述 PyTorch 框架下支持的算子、网络模型列表、加速库等功能特性。
- 《PyTorch 框架使用演示》：描述如何使用天数智芯提供的 PyTorch 网络模型测试脚本，对天数智芯加速卡的进行功能和性能验证。
- 《TensorFlow 框架功能说明》：描述 TensorFlow 框架下支持的算子和网络模型等功能特性。
- 《TensorFlow 框架使用演示》：描述如何使用天数智芯提供的 TensorFlow 网络模型测试脚本，对天数智芯加速卡的进行功能和性能验证。
- 《PaddlePaddle 框架功能说明》：描述 PaddlePaddle 框架下支持的功能特性和网络模型。
- 《DeepSpeed 框架功能说明》：描述 DeepSpeed 框架下支持的功能特性和网络模型，以及如何进行测试验证。
- 《Megatron-DeepSpeed 框架功能说明》：描述 Megatron-DeepSpeed 框架下支持的功能特性和网络模型，以及如何进行测试验证。
- 《Megatron-LM 框架功能说明》：描述 Megatron-LM 框架下支持的功能特性和网络模型，以及如何进行测试验证。
- 《Triton 框架功能说明》：描述 Triton 框架下支持的算子和网络模型等功能特性。
- 《Colossal-AI 框架功能说明》：描述 Colossal-AI 框架下支持的功能特性、网络模型和算子等。
- 《LLaMA-Factory 框架功能说明》：描述 LLaMA-Factory 框架支持的功能特性，以及如何进行测试验证。
- 《ixHetero 异构混训框架功能说明》：描述 ixHetero 异构混训框架支持的功能特性，以及如何进行测试验证。
- 《IxFormer(vLLM) 大模型推理框架使用指南》：介绍天数智芯推理框架 IxFormer 的功能特性、支持的第三方推理框架、支持的模型以及 IxFormer API，并指导用户使用 IxFormer 进行模型推理。
- 《IGIE 推理框架使用指南》：介绍天数智芯自研推理框架的功能特性、使用方法、示例代码等。
- 《ixRT 推理引擎使用指南》：介绍天数智芯自研推理引擎的功能特性、使用方法、示例代码、内置插件等。
- 《IxStream 流分析工具包使用指南》：介绍天数智芯提供的流处理工具包 IxStream 的功能模块、上手教程、应用示例、开发指南等。
- 《TorchDebug 精度调试工具使用指南》：提供 TorchDebug 精度调试工具的使用流程、使用示例、相关接口等。

开发使用

- 《软件栈 API 参考》：罗列软件栈支持的加速库 API。
- 《编程开发指南》：描述天数智算软件栈对主流 GPU 通用计算模型的扩展，以及在编程接口上的独特之处。

- 《编译器使用指南》：描述天数智芯编译器的使用步骤、命令、编译选项等，并提供针对示例代码的具体编译步骤作为示例。
- 《天数智芯加速卡调试指南和相关工具使用指南》：提供在使用天数智芯加速卡发生错误时可用的调试和诊断方法及技巧，并提供一系列调试工具的使用指导。

云原生/虚拟化

- 《天数智芯加速卡云原生工具和插件使用指南》：描述天数智芯加速卡 K8s 集群工具和插件的功能，并提供工具和插件的部署步骤和使用步骤。
- 《天数智芯加速卡 GPU 虚拟化 (VGPU) 部署指南》：提供部署天数智芯 VGPU 方案的具体步骤。VGPU 方案是针对天数智芯加速卡实现的基于 Kubernetes(K8s) 集群系统的 GPU 虚拟化方案，部署此方案后可以实现多用户同时使用一张天数智芯加速卡。
- 《天数智芯加速卡虚拟 GPU(svGPU) 使用指南 (基于 KVM)》：提供使用天数智芯加速卡 svGPU 方案的注意事项和操作说明。svGPU 方案是针对天数智芯加速卡实现的基于 KVM 虚拟化平台的 GPU 虚拟化方案，在保证宿主机虚拟化整体安全隔离性的前提下，尽可能让客户机直接操作 GPU 硬件，减小虚拟化带来的性能开销。

最佳实践

- 《CUDA 程序迁移指南》：描述把 CUDA 程序从其他平台迁移到天数智芯平台时的注意事项，并结合示例项目展示迁移步骤。
- 《天数智芯加速卡常见问题分析手册》：提供常见的天数智芯加速卡使用相关问题，并提供问题根因分析和对应的解决方法。
- 《天垓加速卡大模型性能优化指南》：提供常见的大模型性能优化场景和手段，相关问题及对应的解决方法。

1.17 联系我们

如您在使用天数智算软件栈的过程中碰到问题，或您对产品文档有任何建议，欢迎联系天数智芯应用工程师，我们将会及时回复您的疑问。

2 附录：天数智芯产品术语表

bandwidthTest

bandwidthTest 是带宽测试工具，提供 GPU memcopy 带宽以及 PCIe 中的 memcopy 带宽数据，可以测试主机和设备，以及设备间的传输带宽。

CUTLASS Profiler

CUTLASS Profiler 是矩阵算力测试工具，提供算力信息中包括的 Tensor Core Unit 算力。

gemm_perf

gemm_perf 是矩阵算力测试工具，执行用户指定数据类型、循环次数和矩阵大小的 GEMM 运算。

IGIE

IGIE 的全称是 Iluvatar GPU Inference Engine，IGIE 是一个针对天数智芯加速卡研发的高性能、高通用、全流程的神经网络推理框架，可为推理场景提供易部署、高吞吐量、低延迟的完整方案。

igie-exec

igie-exec 有时也作 IGIE-EXEC，igie-exec 是 IGIE 提供的一套基于命令行调用的模型快速部署和验证工具，方便用户一键运行 FP32/FP16/INT8 等模型推理和生成相应的引擎文件。

iluvatar-device

iluvatar-device 是天数智芯加速卡 K8s 设备插件，可根据用户的请求动态地分配天数智芯加速卡资源。

ixBLAS

ixBLAS 是天数智算软件栈内置的函数库，是一系列基本向量和矩阵运算函数的接口标准，适配 CUDA 主流版本。

ixCCL

ixCCL 是天数智算软件栈内置的 GPU 集合通信库，API 接口兼容 NCCL。

ixCCL-tests

ixCCL-tests 是通信库性能测试工具，用于验证 all gather, all reduce, all to all, broadcast, reduce scatter 等多卡通信 OP 的功能和性能。

ixCODEC

ixCODEC 是天数智芯研发的 VPU 视频硬件编解码模块，提供全加速硬件视频编解码能力，支持多路同时解码。

ix-container-runtime

ix-container-runtime 的作用是在容器启动前，根据指定的环境变量配置容器挂载的加速卡，完成指定加速卡的绑卡功能。

ix-Container-Toolkit

ix-Container-Toolkit 是天数智芯自研的容器工具包，帮助用户简化在容器环境中使用天数智芯加速卡的过程。

ix-ctk

ix-ctk 是用于配置 container runtime 和生成 CDI (Container Device Interface) 的 CLI 工具。

ixDCGM

ixDCGM 的全称是 Iluvatar Data Center GPU Manager，ixDCGM 是天数智芯数据中心加速卡管理软件，是一套用于在集群环境中管理和监控天数智芯数据中心加速卡的工具集。ixDCGM 的组件有用户空间库 libixdcm.so、主机侧服务端代理软件 ix-hostengine 和验证工具集 ixvs 及其测试插件。

ixDEC

ixDEC 是天数智芯研发的多媒体库，提供全加速硬件视频解码能力，支持多路同时解码。ixDEC 库现已弃用，功能同 ixCODEC 库。

ixDNN

ixDNN 是天数智算软件栈内置的深度神经网络基元库，适配 cuDNN，借助该加速库，开发者不必花时间针对天数智芯加速卡进行底层级的 GPU 性能调整，从而可以更专注于神经网络的训练和应用开发。

ix-Exporter

ix-Exporter 是天数智芯加速卡 K8s 集群资源监控插件，是一个 http 后台应用程序，支持集群用户远程实时获取天数智芯加速卡的多项指标。

ixFaiss

ixFaiss 的全称是 Iluvatar Facebook AI Similarity Search，主要针对聚类和相似性搜索，为稠密向量提供高效相似度搜索和聚类。

ixFFT

ixFFT 是天数智算软件栈内置的函数库，用于 GPU 加速的快速傅里叶变换实现，适配 CUDA 主流版本。

ix-Feature-Discovery

ix-Feature-Discovery 是天数智芯自研的 K8s 插件，旨在自动发现并标记 K8s 集群中节点上的加速卡特性。

IxFormer

IxFormer 有时也作 ixFormer，IxFormer 是天数智芯设计的专用于大模型推理优化的加速框架，支持业界目前主流大模型的推理加速，实现大模型在天数智芯加速卡上的最佳推理性能。

ixfw

ixfw 是天数智芯固件升级工具。安装文件名是 ixfw-{gpu_type}-{fw_version}_{ARCH}.run，固件升级包中的 {gpu_type} 表示天数智芯加速卡的型号，{fw_version} 表示固件版本，{ARCH} 表示适用的架构，如 ixfw-mr_100-2.0.17_x86_64.run。

ixGDB

ixGDB 工具是针对天数智芯加速卡中 CUDA 应用程序开发的开源调试工具。

ixGDS

ixGDS 是 GDS 基准测试工具，用于验证 GDS 功能是否可用。GDS 通过 DMA 使 GPU 与磁盘之间可以直接传输数据，避免了数据通过 CPU，可以提升数据传输带宽，降低 CPU 负载。

ix-GPU-Operator

ix-GPU-Operator 是天数智芯自研的一款基于 K8s Operator 框架开发的工具，目的是帮助用户在 K8s 集群中一键配置、部署和管理天数智芯加速卡组件。

ixgpu_to_third_party_dmatest

ixgpu_to_third_party_dmatest 是天数智算软件栈提供的 DMA 测试工具，用于读写用户设备的内存。

ixgpu-vm-p2p-tool

ixgpu-vm-p2p-tool 工具用于在虚拟环境中提升天数智芯加速卡之间 P2P 的传输性能。

ixHetero

ixHetero 是天数智芯自研的一款基于 Megatron-LM 框架的大模型异构混合训练框架，适用于天数智芯加速卡以及其他厂商加速卡之间进行大模型异构混训训练，从而充分利用开发者和各平台的计算资源。

ix-hostengine

ix-hostengine 是主机侧服务端代理软件，是 ixDCGM 的组件之一，依赖 libixdcmg.so 动态库。ix-hostengine 的主要工作是将 ixDCGM 库实例化为持久的独立进程，用于监视和管理当前服务器上的加速卡。

ixJPEG

ixJPEG 是天数智芯研发的函数库，为深度学习和超大规模多媒体应用程序中常用的图像格式提供高性能、GPU 加速的 JPEG 编解码功能，提供 jxJPEG Decode 解码库和 ixJPEG Encode 编码库。

ixKN

ixKN 是性能分析工具，在 CUDA 核函数 (kernel) 执行期间，抓取性能分析指标 (event/metric) 的数据并进行图形化展示。

ixLogCollect

ixLogCollect 是天数智芯自研的一款脚本工具，旨在帮助用户一键收集系统 Log 以及 UMD/KMD 相关 Log，方便进行问题排查。

ixML

ixML 是系统管理工具，提供了监控和管理天数智芯加速卡多种状态的 API。

ixobjdump

ixobjdump 是天数智芯提供的一款二进制文件分析工具，主要从 CUDA 二进制文件中提取信息，并以可读性较强的格式呈现给用户。

ixPROF

ixPROF 是 Profiler 工具，用于收集和查看追踪数据，用户可使用 ixPROF 了解天数智芯加速卡的运行状态，并进行系统性能分析。

ixPTI

ixPTI 的全称是 Iluvatar Profiling Tools Interface，提供基于 C++ 的接口，用于构建针对 CUDA 应用程序的 Profiling 和 Tracing 性能分析。

ixRAND

ixRAND 是天数智算软件栈内置的随机数库，适配 cuRAND 库，借助该加速库，开发者可以利用 GPU 的并行能力快速大量生成所需分布的伪随机数。

ixRT

IxRT 的全称是 Iluvatar CoreX RunTime，有时也作 ixRT，IxRT 是天数智芯的专用推理加速引擎，支持对业界主流训练框架的模型进行解析及优化。

IxRT-EXEC

IxRT-EXEC 有时也作 ixrt-exec，IxRT-EXEC 是一个集成在 IxRT 推理引擎中的命令行工具，支持用户在不同开发代码的场景下使用 IxRT 推理引擎快速运行 ONNX 模型。

ixSAN

ixSAN 的全称是 Iluvatar Sanitizer，是天数智芯提供的一款用于检查 CUDA 应用程序功能正确性的工具集，包含多种检测工具，可以按需执行不同类型的检查。

ixSMI

ixSMI 是系统管理工具，提供系统管理信息，用户可使用该工具对天数智芯加速卡进行监控。

ixSolver

ixSolver 是高性能线性代数库，专门用于在天数智芯加速卡上执行各种线性代数运算，旨在为科学计算、工程应用和机器学习等领域提供高效的矩阵计算功能。

ixSPARSE

ixSPARSE 是天数智算软件栈内置的线性代数运算高性能库，适配 cuSPARSE 库，该库提供了一系列用于处理稀疏矩阵的线性代数工具。

IxStream

IxStream 有时也作 ixStream，全称是 Iluvatar Stream，IxStream 是天数智芯提供的面向 AI 智能视频分析 (IVA) 以及多传感器数据流处理的工具包，旨在支持用户能够在部署了天数智芯加速卡和软件栈的硬件平台上快速开发和部署实时数据流分析 Pipeline。

ixSYS

ixSYS 是性能分析工具，在 CUDA 应用程序运行时对系统进行采样抓取 trace，trace 信息可用 Web 图形化方式统计及展示。

ixTX

ixTX 的全称是 Iluvatar Explorer Tools Extension，是一个基于 C 语言的应用程序编程接口，用于注释事件、代码范围和应用程序中的资源，为开发人员提供上下文信息。

ixvs

ixvs 的全称是 Iluvatar Validation Suite，ixvs 是用于检测和排除高性能计算环境中天数智芯加速卡常见问题的工具，是 ixDCGM 的组件之一。ixvs 主要关注软件和系统配置，诊断以及系统基本硬件性能等问题。

libixdcmg.so

libixdcmg.so 是一个用户空间的动态链接库，是 ixDCGM 的核心组件。基于 ixML 和 CUDA Toolkit 之上，libixdcmg.so 实现了 ixDCGM 的各种功能，并对外提供可使用的 C 语言 API 接口。

p2pBandwidthTest

p2pBandwidthTest 是 P2P 性能测试工具，提供基于 DMA 的 P2P 传输性能测试。

svGPU

svGPU 的全称是 Software-assistant Virtualization GPU，svGPU 是基于软件的 GPU 虚拟化方案，目前采用名为“mdev”(mediated device) 的虚拟化方案。该方案的核心思想是在保证宿主机虚拟化整体安全隔离性的前提下，尽可能地让客户机直接操作 GPU 硬件，减小虚拟化带来的性能开销。

TorchDebug

TorchDebug 是天数智芯研发的一款精度调试工具，该工具基于 PyTorch 并用于调试模型算子精度问题。

VGPU

VGPU 有时也作 vGPU，VGPU 方案是针对天数智芯加速卡实现的基于 Kubernetes 集群系统的 GPU 虚拟化方案。

全向箔

全向箔 SaaS 平台是天数智芯面向人工智能领域的企业和高校提供的人工智能开发平台，通过集群提供容器编排、资源调度和 GPU 虚拟化等服务。全向箔平台在此基础上提供可视化开发环境，提供颗粒度足够小的算力单元以满足不同用户的算力要求。用户可以快速发起训练和推理任务，有效提高开发和学习效率。

天垓 100

天垓 100 有时也作 BI100, BI-V100，天垓 100 加速卡是天数智芯的第一款云端训练产品，于 2021 年 3 月 31 日发布。

天垓 150

天垓 150 有时也作 BI150, BI-V150，天垓 150 加速卡是一款基于天数智芯自主研发的通用 GPU 架构的加速卡，板级功耗 350W，支持模型训练与推理功能。

天垓 150S

天垓 150S 有时也作 BI150S, BI-V150S，天垓 150S 加速卡是一款基于天数智芯自主研发的通用 GPU 架构的加速卡，板级功耗 450W，支持模型训练与推理功能。

天垓 150 OAM

天垓 150 OAM 有时也作 BI150 OAM, BI-V150 OAM，天垓 150 OAM 加速卡是一款基于天垓 150 芯片的通用 GPU 加速卡，采用 OAM 4U 模组，支持模型训练与推理功能。

天数智算软件栈

天数智算软件栈是一个针对天数智芯加速卡打造的高性能异构计算平台，针对通用计算和深度学习应用的开发和部署提供了一套完善和高效的软件栈工具，支持 x86 和 ARM 等架构。

智铠 100 DUO

智铠 100 DUO 有时也作 MR100 DUO, MR-V100 DUO，智铠 100 DUO 加速卡是一款基于天数智芯自研的智铠芯片的通用 GPU 加速卡，支持模型推理功能。

智铠 100

智铠 100 有时也作 MR100, MR-V100，智铠 100 加速卡是一款基于天数智芯自研芯片的通用 GPU 加速卡，支持模型推理功能。

智铠 50

智铠 50 有时也作 MR50, MR-V50，智铠 50 加速卡是一款基于天数智芯自研芯片的通用 GPU 加速卡，支持模型推理功能。

商标声明

- 天数智芯、天数智芯 logo、Iluvatar CoreX 等商标、标识、组合商标为上海天数智芯半导体有限公司之注册商标或商标，受法律保护。
- CentOS 标识为 Red Hat 公司的商标。
- Docker 为 Docker 公司在美国和其他国家的商标或注册商标。
- Linux 为 Linus Torvalds 在美国和其它国家的注册商标。
- NVIDIA、CUDA、GeForce 和 GeForce GTX 为 NVIDIA 公司在美国和/或其它国家的商标和/或注册商标。
- PyTorch 为 Facebook 公司的商标。
- TensorFlow 为 Google 公司的商标。
- Ubuntu 为 Canonical 公司的注册商标。

除上述明确列出的商标外，本内容中可能存在的任何其他未明示的产品名称、服务名称、企业名称、标识、口号、域名或其他商业标记 (无论是否标注 ™ 或 ® 符号)，均假定归属于其各自合法的商标权人所有。